LITERATURE REVIEW · PRIMER → FORMALISM → SUBSTRATES → OUTLOOK

Physics for AI：物理系统如何执行 AI 计算 —— 一篇文献综述

组织方式取法三篇范式综述：先补**预备知识**（给物理学者讲清卷积、kernel 与训练），再立**计算的形式体系**（Tanaka2019 的框架章、Rajak2022 的问题形式化、Halverson 讲义的 Question→Answer 行文），然后**按物理基质逐章**深读（机制 → 前驱工作 → 方法与公式 → 关键数字 → 特殊问题），以横向议题与总结展望收束。全文嵌入 25 幅原文图版与 5 幅自绘 SVG。

文献基础：**55 篇出版社全文**（papers/01–06 语料库）　嵌入原文图版：**25 幅**（逐张人工核验图注）　自绘示意图：**5 幅 SVG**

公式：**服务端 KaTeX 渲染的原生 MathML**（离线可读）　姊妹篇：**physics_for_ai_technical.html**（逐篇五段式条目 + 口径审计）

日期：**2026-09-24（第 3 版：新增预备知识章 + 各工作深读）**

本综述的组织逻辑（先读这一段）

- **第 2 节预备知识** —— 为没写过神经网络的读者补齐最小概念集：**卷积到底怎么算、kernel 是什么、训练的原理**（损失函数 → 梯度下降 → 反向传播），以及任务/数据集/精度的词汇表。全部用物理学者熟悉的方式讲解。
- **第 3 节形式体系** —— 仿照 Tanaka2019 先讲「储备池计算是什么」、Rajak2022 先写「横场 Ising 模型」的做法：在进入任何材料之前，把「物理系统凭什么能算」形式化为**三种计算原语**（前向线性映射 / 能量最小化 / 物理采样），给出数学表达与口径规则。
- **第 4–8 节按物理基质逐章** —— 每章固定骨架：**本章回答的问题 → 物理机制 → 代表实现（按时间序：研究动机 → 前驱工作链 → 方法与公式 → 关键数字 → 局限）→ 本基质的特殊问题**，仿 Rajak2022 对 QA 硬件/难题的章法与 Tanaka2019 对电子/光/自旋/机械/生物基质的分章。
- **行文采用讲义式 Question→Answer**（Halverson 讲义的风格）：每章以一个具体问题开场；每个量化数字沿用姊妹篇已核验的口径标注。
- **第 9 节横向议题、第 10 节总结与展望** —— 任务与基准、能效口径、可靠性、来自相邻领域的教训；结尾按「已经站稳的结论 / 开放问题」两份清单收束。
- **术语划界（重要）**：Halverson 的 Oxford 讲义把 "Physics for AI" 用作「场论 × 机器学习」的理论物理方向 —— 与本综述的口径（**物理器件与物理过程执行 AI 计算**）不同，见 §1.2 的边界讨论。
- **缩写约定**：每个专业缩写在首次出现处给出英文全称与中文译名，之后直接使用缩写。

01 引言：领域、边界与组织方式

1.1 领域与动机

现代 AI 的算力需求建立在冯·诺依曼架构之上，而该架构有一个结构性代价：**存储墙** —— 权重与激活值要在存储器和运算单元之间反复搬运， 搬运的能耗与时间往往高于运算本身。「Physics for AI」的出发点是让**物理过程本身完成计算**：用欧姆定律与基尔霍夫定律做矩阵乘、用磁性系统的能量景观做优化、用热涨落做采样、用光干涉做线性代数 —— 使「存储」与「计算」在同一个物理位置发生，甚至根本不存在「存储」这个概念（信息就是磁化方向、就是电导、就是相位）。

这一领域过去十年从器件物理的支线成长为有芯片、有系统、有评测方法学的研究方向。本综述把语料库中 55 篇出版社全文 按**执行计算的物理基质**归入五条硬件路径（存内计算 / 自旋与磁子 / 光子 / 概率与热力学 / 新兴基质）， 外加一条用于划界的对照轴（量子机器学习与 AI-for-physics）。划分依据是**物理机制**而非应用领域 —— 因为基质决定了器件形态、外围电路、瓶颈与可扩展性上限。

1.2 术语边界：两种「Physics for AI」

与 Halverson 讲义的术语区分

Halverson 的《Oxford Lectures on Physics for AI》（2025 年 3 月牛津 Physics for AI 会议讲义）把 "Physics for AI" 定义为**理论物理与机器学习的双向关系**：其第一讲是「Field Theory for Machine Learning」（把神经网络系综当作场论处理 —— NN-QFT（neural-network quantum field theory，神经网络量子场论）对应、 NTK（neural tangent kernel，神经正切核）、特征学习），第二讲是「Machine Learning for Field Theory」（NN-FT 对应、对称性与相互作用）。本综述**不覆盖这一方向**：这里的 "Physics for AI" 专指 **用物理器件与物理过程执行 AI 计算**（physical computing substrates for AI）。 两个方向共享「物理 × AI」的口号但研究对象不同 —— 前者研究**计算理论的物理结构**，本综述研究**计算的物理实现。** 我们在 §9.4 会回到 Halverson 讲义所属的相邻领域，讨论它对主体的方法论启示。

1.3 本综述的组织方式与阅读指南

本综述的章节安排直接取法三篇范式综述：

本综述	取法来源	对应做法
§2 预备知识	讲义式综述的惯例（如 Halverson 讲义对 NN 形式体系的自足引入）	为物理学者补齐 ML 侧的最小概念集：神经网络、卷积与 kernel、训练的原理、任务与数据集词汇表
§3 计算的形式体系	Tanaka2019 §2（RC（reservoir computing，储备池计算）框架）· Rajak2022 §1（横场 Ising 与 SAT（Boolean satisfiability，布尔可满足性）编码）· Halverson（形式定义先行）	在进入材料之前，先把「物理系统凭什么能算」形式化为三种计算原语，给出数学表达、性能量与口径规则
§4–8 按基质分章	Tanaka2019 §4–8（电子/光/自旋/机械/生物）· Rajak2022 §2–4（实现与难题）	每章固定骨架：本章问题 → 物理机制 → 代表实现（时间序）→ 演示任务 → 本基质的特殊问题
§9 横向议题	Rajak2022 §5（应用与对比）· Tanaka2019 各章的 issues 段	任务与基准、能效口径、可靠性 —— 跨基质讨论才公平的题目
§10 总结与展望	三篇共有的 Summary / Conclusion and outlook	「已经站稳的结论」与「开放问题」两份清单

行文采用讲义式 **Question→Answer** 节奏：每章以一个具体问题开场；文中每个量化数字沿用姊妹篇已核验的口径标注（器件级 / 单片级 / 系统级 / 仿真级 / 外推 / 模型预测），原文未提供者写「未提供」。 Rajak2022 综述（Phil. Trans. R. Soc. A 381, 20210417, 2022）与 Halverson 讲义仅取其组织思路与边界讨论， 未计入 55 篇语料计数。



图 1.1（自绘 SVG）· 领域总览。五条硬件路径按物理机制划分；对照轴（虚线）仅用于划界与教训提取。 语料量与「系统级指标报告率」的定量视图见姊妹篇 §2.1。

02 预备知识：读懂本文需要的 AI 计算概念

> **本章回答的问题：一个没写过神经网络的物理学者，最少需要哪些概念才能读懂第 4–8 节的每一篇工作？**
>
> 三样东西：**神经网络怎么算**（加权求和 + 非线性，§2.1）、**卷积怎么算、kernel 是什么**（滑窗内积 + 参数共享，§2.2）、 **训练的原理**（损失函数 → 梯度下降 → 反向传播，§2.3）。最后给一张任务与评测的词汇表（§2.4）和符号约定（§2.5）。 本章刻意用物理学者熟悉的方式行文：权重就是矩阵元，卷积就是离散内积，训练就是在一个高维参数景观上做梯度下降的弛豫过程。

2.1 神经网络与「权重」：一切从加权求和开始

一个**人工神经元**做的事极其简单：拿一组输入 $x_1, \dots, x_d$，各乘一个可调系数 w_i（**权重**），求和加偏置 b， 再过一个非线性函数 σ（**激活函数**，最常用的是 ReLU：$\sigma(x) = \max(0, x)$）：

$$y = \sigma\left(\sum_{i=1}^{d} w_i x_i + b\right)$$

把大量神经元排成层、层间全连接，就是**多层感知机**；每一层的加权求和写整齐就是一次**向量-矩阵乘（VMM）**：$y = \sigma(Wx + b)$。一个深度网络 = 「VMM → 非线性 → VMM → 非线性 → …」的级联。

关键观察：神经网络的全部「知识」都存在权重 W 里，而推理（用网络算一次结果）的全部计算量几乎都是 VMM ——这就是本综述第 3 节的形式体系里「原语 P1（前向线性映射）」成为各条物理路径首要目标的原因： **谁能在物理器件上便宜地做 VMM，谁就把推理搬进了物理系统。**第 4 节的交叉阵列、第 6 节的 MZI 网格，都是在回答这一个问题。

2.2 卷积与 kernel：滑窗内积 + 参数共享

卷积神经网络（CNN）处理图像，而图像是二维数组。它的核心操作——**卷积**——本质上是一个小矩阵（**kernel**，卷积核， 通常 3×3）在图像上逐格滑动，每停一格就做一次「对应相乘再求和」（内积），结果填进输出图的一个格子：

$$(I * K)(i, j) = \sum_{m=0}^{2} \sum_{n=0}^{2} K(m, n) \cdot I(i + m,\, j + n)$$

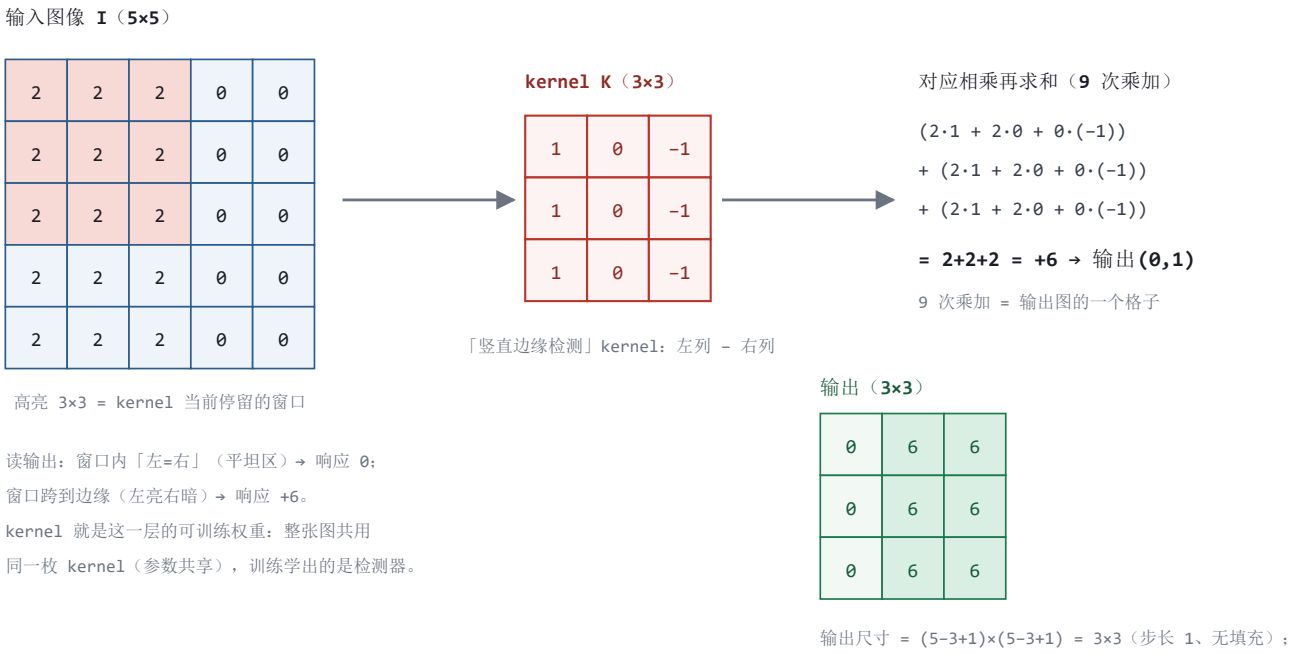


图 2.1（自绘 SVG）· 卷积的一次滑窗计算。输入是一张「左亮右暗」的 5×5 图像，kernel 是一枚竖直边缘检测器（左列 − 右列）。 高亮窗口的 9 次乘加求和得到输出图的一个格子（= +6，恰好在边缘处响应最大）； kernel 滑遍全图得到 3×3 输出 —— 平坦区响应为零、边缘处响应非零。 **kernel 就是这一层的可训练权重**：整张图共用同一枚 kernel（参数共享），所以卷积层的参数量远小于全连接层。

三件与后文直接相关的事：

1. **卷积 = 结构化的 VMM**：把滑窗内积排成矩阵，卷积等价于一个特殊稀疏结构（Toeplitz 型）的矩阵乘 —— 所以「物理器件做 VMM」天然也覆盖卷积； 但卷积的**滑窗串行性**与全连接的**并行性**吞吐不同 —— Yao2020 用「并行卷积器复制」解决的正是这个失配（§4.1），Dai2026 用畴壁位移直接实现「移位-累加」（§4.4）。
2. **kernel 是可训练权重**：训练时被更新的就是 kernel 的 9 个数。物理基质若想跑卷积，就要回答「kernel 存在哪、怎么更新」。
3. **多层卷积 = 特征逐层抽象**：浅层 kernel 检测边缘，深层组合出高级特征 —— 「五层 CNN」（Yao2020）就是五次这样的「卷积 + 下采样 + 全连接」级联。

2.3 训练的原理：损失函数 → 梯度下降 → 反向传播

> **问题：网络的几百万个权重是从哪来的?**
>
> 是**训练**（training）调出来的。三步循环：

第一步：定义损失函数 —— 「网络现在有多差」的标量度量。例如回归用均方误差 $L = \frac{1}{2}(y - \hat{y})^2$，分类用交叉熵。训练数据 $D = \{(x^\alpha, y^\alpha)\}$ 分成**训练集**（调权重用） 与**测试集**（只考不改，考核成绩 = **精度 accuracy**，如「MNIST 96%」指一万张测试图的分类正确率）。

第二步：梯度下降 —— 在权重空间里沿着损失函数的负梯度挪一小步：

$$w \leftarrow w - \eta \frac{\partial L}{\partial w}$$

物理图像：$L(w)$ 是参数空间里的能量景观，训练就是在里面做带步长 η（学习率）的**弛豫**。 实际操作用 **mini-batch 随机梯度下降（SGD）**：每步只用一小批数据估梯度 —— 噪声反而帮助跳出局部极小。

第三步：反向传播（backpropagation） —— 高效算出上式需要的全部偏导：从输出层的误差出发，用链式法则 $\partial L/\partial w^{(l)} = \delta^{(l)} \cdot a^{(l-1)T}$（$\delta^{(l)}$ 为第 l 层误差项，由下一层误差乘权重转置得到，$\delta^{(l)} = W^{(l+1)T}\delta^{(l+1)} \odot \sigma'$）逐层往回传播。 **一次训练步 = 一次前向传播 + 一次反向传播 + 一次权重更新** —— 计算量约为推理的 2–3 倍，还要写回权重。

> **为什么「训练」在物理计算里是难题（全篇反复出现的主题）**
>
> 反向传播要求**每个权重都知道自己的梯度**、要求前向通路逐层可微。物理基质里，权重是电导、相移、磁化构型——「梯度」必须穿过一个**不可微分的物理过程**（写入是非线性的、器件有漂移与噪声）。各章会反复回到三条回应线索：光域伴随法（Pai2023，§6.1）、硬件采样 + 对比散度（Niazi2024，§7.2）、片上写入训练（Wan2022，§4.1）；方法论层面的系统讨论见 Momeni2025 与 §3.4。

2.4 任务与评测的词汇表

术语	含义	本综述中的典型出现
MNIST	手写数字数据集（6 万训练 + 1 万测试张 28×28 灰度图），Modified National Institute of Standards and Technology database	几乎所有基质的首选演示任务（「MNIST 96.19%」= 测试集分类正确率）
CIFAR-10	10 类小尺寸彩色图像分类数据集（比 MNIST 难）	仿真级扩展验证（Yao2020）
精度 accuracy	测试集上分类正确的比例	各章任务结果
分类 vs 生成	判别「输入属于哪类」vs 学出数据分布并能采样出新样本	判别：MNIST 分类；生成：Niazi2024 的玻尔兹曼网络采样出手写数字（§7.2）
组合优化	在离散且巨大的解空间里找最优解；Ising 编码后「最优解 = 能量景观最低点」	MAX-CUT（把图节点分两组使跨组边权最大）、TSP（traveling salesman problem，旅行商问题）、SAT（Boolean satisfiability，布尔可满足性）
TTS	time-to-solution，求得解所需时间；专用求解器的核心指标	Nikhar2024 的标度定律（§7.2）
基准 benchmark	统一的任务集 + 统一评测口径 —— 本领域最缺的东西	§9.1
推理 vs 训练	用训练好的网络算结果 vs 调整权重本身	全篇口径标注的基础：推理能效 ≠ 训练能效

2.5 符号约定

x 输入向量；W、w_i 权重（矩阵/矩阵元）；σ 激活函数；L 损失函数；η 学习率；$s_i \in \{-1, +1\}$ Ising 自旋；J_{ij} 耦合、h_i 外场；$\beta = 1/k_{\mathrm{B}}T$ 逆温度；G_{ij} 电导；V_j、I_i 电压/电流；$\langle E \rangle$ 热力学平均。各章首次出现的新符号就地定义。

03 计算的形式体系：三种计算原语

本章回答的问题：一个物理系统要满足什么条件，才配被称为「在计算」？

答案不是「它看起来像计算机」，而是它的**物理定律与某个计算语义之间存在严格映射。**梳理全部 55 篇语料后，这种映射收敛为三种原语 —— 本章依次形式化它们（§3.1），给出「原语 × 基质」的映射表（§3.2），确立全篇通用的性能量与口径规则（§3.3）， 并把「训练」作为横贯三种原语的领域级难题先立起来（§3.4）。这一章对应 Tanaka2019 的框架章（§2）与 Rajak2022 的问题形式化（§1）： **第 4–8 节的所有工作，都是这三种原语在不同物理基质上的实例化。**

3.1 原语 P1 / P2 / P3：线性映射、能量最小化、物理采样

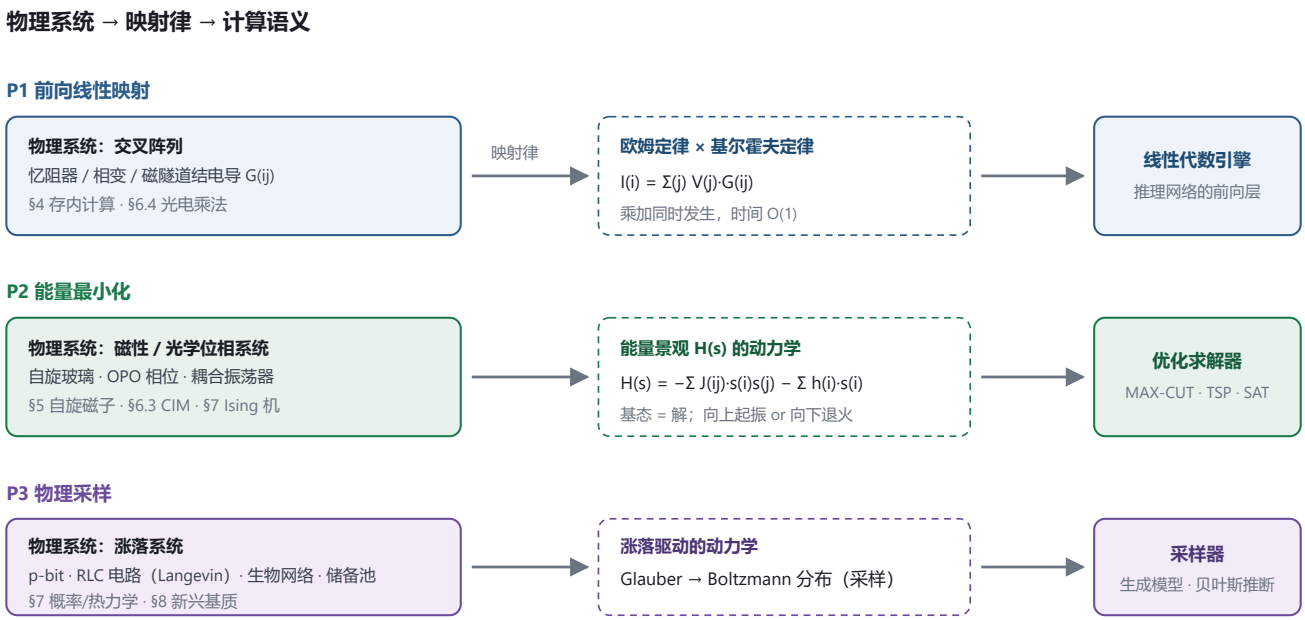


图 3.1（自绘 SVG）· 三种计算原语。每种原语 = 一类物理系统 + 一条映射律 + 一种计算语义。 P1 把物理定律变成线性代数；P2 把优化问题写进耦合、让能量景观自己搜索；P3 把热涨落当作采样器。 「储备池计算」（Tanaka2019）可视为 P1+P3 的组合：物理动力学提供非线性特征映射，读出层提供线性代数（见 §8.3）。

原语 P1：前向线性映射

问题：一个无源电路网络凭什么做矩阵乘?

把权重写成电导 G_{ij}、输入写成电压 V_j，欧姆定律给出支路电流 $I_{ij} = V_j G_{ij}$（乘法）， 基尔霍夫电流定律在列线上完成累加：

$$I_i = \sum_j V_j G_{ij}$$

这就是向量-矩阵乘（VMM），**整个乘加在物理上同时发生，时间 O(1)，与矩阵规模无关。** 级联这种层并插入非线性，就得到推理网络的前向传播 —— 第 2 节的卷积网络同样可以写成这种矩阵形式（结构化的稀疏 VMM）。

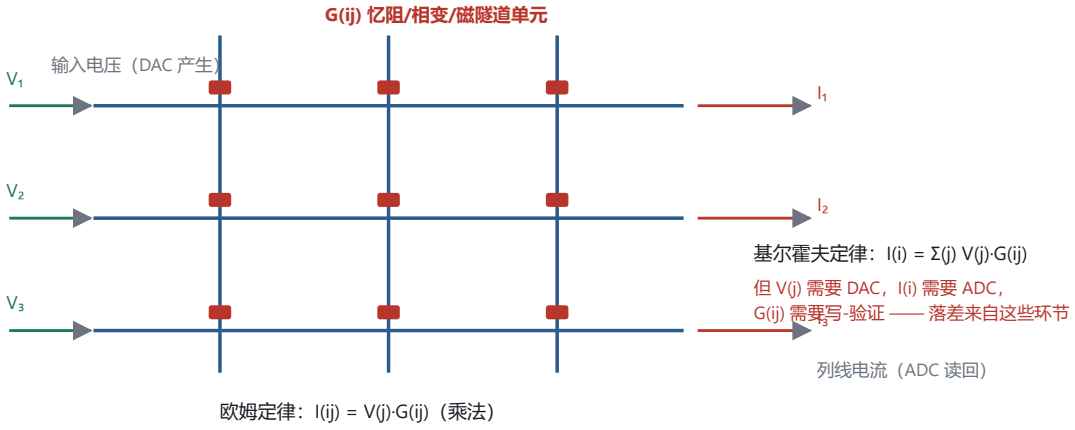


图 3.2（自绘 SVG）· 原语 P1 的物理实现与其隐藏成本。 公式里没有出现的东西 —— 产生 V 的 DAC、读回 I 的 ADC、把 G 写到位并保持的 write-verify —— 正是第 4 节「器件级 vs 系统级落差 2.9×」的来源。

原语 P2：能量最小化

问题：优化问题怎么「写进」一块材料?

把问题编码成 Ising 能量函数

$$H(s) = -\sum_{i<j} J_{ij}\, s_i s_j - \sum_i h_i\, s_i, \qquad s_i \in \{-1, +1\}$$

MAX-CUT、TSP、SAT 都有多项式规模的 Ising 编码（Rajak2022 §1 对 SAT 编码有系统展示）。剩下的事情交给物理： **基态 = 最优解**，而物理系统天然趋向低能量态。实现「搜索基态」有两条相反的物理路径： **向下退火**（降低噪声/温度，Sutton2017 的内在退火、Rajak 综述的 QA/SA —— SA（simulated annealing，模拟退火）即经典热退火算法） 与**向上搜索**（抬高泵浦增益，让系统在最低损耗的相位配置起振 —— Marandi2014 的 OPO-CIM： OPO（optical parametric oscillator，光学参量振荡器）提供二值相位自旋，CIM（coherent Ising machine，相干伊辛机）是这类系统的统称）。 耦合的可编程性是 P2 的全局难点（§10 开放问题）。

原语 P3：物理采样

问题：热噪声明明是误差源，怎么会是资源?

当计算语义是**采样**而非**求值**时，涨落恰好是引擎。p-bit（probabilistic bit，概率比特）网络按 Glauber 动力学更新：

$$m_i = \mathrm{sgn}\left[\tanh(\beta I_i) - r\right], \qquad I_i = \sum_j J_{ij} m_j + h_i, \quad r \sim U(-1, 1)$$

细致平衡保证平稳分布为 Boltzmann 分布 $P(s) \propto e^{-\beta H(s)}$ —— 网络**天然产出正确分布的样本**， 无需逐步伪随机数与逐步矩阵乘。RLC（resistor–inductor–capacitor，电阻-电感-电容）电路的 Langevin 动力学同理：$\mathrm{d}x = -\nabla U\,\mathrm{d}t + \sqrt{2T}\,\mathrm{d}W$ 的平稳分布是 Gibbs 分布（Melanson2025 的 SPU）。 采样的两大用途：Boltzmann 机的对比散度训练（Niazi2024）与贝叶斯推断 / 线性代数（Aifer2024 + Melanson2025）。

3.2 原语 × 基质：全部语料的映射表

基质章	主要原语	次要原语	代表实现
§4 存内计算	P1（电导 VMM）	P3（Sutton/Borders 的磁随机器件，见 §5.1/§7.1）	Yao2020 · Wan2022 · Ambrogio2023 · Jung2022 · Rao2023 · Zolfaghar2025 · Dai2026
§5 自旋与磁子	P2（振荡器相位 / 波干涉）+ P3（p-bit）	P1（磁 crossbar，Jung2022）	Camsari2017 · Borders2019 · Kumar2025 · Litvinenko2023/2025 · Prychynenko2018
§6 光子	P1（MZI 网格 / 光电乘法）	P2（OPO-CIM）	Shen2017 · Tait2017 · Feldmann2019 · Marandi2014 · McMahon2016 · Hamerly2019 · Pai2023
§7 概率 / 热力学	P3（Glauber / Langevin）	P2（Ising 能量面）	Sutton2017 · Chowdhury2022 · Niazi2024 · Nikhar2024 · Melanson2025 · Aifer2024
§8 新兴基质	P1+P3 组合（储备池）	P2（机械逻辑）	Mei2023 · Cai2023 · Tanaka2019（框架）

> 注意：基质章的划分与原语不正交 —— 一条路径可以实例化多种原语（自旋路径同时覆盖 P2 的波/振荡器与 P3 的 p-bit），一种原语也可以跨基质实现（P1 的 VMM 既可用电子电导也可用光电乘法）。这正说明**「原语」是机制层的抽象，「基质」是实现层的归属**，两层各自组织、互相引用 —— 这是 Tanaka2019「机制章 + 基质章」双轴组织的直接借用。

3.3 性能量与口径规则

> **问题：怎么判断「哪条路线更好」？**
>
> 先承认：**在统一基准出现之前，跨路线排名无法诚实地做出**（Albash2018 / Baltz2018 / Tanaka2019 三篇权威综述的一致立场）。 能做的诚实比较发生在同一口径内部。本综述沿用三类性能量与一条硬规则：

（i）能效：TOPS/W（tera-operations per second per watt，每瓦每秒万亿次运算）或 GOP/s/W（giga-operations per second per watt， 每瓦每秒十亿次运算），必须分层 —— 器件级 / 宏单元（tile）级 / 全芯片持续级。 最干净的自曝样板：Ambrogio2023 的 tile 峰值 20.0 → 全芯片 6.94 TOPS/W（2.9× 落差）。 **（ii）时间标度**：Ising 机类用 time-to-solution 标度定律 $\langle \mathrm{TTS} \rangle_q \approx 10^{\gamma n + \eta}$ （Nikhar2024：二阶实测 γ = 0.0206(2)；γ 主导渐近、η 主导前因子）。 **（iii）任务精度与规模**： MNIST 96.19%（Yao2020 全硬件）、元音 76.7% vs 91.7%（Shen2017）、4,264 p-bit 训练玻尔兹曼网络 90%（Niazi2024）。

> **硬规则：三种「规模」互不可比 + 数字必须标层级**
>
> 物理自由度数（Litvinenko2025 实测 50 自旋）、器件状态分辨力（Rao2023 的 2,048 电导级）、 训练数据量（Merchant2023 的 220 万结构）是三种完全不同的数 —— Litvinenko2025 自带的对比表里三者同台出现（图 5.5）， 混用是常见误读来源。本综述每个数字标注其层级；**原文未提供的口径写「未提供」，不推算不补全。**

3.4 横贯性难题：训练

> **问题：推理可以交给物理，训练呢?**
>
> 这是全领域的方法论核心难题（Momeni2025 把「物理神经网络的训练」立为领域级开放问题）：物理系统定义了一个 **通常固定或弱可调的前向映射**，而训练要求梯度 $\partial L/\partial \theta$ 穿过这个不可微分的物理过程 （反向传播的链式法则在物理器件上如何实现，见 §2.3）。语料中出现了三条回应线索，分别对应三种原语：

1. **P1 + 伴随法**：Pai2023 利用 MZI 网格的物理可逆性，让前向光与反向（伴随）光干涉、在光域测出梯度 —— 训练与推理共用同一硬件（§6.1）；

2. **P3 + 对比散度**：Niazi2024 用 p-bit 网络的 Boltzmann 采样直接完成玻尔兹曼网络的正相/负相统计（§7.2）；
3. **芯片在环**：Wan2022 的芯片在环（chip-in-the-loop）渐进微调与 Yao2020 的混合训练 —— 训练步能效显著低于推理（§4.1/§4.2）。

各基质章在对应位置展开这三条线索；§9.2 与 §10 再做横向收束。

04 基质一 · 存内计算与模拟 AI 加速器（原语 P1）

> **本章回答的问题：把欧姆定律与基尔霍夫定律直接变成矩阵-向量乘法引擎——即 §3 的原语 P1 $I_i = \sum_j V_j G_{ij}$——在真实硅硬件上究竟走到了哪一步？名义上省下的乘加能耗，从器件、宏单元到全芯片的每一级口径还各剩多少？**
>
> 本章按时间序梳理这条最接近工程化的路径：先看 VMM 原语如何第一次住进完整的卷积神经网络（CNN，convolutional neural network，卷积神经网络）（Yao2020），再长成可独立运行的整颗芯片（Wan2022）与多 tile 系统（Ambrogio2023）；随后是两条横向革新——读出端的电阻求和与时域转换（Jung2022）和器件端的数千电导级（Rao2023）；最后把感知链路前端也搬进物理域（Zolfagharinejad2025、Dai2026）。两条综述（Ielmini & Wong, 2018；Sebastian et al., 2020）早已给出该基质的理论框架，本章关注的正是理论承诺与实测口径之间的差距：tile 峰值与全芯片持续能效可以相差近 3 倍，而这就是模拟计算为「可用性」支付的价格。

4.1 卷积如何住进忆阻器阵列：Yao2020

研究动机。在 Yao2020（清华大学）之前，忆阻器存内计算只演示过两层（Li et al., 2018）与三层（Ambrogio et al., 2018）的多层感知机（MNIST 任务），更早还有单阵列的分类与稀疏编码演示（Prezioso et al., 2015；Yao et al., 2017），以及单个卷积核在阻性 crossbar 上的操作验证（Gao et al., 2016）。完整 CNN 迟迟无法全硬件化的原因有三：阵列良率与不均匀性、器件非理想特性（variation、电导漂移、state locking）使精度难以比肩软件、以及卷积滑窗是顺序过程而全连接 VMM 是并行的——两者存在严重吞吐失配（原文 p.641）。

方法：卷积 = 滑窗内积 + kernel 权重共享。系统由八个处理单元（PE，processing element，处理单元）组成，每个 PE 含一个 128×16 的 1T1R（one-transistor–one-resistor，一晶体管一电阻器）阵列，忆阻器叠层 TiN/TaO_x/HfO_x/TiN 在 130 nm CMOS（complementary metal–oxide–semiconductor，互补金属氧化物半导体）代工厂晶圆的后道工序完成，良率 99.99%（原文 p.647）。输入按量化位数编码为脉冲序列（8-bit 输入拆成 8 个时隙、按位驱动位线）；带符号权重映射为一对差分电导 $w = g^+ - g^-$。一次卷积即把 3×3 感受野展开为 9 维向量、同时驱动 9 条位线；不同 kernel 占据不同的差分行对、共享同一组输入脉冲，整列并行完成乘累加（MAC，multiply–accumulate，乘累加）——这正是 §2.1「卷积 = 滑窗内积、kernel 权重共享」的物理化身（原文 p.643）。

混合训练。纯 ex-situ 迁移会因器件缺陷与寄生效应损失精度，纯 in-situ 训练又受电导调节非线性与不对称拖累。Yao2020 的折中是：前端卷积层 ex-situ 训练后经 15 级量化、闭环写入迁移；只对末级全连接（FC，fully connected，全连接）层做 in-situ 训练。批量权更新按

$$\Delta W = \eta \sum_{i=1}^{100} V_i \, \delta_i \quad \text{（原文式(1)，p.649）}$$

计算，再经阈值学习规则筛除微小更新：

$$\Delta W_{m,n} = \begin{cases} \Delta W_{m,n}, & |\Delta W_{m,n}| \geq Th \\ 0, & |\Delta W_{m,n}| < Th \end{cases} \quad \text{（原文式(2)，p.649）}$$

其中 V_i 为注入 FC 层的 192 维列向量，δ_i 为 10 维误差行向量，阈值 $Th = 1.5\,\mu S$。**关键数字**（系统级，MNIST 全测试集 10,000 张）：软件基线 97.99% → 15 级量化 96.92% → 权重迁移后 95.07% → 混合训练 96.19%（原文 p.644）；并行卷积器配置下精度从 93.86% 恢复到 95.83%、延迟降低约 3×（原文 p.642、p.646）。能效基准给出 11,014 GOP/s/W（giga-operations per second per watt，每瓦每秒十亿次运算）与 1,164 GOP/s/mm^2，较 Tesla V100 GPU（graphics processing unit，图形处理器）分别高 110× 与 30×（原文 p.646、p.650）——但这是**计算核口径**：论文自述未含池化、激活、层间路由与缓冲等功能块，全芯片持续口径未提供。

局限。论文自述：少数「尾部单元」的电导漂移会使精度随时间退化（30 天内 15 级不重叠但精度单调受损，原文 p.648）；并行复制 kernel 需要额外的存储与数据传输模块；更高量化精度才能完全恢复精度，但代价是更多硬件资源（原文 p.646）。另一个明显的局限是测试系统靠商用 ADC 芯片与 ARM 核拼装，未针对高性能优化（原文 p.647）。

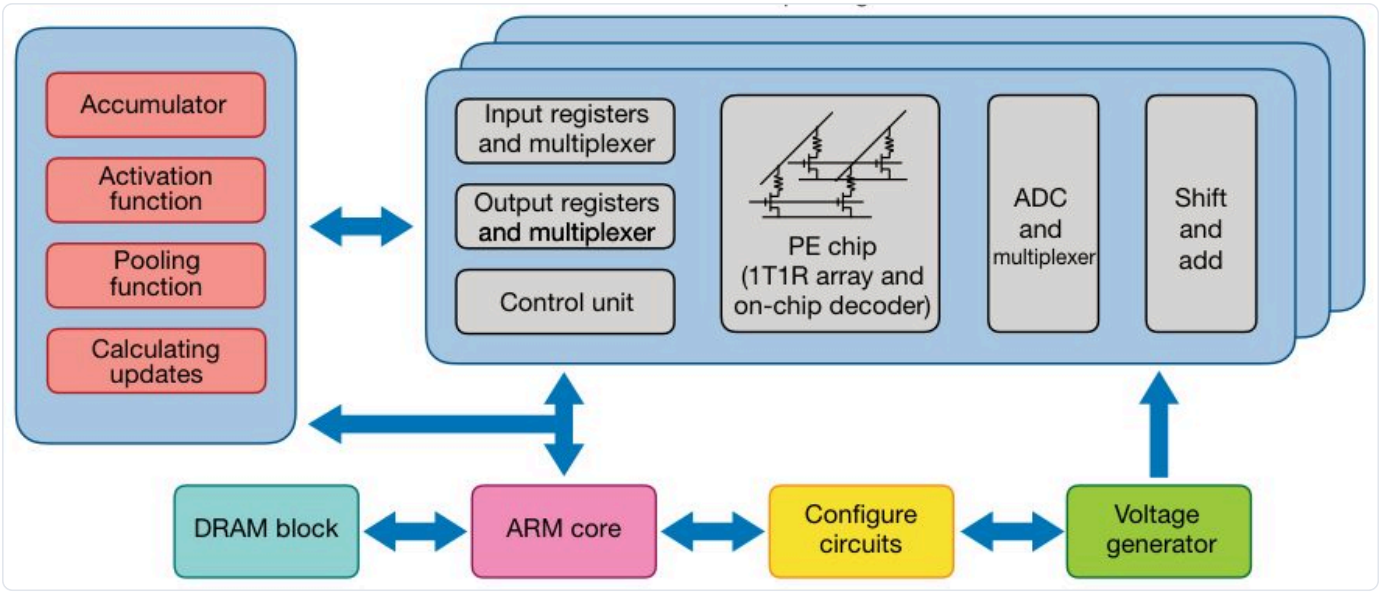


图 4.1 · 全硬件忆阻器 CNN 的系统架构。左侧共享功能块（累加器、激活函数、池化函数、更新计算），中部为可复制的 PE 芯片组——每片含 1T1R 阵列与片上译码器、输入/输出寄存器与多路选择器、控制单元、ADC 与移位累加单元；底部为 DRAM（dynamic random-access memory，动态随机存取存储器）块、ARM 核、配置电路与电压生成电路的集成关系。共享 FC 层 + 复制卷积器的结构正是该文吞吐失配解决方案的框图呈现。**图源**：Yao et al., *Nature* **577**, 641 (2020)，第 2 页图 · DOI `10.1038/s41586-020-1942-4`。

4.2 从宏单元到独立 SoC：Wan2022

研究动机与前驱链。Wan2022（斯坦福 × UCSD × 清华）开篇指出的缺口是：早期 RRAM（resistive random-access memory，阻变存储器）存内计算把模数转换与神经元激活留给片外软件、基准精度常靠器件实测数据驱动的软件仿真「高估」；2018–2021 年的一批全集成 RRAM-CIM 芯片（如 66.5、78.4 TOPS/W 的 Mochida et al., 2018 与 Liu et al., 2020）做到了单片 MVM，却没有任何工作同时交付高能效、支持多样模型的通用性与软件可比精度三者的平衡（原文 p.504）。

方法：TNSA + 电压模读出。NeuRRAM 芯片集成 48 个 CIM（compute-in-memory，存内计算）核、共 300 万个 RRAM 单元，每核中心是 256×256 的可转置神经突触阵列（TNSA，transposable neurosynaptic array）：16×16 个「核粒」中 RRAM 权重与 CMOS 神经元电路交错排布，每个神经元只接 1 条位线（BL，bit line）与 1 条源线（SL，source line），从而在不复制两端 ADC（§3 的「ADC 数量 = 列数」难题）的前提下支持前向、反向与往复三种数据流——反向数据流正是训练所需的反向传播、往复数据流正是 RBM 采样所需（原文 p.505–506）。读出端用**电压模感知**替代传统电流模：输出线电压自动稳定到输入的加权平均

$$V_j = \frac{\sum_i V_i \, G_{ij}}{\sum_i G_{ij}} \quad \text{（原文 p.514）}$$

这免去了吸收大电流的大晶体管、天然归一化各层差异巨大的输出动态范围、单周期完成整个 VMM，神经元同时充当 ADC 与激活函数，支持 1–8 bit 输入与 1–10 bit 输出（原文 p.507）。

write-verify 与器件离散性。权重以相邻两行差分电导编码，用增量脉冲 write-verify 写入：初值 1.2 V（SET）/1.5 V（RESET）、步进 0.1 V、脉宽 1 μs、验收窗口 ±1 μS，平均 8.52 个脉冲写到一个单元，单片集成后约 56 μs/cell；写入后电导弛豫的标准差约 2.8 μS（最大约 4 μS ≈ 10% g_{max}），经 3 轮迭代复写降至约 2 μS（原文 p.513）。配合噪声注入训练与「芯片在环」渐进微调，全硬件实测精度达到等效 4-bit 权重量化软件模型的水平（原文 p.510）。

关键数字（系统级，全硬件实测）。MNIST 99.0%（7 层 CNN）、CIFAR-10 85.7%（ResNet-20）、Google 语音命令 84.7%（4 单元 LSTM，long short-term memory，长短期记忆网络）、RBM 图像恢复 L2 误差较含噪输入降低 70%（原文 p.504）；能效-延迟积（EDP，energy-delay product）较先前最优 RRAM-CIM 芯片改善 1.6–2.3×、计算密度高 7–13×（宏单元口径，100% 阵列利用率的峰值，原文 p.507）。**局限**：论文自述部分算子（平均池化、逐元素乘法）仍在片外 FPGA 上；多核并行引入电源 IR 降等非线性非理想（3 核并行卷积的均方根误差 0.318→0.383，原文 p.515）；含

FPGA 与中间数据搬运的系统级能效口径未提供，训练能耗亦未提供——训练仍靠片外软件微调，且片外数字处理「终须集成进同一芯片」（原文 p.506）。

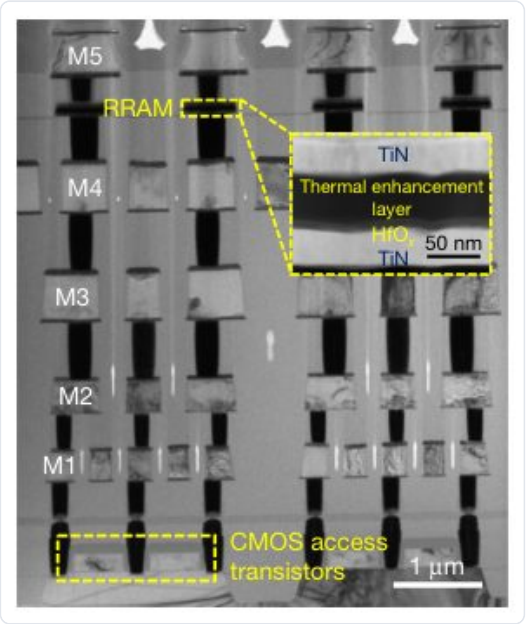


图 4.2 · 1T1R RRAM 单元的 TEM（transmission electron microscopy，透射电子显微术）截面。TiN/HfO_x/热增强层/TiN 阻变叠层集成于 CMOS 金属层 M4 与 M5 之间，黄框放大显示叠层细节（50 nm 标尺），底部为 M1 层的 CMOS 存取晶体管（1 µm 标尺）——RRAM 与标准 CMOS 代工流程单片集成的直接证据。**图源**：Wan et al., *Nature* **608**, 504 (2022)，第 3 页图 · DOI `10.1038/s41586-022-04992-8`。

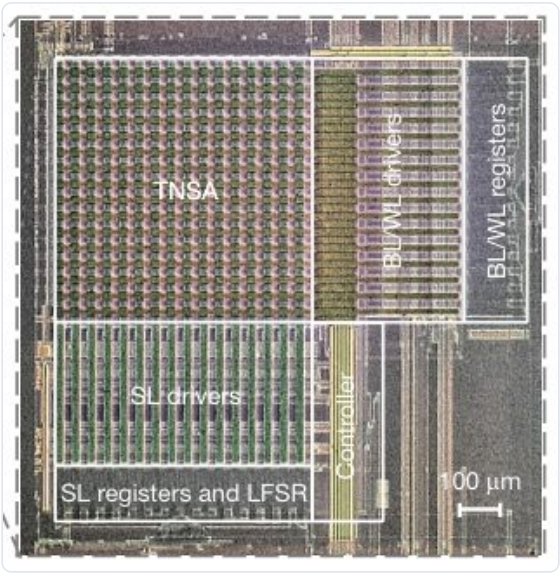


图 4.3 · CIM 核版图显微照片。TNSA 存储阵列、BL/WL（word line，字线）驱动器、BL/WL 寄存器、SL 驱动器、SL 寄存器与 LFSR（linear-feedback shift register，线性反馈移位寄存器，用于概率采样）、控制器（100 µm 标尺）——「交错阵列 + 完整数字外围」单片集成的实物证据。**图源**同图 4.2，第 3 页图。

4.3 多 tile 系统与诚实核算：Ambrogio2023

研究动机与前驱链。到 2023 年，模拟存内计算的缺口已从「单芯片能否工作」变成「多 tile 系统能否跑出商业相关精度」：此前的架构研究（Jain et al., 2023）预测模拟 AI 系统能效可达先进 GPU 的 40–140 倍，但其中两个关键假设——密集电路交换 2D mesh 互联、以及足够大且足够准的模型演示——都还没有硬件证据（原文 p.768）。此前单芯片工作包括 IBM 自己的 PCM 模拟训练（Ambrogio et al., 2018）与 14 nm 全片上 MAC（Narayanan et al., 2021）、以及 Yao2020 与 Wan2022（原文引文 3–7）。

方法：时域编码 + 斜坡式 ADC。芯片基于 14 nm CMOS，34 个模拟 tile（每个 512×2,048 PCM（phase-change memory，相变存储器）crossbar，蘑菇型单元、环形加热电极直径约 35 nm，共 3,500 万 PCM 器件）（原文 p.768、p.776）。输入以 8-bit 整数在输入着陆垫转换为脉宽调制（PWM，pulse-width modulation，脉冲宽度调制）的**时长向量**，沿 512×512 条 2D mesh 导线以纯时域形式广播到各 tile——tile 之间传时长而非数字码，等价于把 ADC 拆成三段：tile 内共享斜坡电路与列比较器、输出着陆垫只放数字计数器，这就是**斜坡式（ramp-based）ADC** 的架构化应用（原文 p.769）。权重编码为 $W = F(G^{+} - G^{-}) + g^{+} - g^{-}$（原文 p.769 图 1g 注记），可配 4-PCM/权重或更密的 2-PCM/权重，相邻 tile 还可共享电容库把模拟积分扩展到 2,048 行（原文 p.769–770）。为抵消外围电路固定不对称，非对称平衡（AB，asymmetry balance）法把 W 与 $-W$ 各编一份、正反输入各算一次（原文 p.771）。

关键数字（系统级，全芯片实测）。关键词检出（KWS，keyword spotting）：全连接网络经硬件感知（HWA，hardware-aware）重训练后端到端 86.14%，越过 MLPerf 软件等效（SWeq，software-equivalent）线 85.88%，单帧 2.4 µs、比 MLPerf 已报最快延迟快 7×（原文 p.771）。语音转写 RNNT（recurrent neural-network transducer，循环神经网络转换器）：4,500 万权重中 99.9% 映射到 5 颗芯片 142 个 tile、超过 1.4 亿 PCM 器件（平均约 2.9 PCM/权重），词错误率（WER，word error rate）9.475%（软件基线 7.452%、SWeq 限 8.378%）；经权重扩展法（乘随机矩阵及其 Moore–Penrose 伪逆提升信噪比）改善到 9.258%，一周 PCM 漂移后仅 +0.4%（原文 p.773–774）。**能效口径链**是本文历史价值所在：模拟 tile 峰值 **20.0 TOPS/W** → 最好单芯片 12.40 → 全部 5 芯片模拟积分口径 7.09 → 含估计数字处理的全系统持续 **6.94 TOPS/W**（原文 p.774）——外围电路、通信与低效的数字处理吃掉了约 2/3 的峰值能效，但即便按 6.70 TOPS/W、3.57 W 计，仍较 MLPerf 最佳提交高 14×（546.6 samples/s/W，原文 p.774）。

局限。论文自述：芯片不含片上数字核与 SRAM，joint-FC 层、全部向量-向量运算与激活（除 ReLU 外）在片外主机完成；real-time 因子 8×10^{-5} 虽满足实时约束，但数字处理部分能效低下（原文 p.774、p.776）。

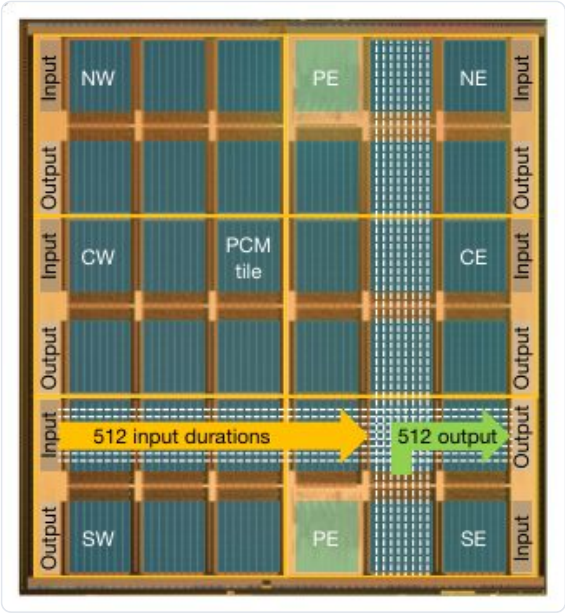


图 4.4 · 模拟 AI 芯片顶视图。六个电源域（NW/NE/CW/CE/SW/SE）围绕中央 PCM tile 与两个处理单元（PE），输入侧标出「512 input durations」箭头、输出侧为「512 output」——时域时长向量经 2D mesh 进出各 tile 的拓扑一目了然，这是它绕开高精度 ADC 的架构基础。**图源**：Ambrogio et al., *Nature* **620**, 768 (2023)，第 2 页图 · DOI `10.1038/s41586-023-06337-5`。

4.4 读出端革新：电阻求和 + 时域转换：Jung2022

研究动机与前驱链。Jung2022（三星）回答一个具体问题：**STT-MRAM（spin-transfer-torque magnetoresistive random-access memory，自旋转移矩磁阻随机存取存储器）电阻太低怎么办？**在四类可量产非易失存储器中，RRAM、PCM、闪存 crossbar 已被反复用于模拟 MAC，而 MRAM（magnetoresistive random-access memory，磁阻随机存取存储器）只有仿真研究（Patil et al., 2019；Zabihi et al., 2019）——障碍是其低电阻：本工作的 MTJ（magnetic tunnel junction，磁性隧道结）含 FET 开关在内 $R_L \approx 13\,\text{k}\Omega$、$R_H \approx 26\,\text{k}\Omega$（原文 p.212、p.217），电流求和 crossbar 会产生巨大功耗。电阻求和此前只在闪存上做过仿真（Lin et al., 2018）（原文 p.213 引文）。

方法：反着用欧姆定律。每个 bit-cell 由两条「MTJ+FET」支路并联、输入电压选通其一，输出电阻即输入×权重的二值乘积——一个**模拟 XNOR** 取代了欧姆定律的交叉点乘法；64 个 bit-cell 沿列串联，列电阻之和天然就是点积（原文 p.212）。读出端不用 ADC：列端集总电容 $C_L \approx 33$ fF 加上每单元约 2.1 fF 的分布电容，用 4-bit TDC（time-to-digital converter，时间数字转换器）测量列电压从 0 充到 V_{REF} 的**时间**——充电时间即计算结果（原文 p.213）。列电阻本可在 −64…64（6-bit）间取值，4-bit TDC 截取 −46…48，对神经网络精度影响很小（原文 p.213）。

关键数字（宏单元口径）。约 400 万次点积的平均绝对误差 0.47 bit @ 1.0 V TDC 供电（阵列+TDC 总功耗 347 μW，能效 262 TOPS/W）；TDC 供电降到 0.8 V，功耗 225 μW、误差升至 **0.83 bit**、能效 **405 TOPS/W**（原文 p.214）——「外围供电电压」这个旋钮的精度-能效交换被显式量化了。系统演示（系统级）：64×64 阵列、28 nm CMOS 外围，二层二值神经网络（BNN，binary neural network，二值神经网络）感知机跑 MNIST 全测试集 93.23±0.05%（软件基线 95.24%，输入用 8-bit thermometer 码扩展以抗噪，阵列权重复用 28 次）；基于实测误差仿真（仿真级）的 VGG-8 达 98.86%（基线 99.28%）；作为十层 VGG（Visual Geometry Group）类网络第七卷积层、四芯片并行做人脸检测，总体 93.4%（基线 95.7%）（原文 p.214–215）。

局限。论文自述：64×64 阵列远小于数字 MRAM 宏单元，行数受列电阻上累积的模拟噪声超过读出 LSB（least significant bit，最低有效位）所限；构造集成多阵列、数据转换器与数字电路的 SoC（system-on-a-chip，片上系统）是下一步挑战（原文 p.215）。1-bit 权重属性要求 8 次输入复用，是精度换带宽的直接代价。

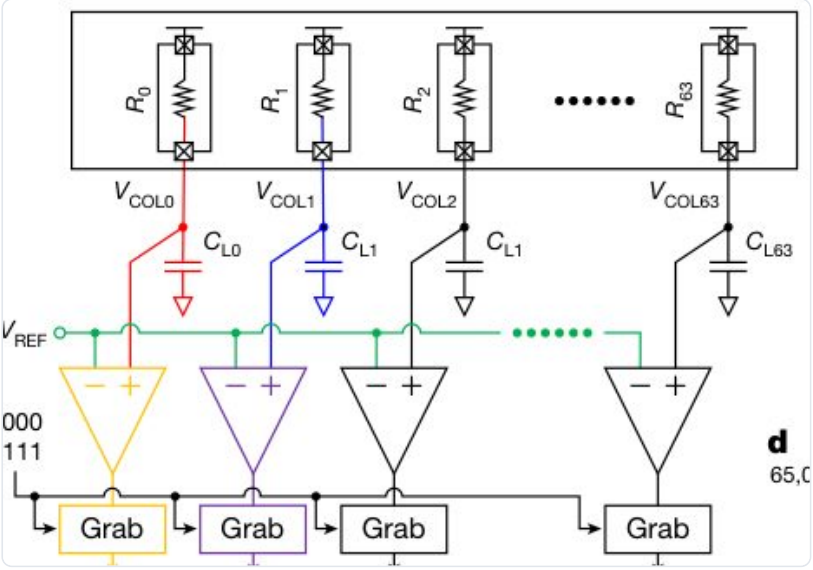


图 4.5 · 电阻求和列与 TDC 读出电路。列电阻 R_0–R_{63} 串联构成点积列，列电压 V_{COL0}–V_{COL63} 经集总电容 C_L 与参考电压 V_{REF} 送入比较器，再进入「Grab」时域转换单元输出 4-bit 码——列电容充电时间即计算结果。注意每列对应一个比较器 + TDC：这是「ADC 数量 = 列数」问题在时域的低功耗解法。**图源**：Jung et al., *Nature* **601**, 211 (2022)，第 3 页图 · DOI `10.1038/s41586-021-04196-6`。

4.5 器件端革新：数千电导级：Rao2023

研究动机与前驱链。Rao2023（TetraMem × UMass × USC × MIT）的出发点是边缘部署范式：云端训练、权重下载、边缘精确编程——这要求忆阻器具备高精度电导可编程性。但此前所有忆阻器（含实验室与产线器件）只报道过 <200 个电导级（Sun et al., 2018；Chen et al., 2020），瓶颈是每个电导态普遍存在的读出涨落（原文 p.823）。

方法：物理诊断 → 去噪协议。器件为 Pt 底电极 / HfO_2-Al_2O_3 双层 / Ti-Ta 顶电极，在商用 180 nm CMOS 产线 8 英寸晶圆上的 240 nm 通孔内完成（原文 p.824、p.828）。关键不是调参而是归因：读出涨落主要是随机电报噪声（RTN，random telegraph noise，随机电报噪声）；导电原子力显微术（C-AFM，conductive atomic force microscopy，导电原子力显微术）直接观察到每次 set/reset 都留下「不完全导电通道」（岛状或主通道模糊边缘），它们远比成熟主通道脆弱；量子输运模拟给出截面传输概率 $n(z) = \int |\psi(x,y,z)|^2 \, dx \, dy$（原文 p.827），证实库仑阻塞机制：通道附近缺陷俘获电子即可部分或完全阻断不完全通道——缺陷被判为具有长俘获/去俘获时间的氧间隙原子（原文 p.827）。据此设计**去噪协议**：用亚阈值电压脉冲驱动相场弛豫，使岛状通道湮灭或补全、相界锐化，涨落大幅下降（原文 p.825–827）。

关键数字（器件级）。单片集成芯片上单器件调到 **2,048 个电导级**（50–4,144 μS、相邻间隔 2 μS，等效 11-bit 分辨率），0.2 V 读出偏差 <1 μS；整个 256×256 阵列用片上电路演示编程（片上演示受 6-bit 片上 ADC 限制为 64 级），每个单元此前已经历逾百万次循环（原文 p.824、p.826）。去噪不需要常规读写电路之外的任何硬件，额外能耗只占编程能量的一小部分（原文 p.826）。**局限**：2,048 级依赖片外高分辨率驱动电路；网络级精度演示与能效数字未提供；论文自述多级态的长期可靠性仍需材料与器件工程进一步改进（原文 p.826）。

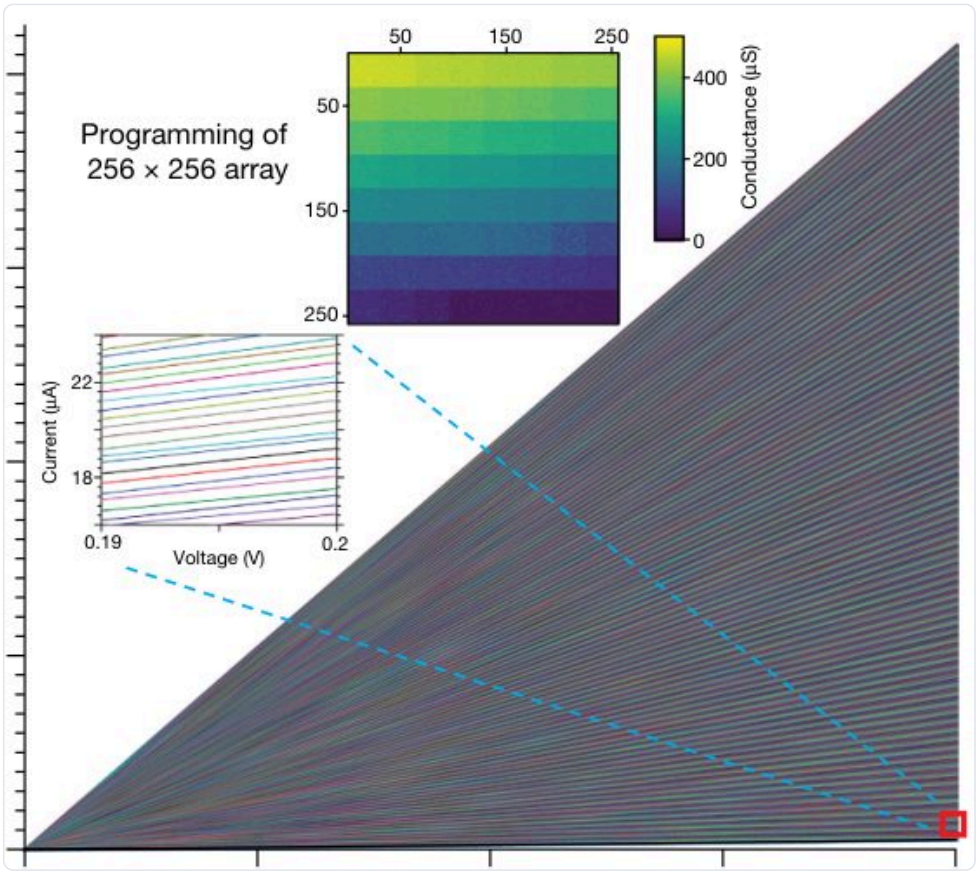


图 4.6 · 256×256 忆阻器阵列的电导编程全景。主图为全阵列 I–V 扫描的 256 条电导轨迹（从 0 到高电导近似线性铺满）；上插图为按 64 级色标把 32×32 个子块编程后的全阵列电导分布（色标 0–250 级、0–400+ μS），左插图为相邻级在 0.19–0.2 V 区间的局部 I–V 细节、各态清晰可辨——「数千电导级」主张与阵列级可编程性的直观呈现。**图源**：Rao et al., *Nature* **615**, 823 (2023)，第 2 页图 · DOI `10.1038/s41586-023-05759-5`。

4.6 把感知前端与算子也物理化：Zolfagharinejad2025 与 Dai2026

Zolfagharinejad2025（Twente × IBM Zurich）把物理域的边界从分类器推到特征提取：模拟语音识别通常要经历「麦克风→ADC→傅里叶变换」三次域转换，该文用两级链路全部消去——第一级可重构非线性处理单元（RNPU，reconfigurable nonlinear processing unit，可重构非线性处理单元，轻掺杂硅上八电极、室温工作）凭借外部电容（10–100 pF）提供的毫秒级衰减记忆与可调非线性，对原始音频做模拟时域滤波（仿耳蜗失真产物）；第二级把提取的特征送入模拟存内计算（AIMC，analogue in-memory computing）芯片（IBM HERMES 项目 PCM 芯片）上的紧凑 CNN 分类。设计逻辑是**减少 ADC 出现的次数**：模拟-数字边界被外推到系统最前端。关键数字（系统级）：TI-46-Word 96.2±0.8%（软件分类器口径 98.5%）、Google Speech Commands 89.3%（接近全软件最优 92.4%）；约 95% 的总操作在新材料系统中完成、不足 5% 下放数字处理器；RNPU 特征提取每次推理约 300 nJ、分类器约 78 μJ（原文 p.886–890）。此外 RNPU 前端把 GSC 任务的 MAC 需求从 5.02 M 压到 2.28 M（原文 p.889）。

Dai2026（UCLA 等，Nat. Commun.）则在算子层面特化：磁性畴壁（DW，domain wall，畴壁）在纳米轨道中的位移被直接映射为卷积的「移位-累加」结构。磁卷积加速器（MCA，magnetic convolutional accelerator）中，输入编码为磁畴长度 L_D、卷积系数编码为反常霍尔效应（AHE，anomalous Hall effect，反常霍尔效应）读出电极的间距 W_P，单个单元的霍尔电压为

$$V_H = \alpha I_H \frac{L_D\, L_P}{W_P} \quad \text{（原文式(1)，p.3）}$$

固定器件常数后简化为 $V_H = c_1 + c_2 W_P L_D$（原文式(2)，p.3）；N 个单元串联求和 $V_{H,\mathrm{TOTAL}} = c_1 + c_2 \sum_{n=1}^{N} W_P(n)\, L_D(n)$（原文式(3)，p.3）；每个时钟周期用自旋轨道矩（SOT，spin-orbit torque，自旋轨道矩）把畴列移过一个单元，第 k 周期的输出为

$$V_{H,\mathrm{TOTAL}}(k) = c_1 + c_2 \sum_{n=1}^{N} W_P(n)\, L_D(n-k) \quad \text{（原文式(4)，p.3）}$$

——这正是离散卷积 $W_P * L_D[k]$ 的物理实现，§2 的滑窗操作在这里变成了畴壁的逐格位移。实验演示（器件级/系统级）：4 点短时傅里叶变换（STFT，short-time Fourier transform，短时傅里叶变换，7 电极器件）、MNIST 上 CNN 推理平均 98% 精度（3×3 kernel 拆成三个 1×3 分置于三器件、池化与 FC 层片外）、Cameraman 图像边缘检测（原文 p.4–6）。对 28 nm CMOS 的基准（8-bit、1024 点卷积，实验参数+综合估算的仿真级/外推口径）：面积与吞吐大幅占优，单操作能耗因驱动畴壁的大电流暂略高于 CMOS，但综合品质因数 $\mathrm{FOM} = T/(AE)$（原文式(7)，p.7）改善 3–5 个数量级（原文 p.7）。**局限**：论文自述畴壁钉扎与相邻畴壁「同步问题」造成畴长涨落、偏离理想线性（原文 p.3）；1D 结构须把 2D 卷积拆分到多个器件；能效改进（低粗糙度体系 DW 移位能量约 27 aJ）属文献外推。

4.7 本基质的特殊问题

七篇代表作拼出的图景是：原语 P1 的硬件化已在「能跑什么」上完全达标，但在「能效账本」与「训练」上仍留着清晰的缺口——前者由外围电路主导，后者是 §2.4 训练难题在本基质的直接体现，Momeni et al.（2025）在物理神经网络训练的系统综述中同样指出：迄今没有任何训练方法在与反向传播同等的性能下扩展到大模型。Kudithipudi et al.（2025）进一步提醒，从演示级走向规模化的挑战横跨架构、算法与生态，而非单一器件指标。

存内计算：已经站稳的与还欠着的

- **站稳的**：全硬件 CNN 实测 96.19%（Yao2020）；可独立运行、四类任务全硬件实测的 48 核 SoC（Wan2022）；多 tile 系统 + 软件等效语音负载 + tile→全芯片双口径披露（20.0 → 6.94 TOPS/W，Ambrogio2023）；商用产线单器件 2,048 电导级（Rao2023）；MRAM crossbar 从仿真走向实测（Jung2022）。
- **还欠着的**：外围电路（ADC/DAC/TDC）主导能耗——Yao2020 的宏单元里 ADC 功耗是阵列的 14.4×（原文 p.650），Ambrogio2023 的外围与数字处理吃掉约 2/3 峰值能效；「精度-能效」交换尚未成为显式设计参数（Jung2022 的 0.83-bit 是罕见的正面量化）；训练能效远低于推理——Wan2022 的训练靠片外微调、Yao2020 只训 FC 层，完整片上训练在本语料中缺席；「全芯片持续口径」实测仍只有 Ambrogio2023 与 Wan2022 两篇提供；电导级数与阵列规模、片上 ADC 精度之间的联动（Rao2023 的 2,048 级依赖片外驱动）尚未打通。
- **路线分野**：器件端「高精度路线」（Rao2023，押注电导级数）与读出端「1-bit 极简路线」（Jung2022，押注并行度与低阻器件适配）短期看不到收敛；系统端「推理专用」（Ambrogio2023、Dai2026）与「通用可重构」（Wan2022）亦各行其道。

05 基质二 · 自旋电子学与磁子学（原语 P2 + P3）

> **本章回答的问题：磁化动力学能提供哪些「电学给不了」的计算资源?**
>
> 答案按物理层次分三档，外加一条拓扑支线：**器件层** —— 单个低势垒磁隧道结的热涨落直接充当随机比特，p-bit 让热噪声从敌人变成资源（P3，§5.1）；**振荡器层** —— 自旋霍尔纳米振荡器的相互同步相位连续可调，相位本身成为计算自由度（P2，§5.2）； **波层** —— 自旋波/声表面波在延迟线中做时间复用，用「换媒介」换「换规模」（P2，§5.3）；**拓扑支线** —— skyrmion 的非线性电阻 为储备池计算提供积木（RC，§5.4）。三层成熟度递减、可扩展性递增；这条路径的独特背景是**产业化底盘已经量产**—— Dieny2020 指出商用 STT-MRAM 已在嵌入式缓存中替代 eFlash/SRAM，TSMC 已在 22 nm FinFET 工艺集成嵌入式 MRAM（原文 p.446–447）—— 但「用磁性做计算」长期停留在器件与演示级；直到声表面波伊辛机出现，本基质才有了第一台给出整机口径实测指标的系统（§5.3、§5.5）。

5.1 器件层：p-bit 与可逆逻辑（原语 P3 的磁性实现）

Camsari2017（Purdue，理论框架）确立了整条随机计算路线的语法。**研究动机**：常规逻辑与存储都建立在稳定、 确定性的单元上——标准 MOS 晶体管，或势垒超过 40–60 kT 的纳米磁体；作者反其道而行，问不稳定、随机的单元能否互联成网， 既保住数字电路的精度、又获得数字电路没有的**可逆性。前驱工作链**：从论文引言的引用看，供体已经齐备 —— 低势垒磁体的时间平均磁化随自旋电流呈 S 形响应曾被 Behin-Aein 等（2016）作为硬件信念网络的构件（集成平均版）， Shim、Jaiswal 与 Roy（2017）用自旋霍尔效应诱导的随机翻转做过 Ising 型组合优化，Sutton 等（2017）提出用随机纳米磁体 本征求解旅行商问题；随机数发生器一侧有 Fukushima 等（2014）的 spin dice 与 Choi 等（2014）的 MTJ 真随机数发生器； 而方程层面，式(1)–(2) 与 Hinton 及合作者的玻尔兹曼机定义方程一致——区别只在于：这次跑在物理自旋上而不是软件里。 **方法与公式**：p-bit 的通用模型是输入电流驱动下的二元随机翻转

$$m_i(t) = \mathrm{sgn}\{\mathrm{rand}(-1, +1) + \tanh[I_i(t)]\} \quad \text{(原文式(1)，p.1)}$$

其中 $\mathrm{rand}(-1, +1)$ 是 $[-1, +1]$ 上均匀分布的随机数，每个保持时间 τ 更新一次；输入为零时输出以等概率取 ± 1， 时间平均 $\langle m_i \rangle = \tanh(I_i)$ 给出天然 S 形。互联规则即玻尔兹曼机的权重逻辑

$$I_i(t) = I_0\left[h_i(t) + \sum_j J_{ij} m_j(t)\right], \qquad E(\{m\}) = -I_0\left[\sum_{i,j} \frac{1}{2} J_{ij} m_i m_j + \sum_i h_i m_i\right], \qquad P(\{m\}) = \frac{\exp(-E)}{\sum_{i,j} \exp(-E)}, \quad \text{(原文式(2)}$$

其中 I_0 是逆向「赝温度」。真值表到对称 $[J]$ 矩阵的转换一步完成、无需学习（沿用 Hopfield 网络的投影构造）。 作者反复强调一个工程要点：构建大规模关联网络**必须用三端器件**——读/写通路分离才能提供扇出增益与隔离，两端器件不行。 在「磁体 + CMOS」具体实现中，巨自旋霍尔效应（GSHE，giant spin Hall effect）层写入圆形低势垒磁体、MTJ 与两级反相器读出， 互联用无源电阻网络完成，第 i 个 p-bit 的输入电流为

$$(I_{\mathrm{IN}})_i = \sum_j G_{ij} (V'_{\mathrm{OUT}})_j + G_i (V'_{\mathrm{BIAS}})_i, \quad \text{(原文式(9)，p.6)}$$

对照式(2)可见电导 G_{ij} ——对应耦合 J_{ij}、G_i 对应偏置 h_i——这是 Ising 哈密顿量到电阻网络的**硬件映射。** 可逆 AND 门只用到两个离散电导值，其 $[J]$ 与 $\{h\}$ 取三个整数值（$h^T = [+1, +1, -2]$） （原文式(10)，p.7）； 互连电阻取 $R_0 = 125\ \mathrm{k\Omega}$，给每个 p-bit 约 6 μA 电荷电流，对应 $I_0 \approx 3.5$（器件级参数，仿真标定）。

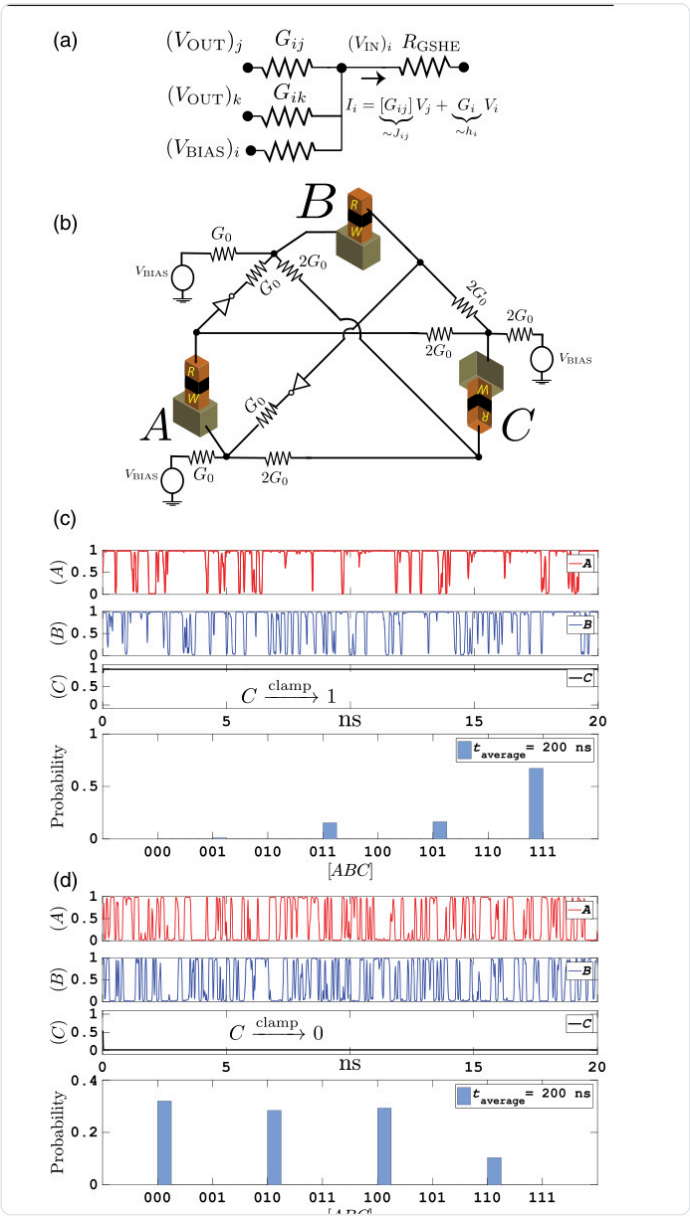


图 5.1 · p-bit 可逆 AND 门的电路映射与钳位实验。(a) 无源电阻网络：各 p-bit 输出电压 V_{OUT} 经电导 G_{ij}、G_{ik} 汇入第 i 个 p-bit 输入，图中标注 $I_i = [G_{ij}V_j + G_iV_i]$ 并注明 $G_{ij} \sim J_{ij}$、$G_i \sim h_i$；(b) 可逆 AND 门实现：三个 p-bit（A/B/C，各为 R/W 磁体叠层）经 G_0 与 $2G_0$ 电导网络及缓冲器互联，V_{BIAS} 提供偏置；(c) 输出位 C 钳位到 1 时的时间序列——A、B 大部分时间处于 (11) 态，200 ns 统计直方图中 [ABC]=111 出现约 0.7 的显著峰；(d) C 钳位到 0 时，A、B 在三个相容组合 000、010、100 之间近似等概率涨落（110 有小峰）——「分解输出 0 的三种可能输入」正是反向运算的雏形。**图源**：Camsari et al., *Phys. Rev. X* **7**, 031014 (2017)，第 6 页图 4 · DOI `10.1103/PhysRevX.7.031014`。

关键数字：本篇全部为**仿真级**——sLLG（含热噪声的随机 Landau–Lifshitz–Gilbert 方程）+ 14 nm FinFET SPICE 的 自洽模拟，参数取 $M_s = 300\ \mathrm{emu/cm^3}$、圆形磁体 15 nm/0.5 nm、$\alpha = 0.1$、$V_{DD} = 0.8$ V（原文表 I，p.7）； S 形响应由 500 ns 时间平均提取，GSHE 增益 $\beta \equiv I_s/I_c = \theta_{SH}(L_F M/t)[1 - \mathrm{sech}(t/\lambda_s)]$ （原文式(5)，p.4），热噪声尺度的热自旋电流 $I_{\mathrm{ths}} = (4q/\hbar)\alpha(kT)$ 约 0.25–2.5 μA（器件级估算，原文式(6)，p.5）。 放大到系统级：32 位加法器由 448 个 p-bit 组成，准瞬间从 $2^{33} \approx 8 \times 10^9$ 种可能中收敛到唯一正确答案—— 相互作用参数从 $I_0 = 0.25$ 猝火到 5 后，1000 次试验中 S−A−B 全部严格为零（仿真级，原文图 13，p.14）； 在 $I_0 = 1$ 下正确峰概率约 12%，靠 100 个时间样本的多数表决提取（仿真级，原文图 11，p.12）； 样本可以 GHz 速率采集（外推，原文 p.17）。可逆性的保留由部分有向连接换得：两 p-bit 模型给出第 4 个本征值 $\lambda_4 = \tanh(I_0 J_{12})\tanh(I_0 J_{21})$，全有向时 $\lambda_4 = 0$ 即迅速收敛（原文 p.15–16）； 75% 双向性下仍无错但需 $T = 50000$ 步（仿真级，原文图 15，p.15）。4 位乘法器反向运行即分解器： 输出钳 9 得 3×3，钳 6 则因子在 2 与 3 之间交叉振荡（仿真级，原文图 16，p.16）。 **局限**：无任何硬件实测（原文未提供实测数字）；电阻网络 $R_{ij} \sim 100\ \mathrm{k\Omega}$ 的可编程性与规模存疑； 串行异步更新是正确的必要条件，并行更新给出错误结果。

Borders2019（Tohoku × Purdue，首个器件验证）把这个框架做成**真实器件。 前驱工作链**：方案直接沿用 Camsari、Salahuddin 与 Datta（2017）提出的嵌入 MTJ p-bit 电路设计； 作者明确把器件钉在产业底盘上——MTJ 是 MRAM（magnetic random-access memory，磁随机存取存储器）的核心构件， 垂直各向异性 CoFeB/MgO 是「MRAM 技术的事实标准体系」，当时嵌入式 STT-MRAM（spin-transfer-torque MRAM， 自旋转移矩 MRAM）已做到 8 Mb 以上。**方法与公式**：把自由层减薄到热稳定因子 $\Delta E \approx 15\, k_B T$ （对比存储用 MTJ 的 $\Delta E > 60\, k_B T$，器件级实测，原文图 1b，p.391），Arrenhius 关系 $\tau = \tau_0 \exp[E/(k_B T)]$（$\tau_0 \approx 1$ ns）给出毫秒级保持时间——存储要求年、p-bit 只要求毫秒； 自由层厚度 t_{CoFeB} 与结直径 D 是两个调随机性的旋钮，实测保持时间覆盖 1–100 ms（器件级，原文 p.391、p.394）。 三端 p-bit = s-MTJ（stochastic MTJ，随机磁隧道结）+ NMOS 管 + 比较器 + 源极电阻，行为同二元随机神经元

$$m_i = \vartheta[\sigma(I_i) - r], \qquad I_i = -\frac{\partial E(m_1, \ldots, m_N)}{\partial m_i}, \qquad \text{(原文 p.390、p.392)}$$

S 形中心 $V_{IN} = 1.95$ V，输入偏离约 ±75 mV 即由热涨落转为确定（器件级实测，原文 p.392）。 八个 p-bit 经微控制器 + DAC 组成异步网络（最坏互连延迟 150 μs，器件级，原文 p.394），按整数分解的代价函数驱动

$$E = \left(\sum_p 2^p x_p \sum_q 2^q y_q - F \right)^2 \qquad \text{(原文式(1)，p.390)}$$

展开后含 $x_p y_q x_r y_s$ 型四体项——在 AQC 里要靠辅助比特消化，这里由非线性突触**电学直接实现**； 由此 n 个 p-bit 可编码 2^{n+2} 以内的整数（模型级，原文 p.395）。 **关键数字**：硬件实测逐级递进——4 p-bit 分解 $35 = 5 \times 7$、6 p-bit 分解 $161 = 23 \times 7$、 8 p-bit 分解 $945 = 63 \times 15$（系统级实测，原文图 3，p.393；统计窗口 15 s、每点 2000+ 采样）。 注意口径：945 是 8 p-bit 硬件实测上限；与 D-Wave 对比时同口径——后者用 12 个逻辑量子比特分解 143（原文 p.395）。与 CMOS 方案的对比（32 位 LFSR 伪随机数发生器 1194 只晶体管、每随机位约 20 fJ，对比 MTJ p-bit 约 2 fJ； 能耗优势 10 倍、面积优势 300 倍）为**仿真级**（原文 p.393、p.395）。 **退火旋钮做在物理参数里**：改变偏置电流即改变 MTJ 在 P/AP 两态间 50/50 涨落的工作点 （$I_{50/50}$ 约 5–10 μA，电压涨落 30–50 mV，器件级，原文 p.394），器件差异靠突触偏置校准； 仿真显示保持时间的器件间差异只要快于互连延迟就无害（模型级，原文 p.395）。 **局限**：突触仍由微控制器承担（非全硬件网络）； 单次统计需 15 s 量级，吞吐受数据采集限制； Grollier2020 把这类 p-circuits 概括为「在 MHz–GHz 频段以大规模并行、异步方式随机搜索困难问题的巨大相空间」的 硬件二元随机神经元网络（原文 p.364、p.366），并提醒其镜像量子线路的能力仅限无「符号问题」的子系统（原文 p.366）。

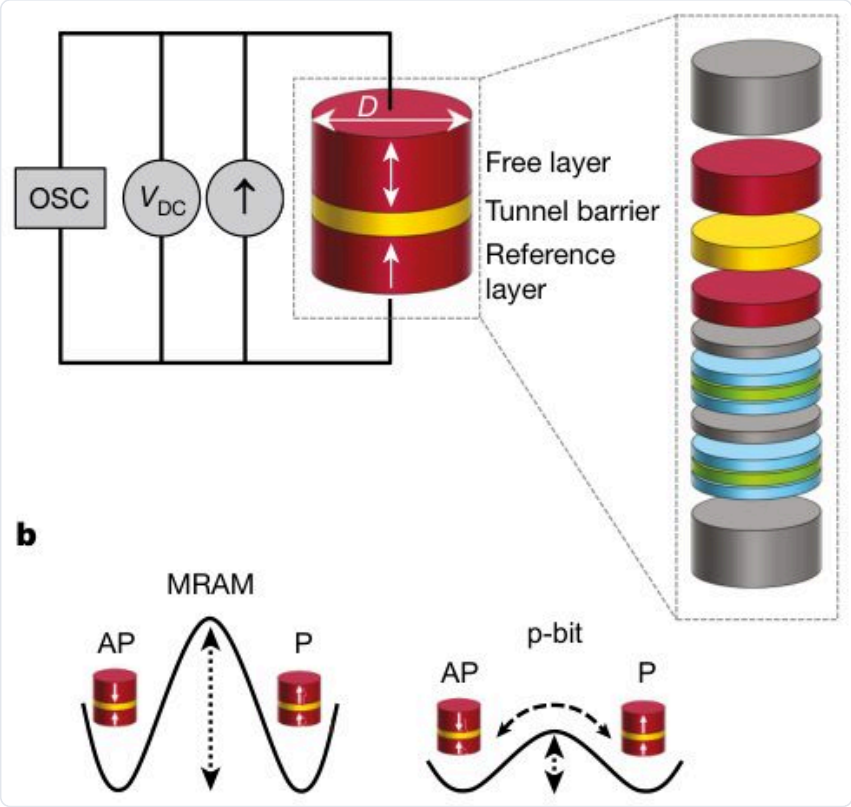


图 5.2 · s-MTJ p-bit 的器件原理。上：测量回路（OSC 示波器、V_{DC} 偏置与电流源）与 MTJ 柱（直径 D；自由层 / 隧穿势垒 / 参考层）放大后的完整多层膜叠层；下：能量景观对比——MRAM 用高势垒双势阱（$\Delta E > 60\,k_BT$，AP/P 稳定存储），p-bit 用 $\Delta E \approx 15\,k_BT$ 的浅势阱，热涨落直接驱动两态间随机翻转：「同一器件、两种用法」正是随机写入与概率计算的分野。 **图源**：Borders et al., *Nature* **573**, 390 (2019)，第 391 页图 1 · DOI `10.1038/s41586-019-1557-9`。

5.2 振荡器层：同步是计算的前提

Kumar2025（Gothenburg 系）推进振荡器路线的关键前提——**相互同步的相位可调控。 研究动机**：自旋转移矩/自旋轨道矩振荡器之间有四种同步机制（偶极耦合、直接交换、电流、传播自旋波）； 前两者随距离快速衰减，电流耦合需要高磁电阻的 MTJ 振荡器，唯有传播自旋波（PSW，propagating spin wave） 可在微米距离上与磁电阻无关地驱动同步——而「PSW 的长程同步 + 频率/幅度/相位的精确调控」正是自旋波 Ising 机 这类平台的必要条件（原文 p.245）。**前驱工作链**：纳米接触自旋矩振荡器的自旋波束同步（Houshang 等，2016）、 SHNO（spin Hall nano-oscillator，自旋霍尔纳米振荡器）阵列的长程同步（Awad 等，2017；二维阵列 Zahedinejad 等，2020； 长链 Kumar 等，2023），以及「相位二值化 SHNO 阵列走向自旋霍尔 Ising 机」的设想（Houshang 等，2022）。 **方法**：W/CoFeB/MgO 三层膜——CoFeB/MgO 界面给垂直磁各向异性（PMA，perpendicular magnetic anisotropy）、 W 层给高自旋霍尔角——做成双纳米收缩结构（宽 150 nm、间距 500 nm）。PMA 把自振荡频率抬到铁磁共振（FMR）带隙之上、 非线性转正，使振荡器辐射 PSW 而非局域模。**关键数字**：阈值电流 I_{th} 略低于 0.4 mA， 0.4 T 场下自振荡约 10 GHz，电流加倍频率增约 15%（器件级实测，原文 p.246）； 无 PMA 的 W/NiFe 对照样品 （$I_{th} \approx 1.1$ mA）只出现同相同步——证明反相同步确由 PSW 引起。 电学测量按电流划分出四个区间：I 未同步；II（0.55–0.68 mA）高功率同相锁定；III（0.68–0.76 mA） 微波信号近消失——相分辨微聚焦布里渊光散射（μ-BLS，micro-focused Brillouin light scattering）排除了振荡猝死， 判定为反相锁定；IV 重新同相。两振荡器的相对相位被直接测出：0.55 mA 处 $\Delta\varphi = 17° \pm 3°$、 0.70 mA 处 $100° \pm 5°$、0.75 mA 处 $51° \pm 5°$，且随电流连续变化、峰值达 106°（间距 500 nm） 与 153°（700 nm）（器件级实测，原文图 3、5，p.248–249）； 窄桥结构下同步距离可达 2 μm（器件级，原文 p.249）。 **机制与公式**：定性可用垂直磁化薄膜的自旋波色散描述（原文无编号，p.250）

$$f = f_{FMR} + \frac{\gamma}{2\pi} D k^2, \qquad D \simeq 2A_{ex}/M_s,$$

电流增大 → 幅度增大 → 正非线性推高频率 → PSW 波长变短（$\lambda_{II} = 304$ nm → $\lambda_{III} = 228$ nm）， 而固定间距上要维持波纹同相，只能改变两个自振荡的相对相位——相位的连续可调是波长随电流变化的直接后果。 **意义与局限**：相位可调意

味着相位可作计算自由度；微磁仿真进一步给出电压控磁各向异性（VCMA， voltage-controlled magnetic anisotropy）栅方案——±4 V 即可把耦合相位切到零、翻转耦合符号， 作者明确指出这足以把 MAX-CUT 问题映射到 SHNO Ising 机上（**仿真级**，原文 p.250）。 但成对电压栅只在模拟中存在、实验里相位仍由全局电流与磁场调控；两振荡器的演示距离阵列尚远； 振荡器的能耗、良率原文未提供。材料层面的下一个台阶已被 Baltz2018 预告：反铁磁振荡器 「对磁场扰动稳健、不产生杂散场、动力学超快」（原文 p.1），可望把该层推向 THz 并消除阵列串扰。

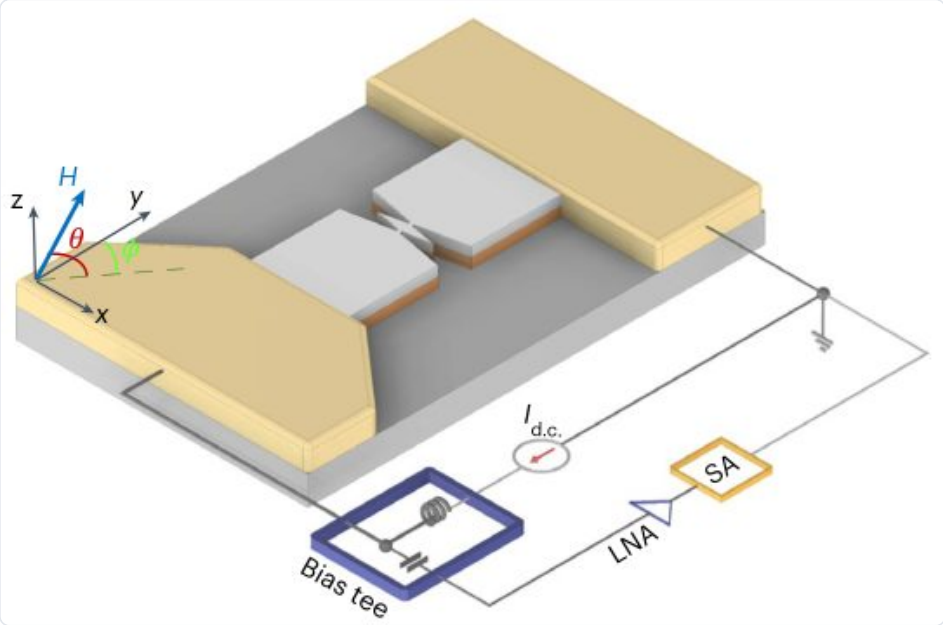


图 5.3 · 双纳米收缩 SHNO 的测量 setup。芯片上两个纳米收缩振荡器共享一条菱形桥； 外加磁场 $\vec{H}$ 的方向由 z-x-y 坐标系中的面外角 θ 与面内角 φ 定义； 直流偏置电流 $I_{d.c.}$ 经 bias tee 注入器件，微波自振荡信号经低噪放（LNA）送入频谱分析仪（SA）—— 同步与否及其区间结构（图 1d 的功率谱密度-电流图）正是从这条电学链路读出的。 **图源**：Kumar et al., *Nature Physics* **21**, 245 (2025)，第 246 页图 1 · DOI `10.1038/s41567-024-02728-1` 。

5.3 波层：自旋波 Ising 机与「换媒介换规模」

Litvinenko2023（Gothenburg，SWIM）把光学相干伊辛机（CIM，coherent Ising machine）的时间复用架构 搬进微波域。**研究动机**：光学 CIM 支持的自旋数最多（4 → 100,000 连续增长）、全连接，但需要光学平台、 千瓦级功耗与公里级光纤，「从原理演示到小型商用器件之间被物理尺寸堵死」；而自旋波群速度比光慢 5–7 个数量级， 波导可以毫米化，微波元件廉价低耗（原文 p.1–2）。**前驱工作链**：时间复用 CIM 的三个台阶—— Marandi 等（2014）的时间复用参量振荡器网络、Inagaki 等（2016）的 2000 节点机、McMahon 等（2016）的全可编程 100 自旋机及 Honjo 等（2021）的 100,000 自旋机；候选物理构件清单里自旋电子器件、忆阻器十字阵列、 超导结、弛豫振荡器、CMOS/FPGA 并列（原文 p.2）。**方法与公式**：自旋波伊辛机（SWIM，spinwave Ising machine） 用 10 mm 长、5 μm 厚的 YIG（yttrium iron garnet，钇铁石榴石）薄膜（生长在 GGG（gadolinium gallium garnet， 钆镓石榴石）衬底上）作延迟线，每个「自旋」是一段自旋波 RF 脉冲的相位（0 相 = −1，π 相 = +1）， 最大自旋数由时间复用决定 $N = \tau_{delay}/\tau_p$（原文 p.3）；色散由磁化方向与材料参数决定 $\omega_0 = \gamma\mu_0\sqrt{(H_{int} + M_s l_{ex}^2 k^2)(H_{int} + M_s l_{ex}^2 k^2 + M_s F_0)}$ （原文式(2)(3)，p.2）；相敏放大器（PSA，phase-sensitive amplifier）把环内脉冲相位二值化到 0 或 π （相对倍频泵浦参考 6.25 GHz），整机目标仍是最小化 Ising 哈密顿量

$$H(s_1, \ldots, s_N) = -\sum_{i<j} J_{ij} s_i s_j - \sum_{i=1}^{N} h_i s_i. \quad \text{(原文式(1)，p.2)}$$

关键数字：实测——载频 3.125 GHz、带宽 $\Delta f = 60$ MHz、群延迟 $\tau_{delay} = 271$ ns （偏差 30.2 ns），色散致脉冲展宽把最窄脉宽限到 34 ns，故满配 10 个自旋、实验用 8 个（器件级实测，原文 p.3）； 4 自旋 MAX-CUT 从非最优态 $\{+1, -1, -1, -1\}$（2 cuts）经 3.8 μs（14 圈环流）收敛到最优 $\{+1, -1, +1, -1\}$（4 cuts）； 8 自旋问题 14 圈内给出正确解；摘要口径：8 自旋 MAX-CUT 4 μs 内、7 μJ （系统级实测，原文 p.1）； time-to-solution 约 5 μs 且在 0–12 dB 耦合衰减下几乎不变，动态范围 15 dB （系统级实测，原文 p.4–5）。**耦合的物理来源是 PSA 的增益竞争**：1:10 耦合

器分出部分信号， 经 68 ns（4 自旋）或 34 ns（8 自旋）延迟电缆注入相邻脉冲，−8 dB 耦合比对应 $J_{ij}=1$（1 bit 分辨率）， 180° 移相器实现负耦合（器件级，原文 p.4）； 传播损耗由式 $\tau_{life}^{-1}=(2\pi f\alpha+\gamma\mu_0\Delta H_0)/2$ 约束（原文式(5)，p.6）。两条退火通道：向环内注入随机相位信号、或按最小增益原理缓升环路增益（原文 p.5）。 **局限与设计目标**：延迟电缆是**固定**耦合——可编程性缺失、分辨率 1 bit、非对称耦合仅为演示便利； 设计目标为投影级：20 nm YIG 薄膜（$v\approx 600$ m/s、$\tau_{life}=550$ ns）下 2.278 mm 延迟线容 759 自旋， 150 条并行波导（总体 2.66×1.5 mm）达 113,850 自旋——与 5 km 光纤 CIM 同量级（投影级，原文 p.6–7）。

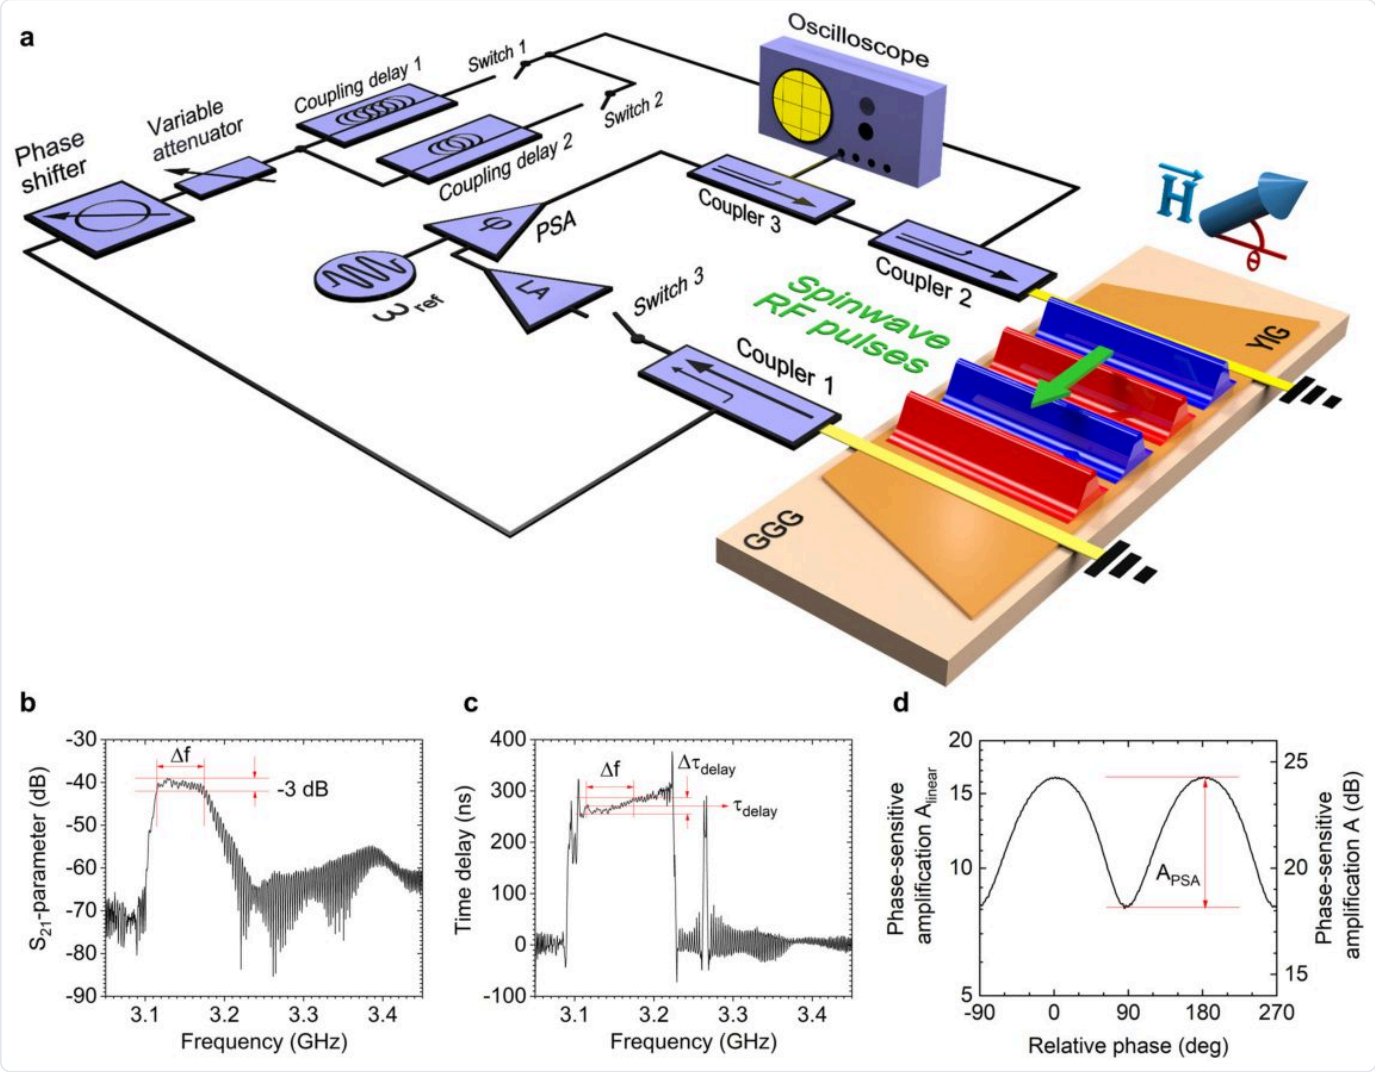


图 5.4 · 自旋波 Ising 机的实验 setup 全景。(a) 微波链路：移相器与可变衰减器串入主环； 顶部为耦合支路——耦合延迟 1/2（配开关 1/2）决定「哪个脉冲与哪个脉冲耦合」； PSA（φ）与线性放大器（LA） 在参考信号 ω_{ref} 驱动下分别负责相位二值化与损耗补偿；开关 3 把放大后的信号切成 RF 脉冲， 经耦合器 1 注入 YIG/GGG 自旋波波导（红/蓝梯度为自旋波 RF 脉冲，$\vec{H}$ 为外加磁场）， 耦合器 2/3 引出信号至示波器实时观测所有自旋；(b) YIG 延迟线的 S_{21} 频响与 −3 dB 带宽 Δf； (c) 频率依赖的时延 τ_{delay} 及其偏差 $\Delta\tau_{delay}$；(d) PSA 增益对相对相位的周期性响应 （$A_{PSA}=6.1$ dB）——脉冲相位被锁到 0/π、耦合得以生效的物理来源。 **图源**：Litvinenko et al., *Communications Physics* **6**, 227 (2023)，第 3 页图 1 · DOI `10.1038/s42005-023-01348-0`。

Litvinenko2025（SAWIM）： 换媒介、换规模。研究动机：SWIM 的自旋数上限卡在自旋波色散的 非线性——带宽内时延不均导致脉冲展宽；此外 YIG 在室温下的退磁温度系数大、热稳定性差（原文 p.1–2）。 方法是把传播媒介换成声表面波（SAW，surface acoustic wave）： SAW 色散天然线性、无展宽， 铌酸锂延迟线的时延温度系数比 YIG 低两个数量级以上。**方法**：50 mm 长 SAW 延迟线（时延 12 μs、 偏差仅 45 ns、带宽 100 MHz），银叉指换能器（IDT，interdigital transducer）作电声换能， PSA 相位二值化，外加一块基于 FPGA（field-programmable gate array，现场可编程门阵列）的测量-反馈模块 （AD8302 鉴相器 + 8 位 ADC + Spartan-6，矩阵乘法一个时钟周期内完成）——耦合脉冲按

$$c_i=-r\sum_{j=1}^{N}J_{ij}s_j \qquad \text{（原文式(4)，p.3）}$$

实时注入，$\sum_j J_{ij}s_j$ 的硬件化正是光学 CIM 在 McMahon2016 阶段迈出的「测量-反馈」步； 58 个循环脉冲中 50 个作全连接伊辛自旋、8 个用于反馈通路延迟（器件级实测，原文 p.2）。 环内脉冲幅度从噪声中生长的过程天然构成退火调度：小幅度时信噪比低、等效温度高、耦合相对强， 幅度饱和后自旋冻结进极小值（原文 p.4）。**关键数字（系统级实测）**： 随机 50 自旋 MAX-CUT， 单次运行 10 ms（受数据采集协议限制，原则上可压到 624 μs——投影级）； 矩阵 A（密度 0.2457）最优解概率 34% （$H = -218$）、矩阵 B（密度 0.2139）85%（$H = -228$）； Möbius 梯图基态概率从 N=12 起衰减， 28–50 自旋段略优于 100 自旋 CIM；BiqMac 基准 170 个矩阵中仅 2 个未达全局最优、且差仅 2%； 精确解概率 1.2–9%，99% 精度解在最优耦合（相对衰减 −6 dB）下达 84%，$TTS_{99} = 25$ ms （密度 0.5 组从 597 ms 改善到 25 ms）； 整机功耗 1.82 W、每解能量 18.2 mJ、能效 55 solutions·s^{-1}·W^{-1} （原文 p.1、p.4–6）。热稳定性比 CIM 好 4–5 个数量级——相位累计温度系数仅 102.5 °C^{-1} 对 CIM 的 1.7274×10^{7} °C^{-1}（相差 1.6854×10^{5} 倍），故无需恒温器与锁相环（器件级测量 + 推导，原文 p.3）。 耦合强度存在最优值：数值玩具模型遵循时延振荡器方程 $\dot{a}_j + (i\omega_0 + \Gamma_0)a_j - K(1-\beta_r\delta_{p_{j,\tau}})\exp(-i\beta_i\delta_{p_{j,\tau}})a_j(t-\tau) = \xi(t)$ （原文式(5)，p.6），实验上 −11 dB 衰减时矩阵 B 解 100% 最优、过强则陷入局域极小（仿真 + 实测互证，原文 p.6）。 **规模化口径**：原型 50 自旋是实测；100 MHz 低频长延迟（1–10 ms）可趋近 $10^4 - 10^5$ 自旋、 GHz 频段（4–6 GHz、2–3 ns 脉冲）配 μs 时延也可达数千自旋、以文献实测的 85 MHz 延迟线为例 15,419 自旋/条、7 条串联逾 100,000 等效自旋——全部为**投影级**（原文 p.7）。 **局限**：单环容量受 PSA 每脉冲 10–20 载波周期与鉴相器 50–70 ns 响应限制；耦合脉冲幅度须钳在饱和幅度 2–30% 区间，更高分辨率问题的映射协议未建立；FPGA 矩阵乘法的 $O(N^2)$ 功耗将在 $10^4 - 10^5$ 自旋时成为主导。

		Spatial / Physical arrays			Time-multiplexed				
	Noisy mean-field GPU [63]	D-wave 2000Q [13,62]	Mem-HNN [12]	PTNO [14]	CIM 2000 [21]	CIM 100,000 [20]	OE CIM [29]	Large-scale OE CIM [28]	SAWIM
Clock frequency	1.582 GHz	-	500 MHz	100 kHz [a]	1 GHz	5 GHz	1 Hz	250 MHz	4.8 MHz
Number of Ising spins solved experimentally (simulated/projected [b])	100	55	60 (100)	8(100)	2000	100000 (-/2000000 [c])	100 (100/-)	25600	50 (50/ 1000000)
Connectivity	All-to-all	Chimera	All-to-all	All-to-all	All-to-all	All-to-all	All-to-all	Fractional neighbours/ All-to-all [d]	All-to-all
Annealing time T_{ann}	12.3 μs	1 ms	600 ns	3.7 ms	5 ms (5 us)	24.7 ms	1 s [e]	20 μs	500 μs [f]
Time-to-solution	10 μs	10^4 s	6.6 μs	3.7 ms / 30 μs [g]	70 μs	593 μs	20 s	22.4 μs	10 ms (624 μs)/ 24.9 ms (1.55 ms)[o]
Power consumption	< 250 W	25 kW	10.9 mW [h]	2.56 mW [i]	< 100 W	7 kW	< 10 W	< 10 W	1.82 W
Physical size (chip/system)	10 cm^2 / 10^3 cm^3	10 cm^2 / 10^7 cm^3	2000 μm^2 / -	100 mm^2 / 10^3 cm^3	- / 10^6 cm^3	- / 10^6 cm^3	- / 10^5 cm^3	- / 10^5 cm^3	500 mm^2 / 10^4 cm^3
Energy-to-solution	< 2.5 mJ	250 MJ	72 nJ [h]	76.8 nJ [i]	< 7 mJ	4.15 J	200 J	0.224 mJ	18.2 mJ (1.1 mJ)
Energy-to-solution per spin	< 25 μJ	4.5 MJ	1.2 nJ	9.6 nJ	< 3.5 μJ	< 4.15 μJ	1 J	8.8 nJ	364 μJ (22.7 μJ)
Energy efficiency (solution/s/W)	> 400	4 x 10^{-9}	1.4 x 10^7	1.3 x 10^7	> 143	0.24	5 x 10^{-3}	4.46 x 10^3	55 (881)
Energy efficiency per spin (solution/s/W/spin)	> 4 x 10^4	2 x 10^{-7}	8.4 x 10^8	1.1 x 10^8	> 2.9 x 10^5	2.4 x 10^4	0.5	1.14 x 10^8	1.1 (17.6)
Cryogenic cooling/Thermostat	No / No	Yes / Yes	No / No	No / No	No / No	No / Yes	No / Yes	No / No	No / No
System stability [j]	-	76 μs	-	-	~ 60 s	~ 362 ms	> 12 h	> 12 h	> 1 h
Scaling of success probability for *N*×*N* problems	e^{-N}	e^{-N^2}	e^{-N} [k]	e^{-N} [l]	e^{-N}	e^{-N}	e^{-N}	e^{-N}	e^{-N}

图 5.5 · 原文自带的跨技术对比表。列为九种系统：含噪平均场 GPU、D-Wave 2000Q、Mem-HNN、PTNO、 CIM 2000、CIM 100,000、OE-CIM、大规模 OE-CIM 与 SAWIM（末列，绿/黄/红底色分别标记有利/中等/不利）； 行为时钟频率、实测自旋数（实测/仿真/投影）、连接性、退火时间、time-to-solution、功耗、物理尺寸、 energy-to-solution（含每自旋口径）、能效（含每自旋口径）、低温/恒温需求、系统稳定性、成功概率标度等十余项。 SAWIM 列：自旋数「50 (50/1,000,000)」、TTS「10 ms (624 μs)/24.9 ms (1.55 ms)」、功耗 1.82 W、能效 55 (881) solutions/s/W。 **引用提醒**：表中混合了实测、仿真与投影三种口径——如 PTNO 列的退火时间 30 μs 为仿真值（脚注 g：实验仅达 3.795 ms）、 Mem-HNN 与 PTNO 的功耗/能效为模拟值（脚注 h、i）、CIM 100,000 的自旋数「−/2000000」为投影口径； 横向读表必须对照原文脚注，不能把投影当作实测。 **图源**：Litvinenko et al., *Communications Physics* **8**, 58 (2025)，第 8 页图 7 · DOI `10.1038/s42005-025-01969-7` 。

5.4 拓扑结构作为计算积木

Prychynenko2018（Mainz + Intel）换一条赛道：不取最小能量，而取**非线性映射**——把 skyrmion 当作储备池计算（RC）的非线性阻性元件。**研究动机**：储备池网络的要素是「随机互联的非线性阻性元件」， 当时用忆阻器织物与原子开关网络实现；作者问磁性拓扑能否以更小的尺寸、更低的功耗、更多的内禀自由度替代 （原文 p.1–2）。**方法与公式**：铁磁纳米带中嵌一个 DMI（Dzyaloshinskii–Moriya interaction）稳定的 skyrmion， 两端触点加电压；电阻由各向异性磁电阻（AMR，anisotropic magnetoresistance）决定

$$\rho_{tot} = \rho_{\perp} + (\rho_{\parallel} - \rho_{\perp})\cos^2\theta, \qquad \text{(原文式(3)，p.4)}$$

θ 为电流与局域磁化方向的夹角——于是电阻成为 skyrmion 类型、尺寸、形状与位置的函数。 LLG 方程含自旋转移矩项、电流分布由 AMR 电导率张量 $j[U,m] = -\sigma[m]\cdot E[U]$ 自洽求解（原文式(1)(2)，p.3）。**结果分两支**：未钉扎的 skyrmion 被电流驱动移向触点，电阻随位置非线性变化 （Néel 型过触点呈双峰、Bloch 型单峰；裸电阻 $R_0 \approx 348\ \Omega$ / 351 Ω）——「电阻-时间」序列经恒流源即转成 电压尖峰，供液体态机（LSM）使用；钉扎在中心（钉扎半径 1.5 nm、$K_p = 3\times10^6$ J/m³）的 skyrmion 在退钉扎阈值以下（$U_1 = 2.5\times10^{-2}$ V 到 $U_2 = 3.0\times10^{-2}$ V）只发生形变， 形变改电阻，给出微分电导 $dI/dU = G[U,m] = R^{-1}[U,m]$ 的非线性 I–V 特性 （原文式(5)，p.6）——这正回声态机（ESM）所需的静态非线性元件；阈值处形变—退钉扎的突变与位置历史 赋予器件记忆行为（仿真级，原文图 5、6，p.7）。**关键数字**：全部来自 1 nm 网格微磁模拟（零温）； 实验锚点是他组的间接证据——MnSi 纳米线中单个 skyrmion 产生/湮灭引起的量子化电阻跳变可测到 0.1% 以下 （原文 p.7–8）。**外推**：skyrmion 织物对原子开关网络的功耗优势约两个数量级（约 1 μW 对 100 μW）、 百万单元储备池约 10×10 μm（原文 p.9）。**局限**：AMR 读出信号小（模拟中 AMR 比取理想值 1）、 无实物器件、室温效应未实测（作者论证热涨落各向同性、预期可平均掉）。

EverschorSitte2024（Nat. Rev. Phys. 前瞻）把这条支线放进更大的框架：物理储备池的四个必要属性—— 非线性、复杂性、短时（衰退）记忆、可复现性（原文 p.456）； 磁性系统的天然优势是「复杂、非线性的动力学响应 + Gilbert 阻尼等耗散带来的衰退记忆」（原文 p.457），并把磁性拓扑（skyrmion 等）与铁电拓扑（畴壁）统一进 「拓扑结构储备池」。该文同时给出共同瓶颈的清醒判断：概念验证多用难与 CMOS 集成的模型体系， CMOS 兼容体系里测到的效应又太小；磁系 AMR 读出在室温下通常很小（原文 p.459）。 Grollier2020 对 Prychynenko 方案的转述也强调了同一画面——电压图案从随机分布的触点注入、 各触点间电阻作为输出，「像河床中水流与石块互相重塑」（原文 p.366）。

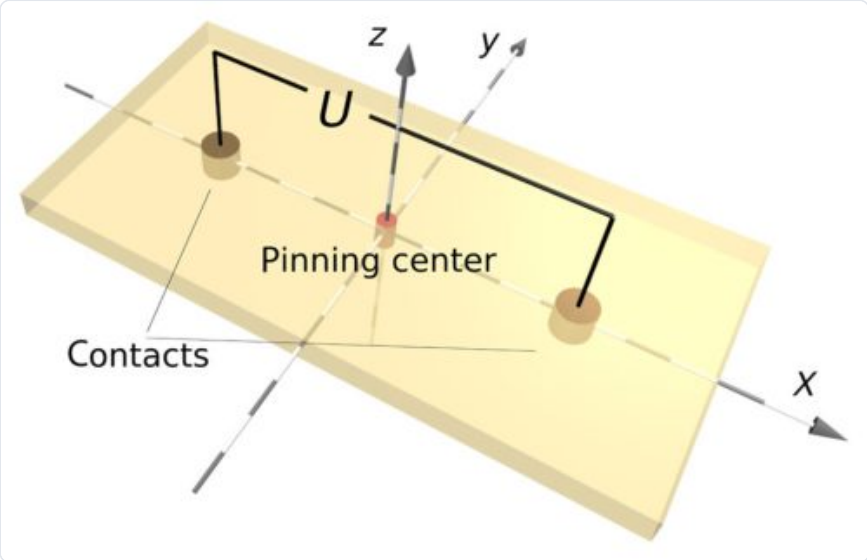


图 5.6 · skyrmion 非线性阻性元件的器件示意。铁磁薄膜带（x-y 平面）两端圆柱触点间施加电压 U， 薄膜中央的红色小区域为钉扎中心（形成势阱）； skyrmion 在钉扎与自旋转移矩的竞争下形变或进出势阱， 通过 AMR 效应改变器件电阻——「非线性 + 记忆」的储备池积木。 **图源**：Prychynenko et al., *Phys. Rev. Applied* **9**, 014034 (2018)，第 3 页图 1 · DOI `10.1103/PhysRevApplied.9.014034` 。

5.5 本基质的特殊问题

自旋与磁子：已经站稳的与还欠着的

- **站稳的**：p-bit 的理论语法与首个器件验证（Camsari2017 全仿真框架 / Borders2019 的 s-MTJ 硬件分解 945）；SHNO 相互同步且相位连续可调（Kumar2025）；波层 Ising 机 8 → 50 自旋的换媒介推进（Litvinenko 系列）—— 且 SAWIM 已是本基质第一台给出**整机口径实测**的系统（1.82 W、55 solutions·s^{-1}·W^{-1}、$TTS_{99} = 25$ ms，均为系统级实测）。
- **还欠着的**：s-MTJ 大规模阵列未兑现（Borders2019 只到 8 p-bit，投影 10^6 p-bit 停留在论述）； p-bit 演示中的突触仍由微控制器/DAC 承担，全硬件耦合网络缺位；SHNO 阵列的成对电压栅（耦合符号翻转、 映射 MAX-CUT 的关键）只有仿真；拓扑支线（skyrmion 储备池）没有任何实物器件；波层 2023 版的固定延迟线 （对应光学 CIM 的 Marandi2014 阶段）到 2025 版虽已补上 FPGA 测量-反馈（对应 McMahon2016 时刻）， 但耦合脉冲幅度被钳在 2–30% 饱和幅度内、高分辨率耦合矩阵的映射协议未建立。
- **口径纪律**：本基质文件自带多级数字，引用时必须分层——硬件实测（8 p-bit / 945；50 自旋 / 84%）、 设计目标（SWIM 的 759 自旋）、投影（113,850；100,000+）不可混写；Litvinenko2025 图 7 的跨技术表 （图 5.5）即混合口径的现成反例。
- **近期出口**：储备池化与采样——拓扑与波的非线性 + 记忆正好匹配「只训练读出」的 RC 范式， 对器件一致性的容忍度显著高于 Ising 机；SAWIM 的幅度生长即等效温度下降，作者也指出控制信噪比 可望实现超快统计采样，衔接 §3 的原语 P3。

06 基质三 · 光子计算与光子神经形态（原语 P1 + P2）

> **本章回答的问题：光子之间不相互作用，「用光算」的优势到底从哪来、边界在哪？**
>
> McMahon2023 对此做过系统审计，结论有两层。第一层是否定性的：**「光速快」是误导性论据**——他将其称为「一个整洁、貌似合理但错误的解释」（原文 p.719）：硅光波导中光速约 0.4c，PCB 走线约 0.43c，CMOS 电路中的信号约 0.2c，与真空光速仅差约 5 倍（原文 p.726）。第二层是建设性的：真正的杠杆是**带宽、空间并行、近乎无耗散的传播**三者的组合——光子学带宽约 500 THz，电子计算系统约 5 GHz，相差约 10^5 倍（原文 p.719）。他还给出量化门槛：MZI 阵列需从当前 64×64 商用原型扩到 1,000×1,000（才与单个最先进电子芯片的并行度相当）、乃至 $10^4\times10^4$ 量级（才可能在 ~1 GHz 时钟下形成实质吞吐优势）（原文 p.731），即 $N \gtrsim 10^4$ 才可能越过 I/O 开销。本章按四种实现风格梳理文献：相干 MZI 网格（§6.1）→ 广播-加权与全光脉冲网络（§6.2）→ 相干伊辛机（原语 P2，§6.3）→ 光电乘法与物理极限（§6.4）；最后以本基质特殊问题收束（§6.5）。四种风格恰好对应了「线性 optics + 电子非线性」「波长域并行」「能量最小化」「探测物理即乘法」四条不同的物理路径。

6.1 相干 MZI 网格：Shen2017 与 Pai2023

Shen2017（MIT）的研究动机是：神经网络前向传播的主体是固定矩阵乘法，而线性变换可以「以光速完成」、探测速率可超 100 GHz，且网络训练完成后光学架构原则上是无源的（原文 p.441–442）。其前驱工作链是：Farhat 等（1985）最早做过 Hopfield 模型的光学实现，但自由空间/分立元件方案受相位稳定性与大神经元数制约（原文 p.441–442 引 ref.22）；Reck 等（1994）证明任意离散酉算符可由分束器与相移器级联实现（原文引 ref.27）；Miller（2015）论证「不完美器件的完美光学」（原文引 ref.26）；Harris 等（2015）建成可编程纳米光子处理器（PNP，programmable nanophotonic processor）提供硬件基底（原文引 ref.23）。

方法上，Shen2017 利用奇异值分解（SVD，singular value decomposition）把任意实矩阵写为

$$M = U\Sigma V^{\dagger} \qquad \text{（原文}p.442\text{）}$$

两个酉矩阵 $U, V^{\dagger}$ 由级联 MZI（Mach–Zehnder interferometer，马赫–曾德尔干涉仪）网格按 Reck 结构实现，对角阵 Σ 由可编程衰减器实现，其对角元按 $\Sigma_{ii} = \sin(\theta_i/2)$ 编程（原文 p.443）。每个 MZI 由两个 50% 定向耦合器夹一个热光相移器（内相位 θ）再加外相位 φ 构成。非线性单元用可饱和吸收体建模，其透射率满足

$$\sigma\tau_s I_0 = \frac{1}{2}\frac{\ln\left(T_m/T_0\right)}{1-T_m} \qquad \text{（原文式(1)，}p.442\text{）}$$

其中 σ 为吸收截面、τ_s 为辐射寿命、T_0 为初始透射率、T_m 为吸收体透射率——但该非线性在实验中由计算机模拟，层间信号经探测后再注入芯片。实验用 56 个可编程 MZI 构成的硅光芯片，把一个两层四神经元 ONN（共 4×6×2=48 个相移器设定）重编程复用四次完成前向传播，在元音识别上实测 correctness **76.7%**（138/180），对比 64 位数字计算机的 **91.7%**（165/180）（系统级实测，原文 p.443）。关键数字分层：SU(4) 核心保真度 $f = \sum_i \sqrt{p_i q_i}$（原文式(2)，p.447）实测 99.8±0.003、折合每输出端口约 2.24% 误差（器件级，p.443）；相位设定精度 16 bit、探测动态范围 30 dB（器件级，p.444）；维持相位调制器设定需约 10 mW/调制器的静态热调功耗（器件级，p.444）；仿真显示若把相位编码噪声压到单 MZI 水平（$\sigma_\Phi \to 5\times10^{-3}$）correctness 可达 90%，与数字基线相当（仿真级，p.444）；论文外推每 FLOP 能耗 $P/R = 5/mN$ fJ，比 GPU（100 pJ/FLOP）好至少五个数量级（外推，p.445）。局限：76.7% 与 91.7% 的差距主要来自相位编码噪声与探测噪声、全网络热串扰（p.444）；MZI 数量随矩阵维度按 N^2 增长——Wetzstein2020 指出这是任意矩阵实现的必然后果，且随电路规模增大，损耗、噪声与器件不完美同步放大（原文 p.40）；非线性未上片。

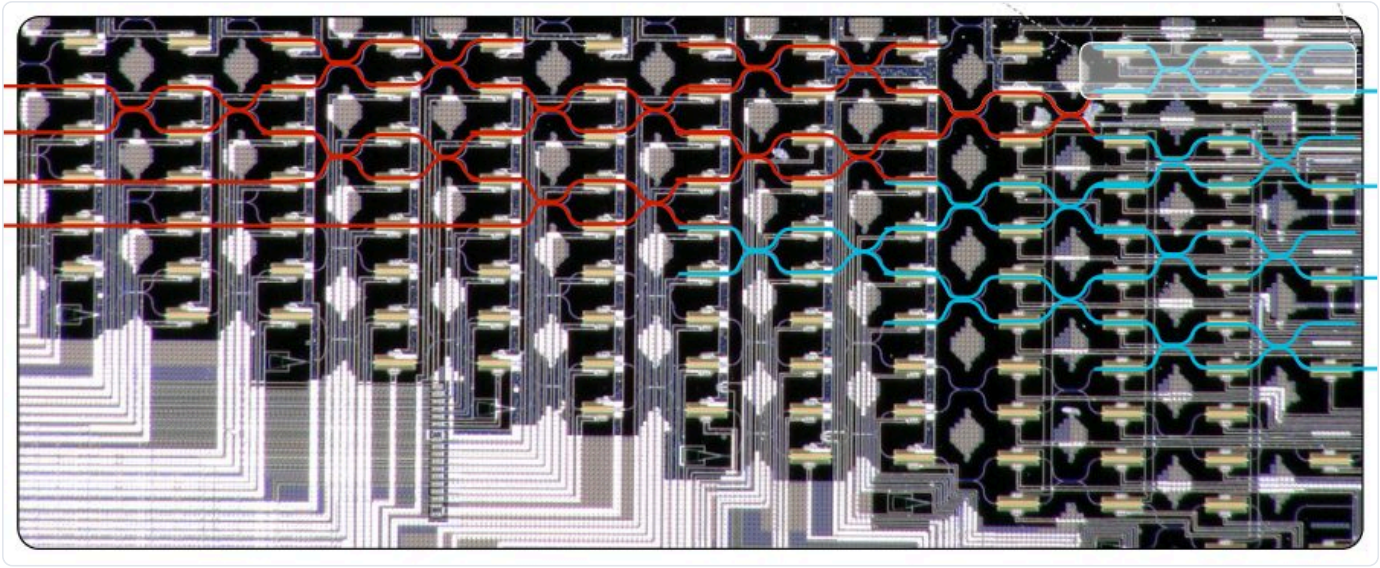


图 6.1 · 相干纳米光子电路的芯片显微照片。红/青高亮出可编程 MZI 网格的两个层级（Reck 结构），网格节点处为热光相移器；左下为探测与走线区。四输入四输出的矩阵-向量乘在这一网格内以光传播一步完成。 图源：Shen et al., *Nature Photonics* **11**, 441 (2017)，第 3 页图 · DOI `10.1038/nphoton.2017.93` 。

Pai2023（Stanford × Politecnico di Milano）把训练搬进了光域。动机：Shen2017 之后光子神经网络推理已演示到 N=64 规模（含商用原型），但高效片上训练从未实现——训练的实验复杂度远高于推理（原文 p.398）。前驱链：Reck 等（1994）与 Miller（2013）奠定 MZI 网格理论；Hughes 等（2018）在 Optica 提出用伴随场与前向场干涉测量梯度的理论方案（原文引 ref.22）；更早 Cruz-Cabrera 等（2000）做过最小体光学演示（原文引 ref.21）；Shen2017 提供推理先行范例（原文引 ref.4）。

方法：三层四端口混合 PNN，逐层执行

$$y^{(\ell)} = U^{(\ell)} x^{(\ell)}, \qquad x^{(\ell+1)} = f^{(\ell)}\left(y^{(\ell)}\right) \qquad \text{（原文式(1)(2)，}p.398\text{）}$$

在典型 MZI 网格之上增加三项硬件使能：**双向光传播**（误差光可从输出端倒注入同一网格）、**全局监测**（每个相移器旁 3% 光栅抽头，IR（infrared，红外）相机成像全部栅格功率）、发生器/分析器子电路的幅度+相位双向探测（原文 p.399）。反向传播的伴随法在这里有精确的物理对应：让前向场 x_h 与反向伴随场 $x_{h,\mathrm{adj}}$ 在每个相移器处干涉，则局部梯度直接由干涉功率给出

$$\frac{\partial L}{\partial h} = I\left(x_h, x_{h,\mathrm{adj}}\right) = \frac{|x_{h,+}|^2 - |x_h|^2 - |x_{h,\mathrm{adj}}|^2}{2} = \frac{p_{h,+} - p_{h,-}}{4} \qquad \text{（原文式(3)，}p.400\text{）}$$

其中 $x_{h,+} = x_h + i\,x_{h,\mathrm{adj}}^{*}$。测量按三步协议执行：①前向——发输入信号、测输出功率；②反向——发误差信号、测伴随功率；③求和——同时发两路，数字相减（或用伴随相位在 0/π 间方波切换的模拟减法）得梯度（原文 p.399–400）。关键数字分层：系统级实测——两层芯片训练任务 circle 数据集 96% test / 93% train，moons 数据集 94% test / 87% train（用真值相位校准后达 98%/95%），推理口径 ring/moons 90%/98%（原文 p.401–402），摘要汇总口径为三层四端口实验与数字仿真相当（>94% test accuracy，原文 p.398）；仿真级——N=64 端口 MNIST 两层 PNN 训练 100 轮后理想情形 97.2%、计入误差平均约 95%（原文 p.402）；器件级——3% 光栅抽头、5 mW 1560 nm 激光、C 带 1530–1565 nm（原文 p.399–400）；外推——假设 100 fJ 级数字运算与抽头噪声因子 <0.01，反向传播能效可改善约 3 倍（外推，原文 p.402）。局限：梯度测量误差随逼近收敛二次增长；相位测量误差是训练退化的主导项；混合架构每层仍需光电转换；输入功率与探测器噪声的权衡对网格规模构成硬限制（原文 p.402）。注意口径：**>94% 是三层四端口芯片实测，97.2%/95% 是 64 端口 MNIST 仿真**，两者不可混用。

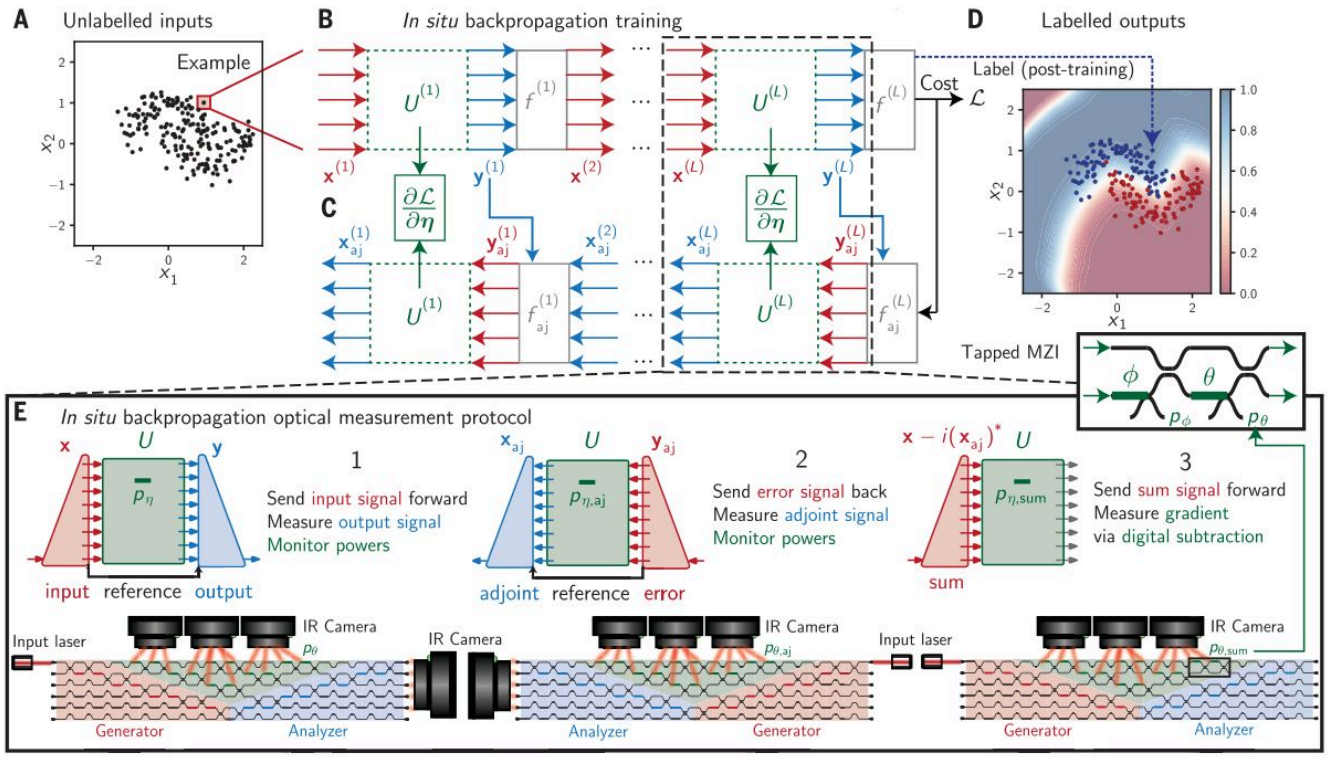


Fig. 1. In situ backpropagation concept. (**A**) Example machine learning problem: An unlabeled 2D set of points that are formatted to be input into a PNN. (**B**) In situ backpropagation training of an *L*-layer PNN for the forward direction and (**C**) the backward direction showing the dependence of gradient updates for phase shifts on backpropagated errors. (**D**) An inference task implemented on the actual chip resulted in good agreement between the chip-labeled points and the ideal implemented ring classification boundary (resulting from the ideal model) and a 90% classification accuracy. (**E**) Our proposed scheme performed the three steps of in situ (analog) backpropagation, using a 6 × 6 mesh triangular mesh MVM chip using a custom | These improvements on an already versa | **Analog update** implementing coherent 4 × 4 bidirectional unitary matrix-vector products using a reference arm. The (1) forward, (2) backward, and (3) sum steps of in situ backpropagation are shown. Arbitrary input setting and complete amplitude and phase output measurement were enabled in both directions using the reciprocity and symmetries of the triangular architecture. All powers throughout the mesh were monitored by an IR camera using the tapped MZI shown in the inset for each step, allowing for digital subtraction to compute the gradient (*22*). These power measurements performed at phase shifts are indicated by green horizontal bars.

图 6.2 · 原位反向传播的概念与三步测量协议。(A) 无标签二维输入；(B) L 层光子神经网络正向传播；(C) 反向（伴随）传播：误差场从输出端倒注入同一网格；(D) 训练后芯片标注的输出与理想决策边界（90% 分类精度）；(E) 原位三步协议 —— ① 前向：发输入信号、测输出功率；② 反向：发误差信号、测伴随功率；③ 求和：同时发两路、经数字相减得梯度。每步的全部栅格功率由 IR 相机经栅格抽头（tapped MZI，右上插图）监测。图源：Pai et al., *Science* **380**, 398 (2023)，第 2 页图 1 · DOI `10.1126/science.ade8450`。

6.2 广播-加权与全光脉冲神经网络：Tait2017 与 Feldmann2019

Tait2017（Princeton）走的是与相干网格正交的路线。动机：光子学擅长传输而罕用于变换，若要让光子硬件继承神经网络的算法、指标与基准生态，必须让物理系统的支配方程与某个神经网络模型**数学同构**——作者明确把 neuromorphic 定义为这种同构关系而非「类脑隐喻」（原文 p.2）；同时硅光平台不含激光增益，故采用调制器神经元（modulator-class）而非激光神经元（laser-class）（原文 p.5–6）。前驱链：broadcast-and-weight 协议由 Tait 等（2014）提出（原文引 ref.32）；MRR（microring resonator，微环谐振器）权重库的可扩展性与精度指标此前已建立（原文引 refs.34,35）；可激发激光神经元已有大量器件工作（原文引 refs.53–59）；相干 MZI 路线（Shen2017）与超导光电网络（Shainline 等）作为对照架构被讨论（原文 p.5）。

方法：**广播-加权**协议——每个神经元的输出调制一个独占波长的载波，WDM（wavelength-division multiplexing，波分复用）合波广播，接收端由 MRR 滤波器库完成连续值加权，平衡探测后**以总功率非相干求和**（免相位管理），电加权和再驱动下一神经元的调制器。「波长 = 连接」把并行度做在波长域而非空间域。其与连续时间递归神经网络（CTRNN，continuous-time recurrent neural network）的同构方程为

$$\tau\frac{ds(t)}{dt} = -s(t) + Wy(t) + w_{\text{in}}u(t), \qquad y(t) = \sigma\left(s(t)\right) \qquad \text{（原文式(1)(2)，}p.2\text{）}$$

状态 s 是加在 MZM（Mach–Zehnder modulator，马赫–曾德尔调制器）上的电压（σ 即 MZM 的正弦电光传递函数），τ 由电低通滤波器设定。同构性的实验证明采用动力学分岔判据：单节点自反馈的双稳 = cusp 分岔（拟合 cusp 点 $W_B = 0.54$，p.3）、双节点反对称耦合的极限环振荡 = Hopf 分岔（$W_B = 0.48$，阈值频率 4.81 kHz，p.4），两者均实验观测。实测芯片为 2 个片外光纤 MZM 神经元 + 片上 2×3 MRR 子网络（两个权重库、各 4 个半径 10 μm 的 MRR）。关键数字分层：器件级——MRR 权重动态精度 4.1+1 bit（p.5）；系统级预测——24 节点仿真 CTRNN 用 NEF 神经编译器求解 Lorenz 系统

$$\dot{x}_0 = -\gamma\upsilon x_0 + \gamma\left(x_1 - x_2\right), \quad \dot{x}_1 = -\gamma x_0 x_2 + \gamma\rho x_0 - \gamma x_1, \quad \dot{x}_2 = \gamma x_0 x_1 - \gamma\beta x_2 \qquad \text{（原文式(3)，p.4）}$$

（$(\upsilon, \beta, \rho) = (6.5, 8/3, 28)$），294× 加速的推导链条是：CPU 侧离散欧拉步进实测 $\Delta t = 24.5$ ns、稳定性要求 $\gamma_{\mathrm{CPU}} \geq 150\Delta t = 3.68\,\mu s$；光子侧受反馈延迟 $t_{\mathrm{fb}} = 47.8$ ps 限制、稳定性要求 $\gamma_{\mathrm{Pho}} \geq 260\, t_{\mathrm{fb}} = 12.5$ ns；$\gamma_{\mathrm{CPU}}/\gamma_{\mathrm{Pho}} = 294\times$（原文 p.5 与 Methods p.7）。**必须强调这是预测口径**——网络级任务从未在该芯片上真实运行，实测只有两节点。资源与功耗均为外推：24 波长/24 调制器/24 MRR 库 = 576 MRR 权重，面积 0.36+0.30 mm²，总系统功率 106 mW（按 5% 激光壁插效率）、折合 180 fJ/SOP（synaptic operation，突触操作）（外推，p.5）；静态热调功耗 3.0 W——按 0.25 nm/mW 调谐效率与 ±1.3 nm 制造重复性，每权重平均 5.2 mW 追踪谐振（外推，Methods p.8）。同口径对比：Shen MZI 路线约 830 fJ/SOP、20 mW/neuron，超导路线约 20 fJ/SOP，TrueNorth 约 240 fJ/SOP（外推对比，p.5）。局限：热调静态功耗是主要负担；权重库间热串扰限制权重精度；实验规模 2 神经元。

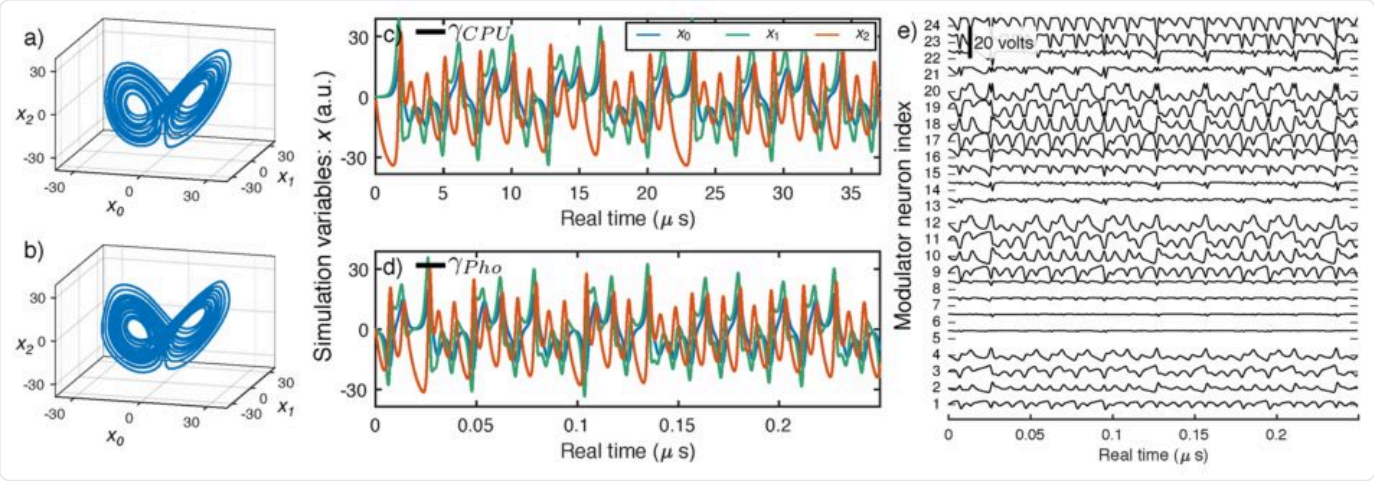


图 6.3 · 光子递归网络的动力学验证。(a/b) 仿真与光子硬件参数下的 Lorenz 吸引子相空间轨迹；(c/d) CPU 基线（时间常数 γ_CPU = 3.68 μs）与光子硬件（γ_Pho = 12.5 ns）的 $x_0/x_1/x_2$ 变量时间轨迹对比 —— 294× 加速预测的来源；(e) 24 个调制器神经元（编号 1–24）的实测时间轨迹（20 V 刻度）。 图源：Tait et al., *Scientific Reports* **7**, 7430 (2017)，第 4 页图 · DOI `10.1038/s41598-017-07754-z` 。

Feldmann2019（Münster × Oxford × Exeter）做出全光脉冲神经突触网络。动机：冯·诺依曼架构下内存与处理器分离，模拟神经网络天然低效；电子域神经形态硬件已有、光学方案尚在萌芽；PCM（phase-change material，相变材料）器件已被证明能在硬件中同时提供神经元的 integrate-and-fire 功能与突触的塑性权重，但全光、集成、可扩展的 PCM 脉冲网络此前未演示（原文 p.208）。前驱链：片上光子突触由 Cheng 等（2017）演示（原文引 ref.14）；全光算盘由 Feldmann 等（2017）演示（原文引 ref.30）；电子 PCM 突触阵列有 Kuzum 等（2012）、Burr 等（2015）（原文引 refs.16,20）；WDM 加权求和协议承接 Tait 等的 broadcast-and-weight（原文引 refs.27,28）。

方法：突触 = 波导上的 PCM 单元（面积 3.6 μm²），**透射率即权重**——非晶态高透（强连接）、晶态高吸收（弱连接）；输入脉冲按波长经小环谐振器合波求和（四个半径 40–55 μm、Q≈10^4、插损 1.5 dB）；神经元 = 半径 60 μm 的大环 + 9 μm² PCM 单元：加权功率超过阈值即把神经元 PCM 打向非晶态、环失谐、探针脉冲透过环输出——一个「发放」。由于发放只发生在功率越过阈值时，激活函数天然近似 ReLU：1553.4 nm 处输出对比度 9 dB、阈值约在最大脉冲能量的 60% 处（器件级，原文 p.210）。权重非易失，维持零功耗。学习侧：监督模式下权重由外部光脉冲设定；无监督模式下输出脉冲经反馈波导导回突触——与输入脉冲时间重叠者被非晶化（增强）、仅受反馈脉冲者被部分晶体化（逐级抑制），即时钟化的简化 STDP（spike-timing-dependent plasticity，脉冲时序依赖可塑性）/Hebb 规则（原文 p.211）。可扩展架构用 collector/distributor 环形级联，耦合效率按 $c_{\mathrm{eff},i} = 1/(N' + 1 - i)$（原文 p.212，未编号）逐级分

配使各神经元均分光功率。关键数字分层：系统级——4 神经元 / 60 突触（每神经元 15 突触）/ 140 余个光学元件，分类四个 15 像素字母 A–D，每个神经元只对训练模式发放（原文 p.208, 213；精度未提供具体百分比）；器件级——该器件发放阈值 430 pJ（原文 p.210）、最大脉冲 710 pJ、脉宽 200 ns（Methods，p.214）、波导交叉损耗 0.23 dB（p.210）；器件级寿命——PCM 单元已演示 10^{12} 次开关循环（引先前实验，p.213）；仿真级——两层网络做英/德语识别，35 词 >90%、150 词 99.6%（Methods，p.214）。局限：每次发放后神经元 PCM 须重结晶回初始态，操作周期数最终受 PCM 寿命限制（作者自承，p.213）；数百 pJ 的脉冲能量远高于理想；全光载波再生意味着输出必然弱于输入（Shastri2021 对此类全光神经元的普遍判词，原文 p.106），实验中输出经片外放大器再回注。

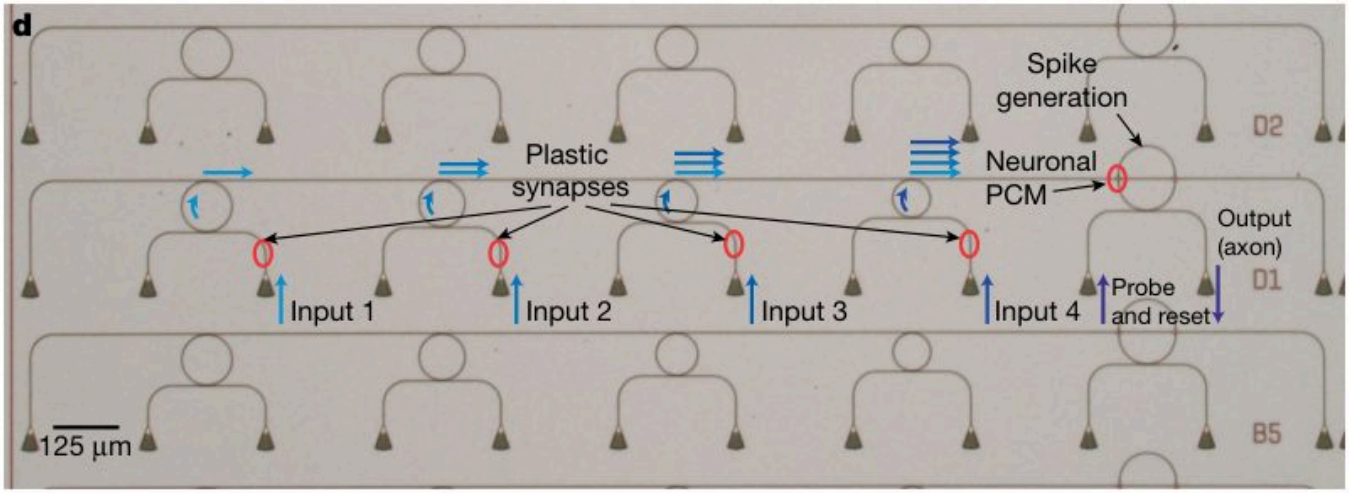


图 6.4 · 全光脉冲神经突触网络的显微照片。四个输入（Input 1–4，蓝色箭头）经环形谐振腔合波， PCM 塑性突触（红圈）加权后汇入神经元 PCM（spike generation），输出经轴突（Output）送出，probe and reset 通道用于读写权重； D1/D2/B5 为器件区编号，125 µm 标尺。 图源：Feldmann et al., *Nature* **569**, 208 (2019)，第 2 页图 · DOI `10.1038/s41586-019-1157-8` 。

6.3 相干伊辛机：原语 P2 的光学实现（Marandi2014 → McMahon2016）

Marandi2014（Stanford / NTT）奠基。动机：Ising 基态问题映射大量 NP 难组合优化，模拟退火与量子退火之外，物理 Ising 机的候选包括 DNA 计算与光纤网络 oracle（原文 p.937 引）；简并 OPO 在阈值处有非平衡相变，阈上输出只取 0/π 两个相位态——天然的二元自由度（原文 p.937）。前驱链：Wang、Marandi 等（2013）在 PRA 提出简并 OPO 构成 CIM（coherent Ising machine，相干伊辛机）的理论方案（原文引 ref.7）；Utsunomiya 等（2011）提出注入锁定激光网络映射 Ising 模型（原文引 ref.24）；量子退火由 Kadowaki & Nishimori（1998）提出、D-Wave 做成大规模机器（原文引 refs.3,6）。

方法：自旋 = 阈上 OPO 的 0/π 相位态，耦合 J_{ij} = OPO 间的相互注入；不同相位配置对应网络不同的总光子衰减率，衰减率最低者即 Ising 哈密顿量

$$H = -\sum_{ij}^{N} J_{ij}\sigma_i\sigma_j \quad （原文式(1)，p.937）$$

的基态。求解机制是**「向上搜索」**：泵浦增益从低于阈值逐渐抬高，当参量增益逼近最低损耗时网络在基态（或近似基态）相位配置处经历 OPO 相变而起振，继续抬泵浦则把增益钉在阈值、持续抑制激发态错误起振——与依赖热跳跃（模拟退火）或量子隧穿（量子退火）跨越亚稳垒的「向下退火」形成对照（原文 p.937–938 与图 1c）。实验为时间复用方案：单个四镜环形腔内 $T_{cavity} = 4T_R$（泵浦重复周期 T_R = 4 ns，腔往返 16 ns）承载 4 个时间分离的 OPO 脉冲；PPLN（periodically poled lithium niobate，周期极化铌酸锂）晶体提供参量增益，1045 nm 飞秒激光泵浦（泵浦脉冲 ~80 fs、信号 ~85 fs）；斩波器以 ~1 kHz 重启系统（上升时间 ~180 µs）；三对输出/输入耦合器加自由空间延迟线实现全部两两耦合，每对约 4% 场耦合（2–6% 之间）（原文 p.938–939）。关键数字分层：系统级——4-OPO 求解 4 顶点立方图（6 边）MAX-CUT，三个延迟全部锁相 π，1,000 次运行未检出激发态，计算误差率 < 10^{-3}（受测量长度限制）（原文 p.940）；器件级——耦合相位容差 ±30°，源于简并 OPO 相敏增益的再生态（原文 p.939）；仿真级——c-数 Langevin

方程模拟至 20,000 个 OPO，计算时间预测亚线性于问题规模（Methods，原文 p.941）。可扩展性论证：N 个自旋有 N^2-N 个耦合，但时间复用网络只需 N−1 条延迟线，物理尺寸线性于 N（Methods，原文 p.941）。局限：演示规模仅 4 自旋；MAX-CUT 实例特设（全反铁磁环）；延迟线耦合固定，一般 Ising 问题需加强度/相位调制器；作者自承没有数学证明保证 OPO 网络对所有 Ising 问题优越（原文 p.941）；功耗数字未提供。

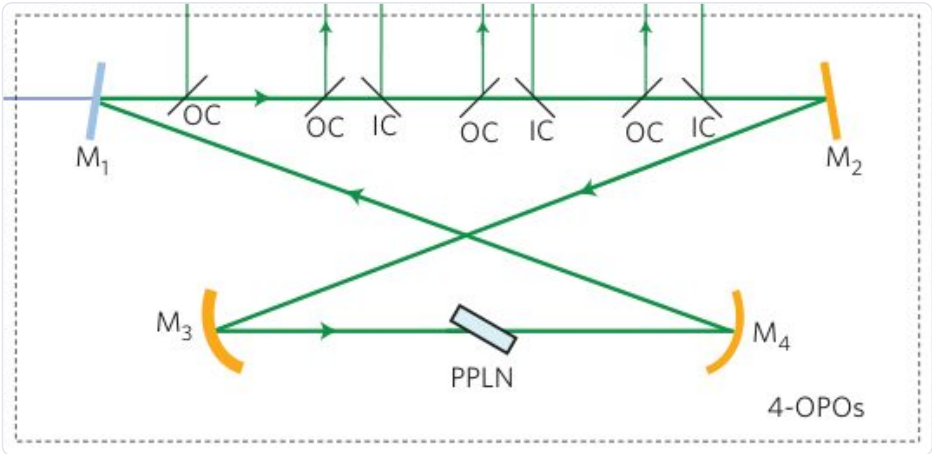


图 6.5 · 时间复用 4-OPO 环腔。四镜（M_1–M_4）环形腔与输出/输入耦合器（OC/IC）：一个腔程内承载 4 个时间分离的 OPO 脉冲，输出耦合器把信号引出做相位测量，输入耦合器注入耦合信号；PPLN 晶体提供参量增益。图源：Marandi et al., *Nature Photonics* **8**, 937 (2014)，第 3 页图 · DOI `10.1038/nphoton.2014.249`。

McMahon2016（Stanford）把 CIM 推到 **100 自旋 × 全连接 × 全可编程**（补充材料标题即如此表述）。其架构是**测量-反馈**：一条延迟线加两个光学调制器即可，与自旋数 N 无关（补充材料 p.3）；每一轮次对腔内每个时间复用 OPO 脉冲做零差测量得到同相分量 c_i，FPGA（field-programmable gate array，现场可编程门阵列）用上一轮测量结果按 $\sum_j J_{ij} c_j$ 计算反馈信号（每个重复周期 T_{rep} = 10 ns 内完成约 2N 次算术运算），注入级再按反馈符号施加 0 或 π 相移、按幅度调制本振脉冲后注入腔内（补充材料 p.3）。往返时间 $T_{rt} = 160 \times T_{rep}$ = 1.6 μs，OPO 阈值约 210 μW（补充材料 p.2, 4）。补充材料明确对比：全光 Ising 机实现任意 Ising 问题需 2(N−1) 个独立物理调制器，测量-反馈架构用电子回路资源置换光学资源，无论 N 多大只需 2 个反馈调制器，并估计现有 FPGA（单芯片 >12,000 乘法器）足以支撑 $N > 10^4$ 自旋的反馈电路（外推，补充材料 p.4）。测量-反馈把「耦合可编程性」与「物理非线性」解耦——全光只发生在 OPO 阈值分岔一步，回路里的光电转换与 FPGA 计算成为电子瓶颈。语料中该文仅持有补充材料（正文无独立 PDF），正文实验细节（如与 NTT 同期机器的基态成功率对比）不可考，其架构逻辑以自绘示意图呈现：

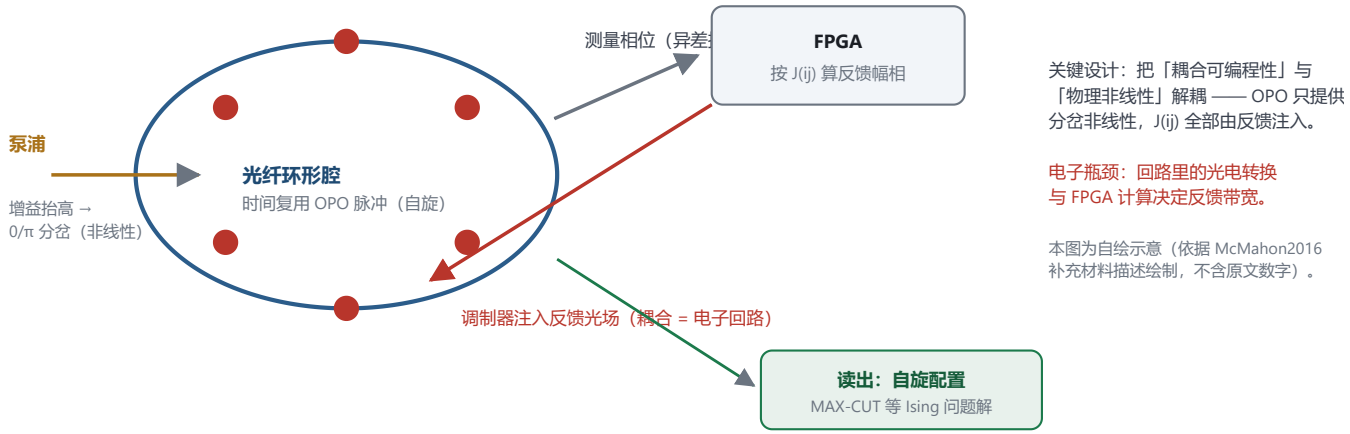


图 6.6（自绘 SVG）· 测量-反馈式相干伊辛机架构（McMahon2016）。时间复用 OPO 环腔提供自旋与分岔非线性；逐脉冲相位测量 → FPGA 按耦合矩阵计算 → 调制器注入反馈光场。100 自旋全连接全可编程的代价是回路中的光电转换与 FPGA 延迟 —— 电子瓶颈恰好卡在「耦合」这一步。图源逻辑：McMahon et al., *Science* **354**, 614 (2016) · DOI `10.1126/science.aah5178`（语料仅持补充材料，本图依其描述自绘）。

6.4 光电乘法与物理极限：Hamerly2019

Hamerly2019（MIT）回答「MZI 网格走不通之后怎么办」。动机：MZI 网格等纳米光子方案中定向耦合器与相位调制器的占位使得扩展到 N≥1000 神经元极富挑战，且迄今没有任何方案同时做到大规模、快速重编程与可训练（原文 p.021032-1）。前驱链：自由空间衍射网络（引 ref.22，但依赖空间光调制器、不可快速重编程）；纳米光子电路（引 refs.23,24，即 MZI 网格与 MRR 加权路线）；输入的时间脉冲编码「令人想起相干伊辛机」（引 refs.28–30）；平衡零差（homodyne）探测为既有技术。

方法：让权重与输入**都编码在光域。**输入 $\vec{x}$ 与权重矩阵每一行 $\vec{A}_i$ 编码为同一相干光源驱动的脉冲序列；输入经自由空间扇出复制到 N′ 个通道；每个平衡零差探测器执行「量子光电乘法」，积累电荷

$$Q_i = \frac{2\eta e}{\hbar\omega}\int \mathrm{Re}\left[E^{(\mathrm{in})}(t)\,E_i^{(w)}(t)^*\right]\mathrm{d}t \;\propto\; \sum_j A_{ij}x_j \qquad (\text{原文式}(2),\ p.021032-3)$$

其中 η 为探测器效率——**乘法发生在探测物理里**（干涉项 $E_wE_{in}^*$ 经平方律探测读出），规模不再受 N^2 相移器约束：N 个输入脉冲 + N′ 个探测器完成 N·N′ 次 MAC（multiply-and-accumulate，乘累加），用线性资源实现二次规模的操作。层间关系即

$$x_i^{(k+1)} = f\left(\sum_j A_{ij}^{(k)}x_j^{(k)}\right) \qquad (\text{原文式}(1),\ p.021032-2)$$

非线性在电域施加、串行化后调制回光域进入下一层。为什么能突破 Landauer 极限？点积通过极化恒等式 $\vec{u}\cdot\vec{v} = \frac{1}{4}(\|\vec{u}+\vec{v}\|^2 - \|\vec{u}-\vec{v}\|^2)$ 计算，其中光学干涉是可逆过程，不落入 Landauer 对不可逆二进制门的假设（原文 p.021032-6）。更深一层贡献是给出本路径的**物理底线**：探测器散粒噪声设定「标准量子极限」（SQL，standard quantum limit）——噪声项按 $n_{\mathrm{MAC}}^{-1/2}$ 缩放（原文式(3)，p.021032-3），MNIST 蒙特卡洛仿真给出：N=100 网络 cutoff 约 0.5–1 aJ（5–10 光子），N=1000 网络低至 **50–100 zJ/MAC（0.5–1 光子）**（仿真级理论极限，原文 p.021032-4），而 32 位数字乘法约需 10^3 次门操作、每次至少 kT ln2 ≈ 3 zJ，即 Landauer 底线 ≥ 3 aJ/MAC（理论极限，原文 p.021032-6）——模拟光学的 SQL 因此理论上可低于数字不可逆计算的极限。关键数字分层：理论极限——50 zJ/MAC 量级 SQL，温度与器件无关（原文 p.021032-4）；仿真级——ALEXNET 全网络 $n_{\mathrm{MAC}} \gtrsim 20$ 即 $E_{\mathrm{MAC}} \gtrsim 3$ aJ，卷积层能量系数 $\langle c_{\mathrm{in}}\rangle > 100$, $\langle c_{\mathrm{out}}\rangle > 1000$，即便 I/O 能量高达 100 pJ 仍可亚 pJ/MAC（原文 p.021032-8/9，式(7)）；外推——现实器件近期可行约 10 fJ/MAC（m,n,k≥100、pJ 级 I/O 假设，原文 p.021032-9）；现状对比——ASIC 约 1 pJ/MAC、GPU 约 20 pJ/MAC（原文 p.021032-1）；架构规模——探测器阵列尺寸限定 N ≳ 10^6（原文 p.021032-1, 9）。局限：权重生成的电学能耗按 O(N^2) 计、需大 batch 摊销（原文 p.021032-3, 6）；自由空间元件引入相位稳定性与像差问题；SQL 只计输入光能量，实际系统按探测器/耦合/光源效率因子上移（原文 p.021032-5）；近期能耗由跨阻放大器（~100 fJ）与 ADC（数 pJ）等电子学主导（原文 p.021032-6）。

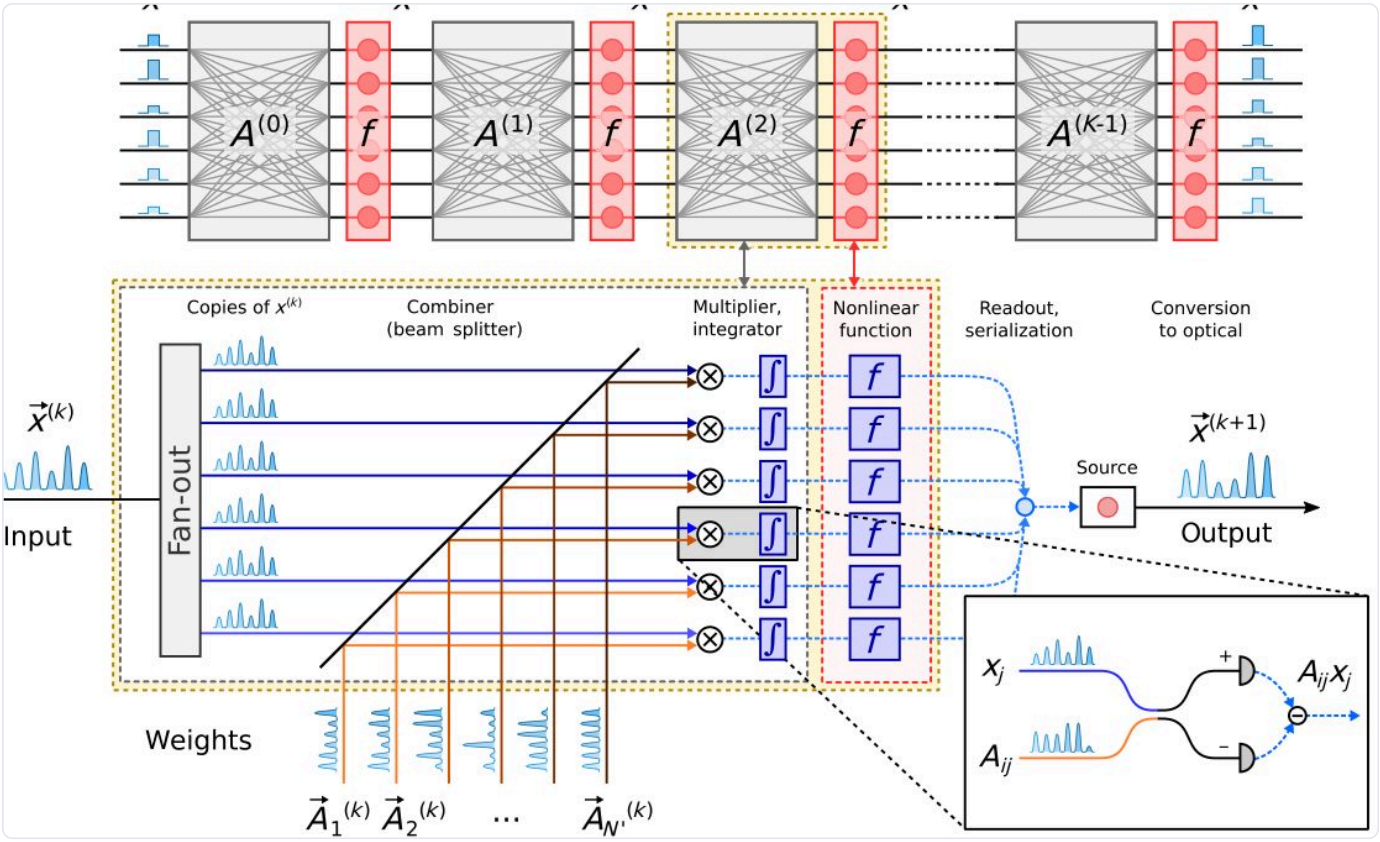


图 6.7 · 光电乘法光学神经网络架构。上：级联层 $A^{(0)}$…$A^{(K-1)}$ 与逐层非线性 f；下（单层细节）：输入 $x^{(k)}$ 经扇出复制多路，与 N′ 个权重光向量 A_1…$A_{N'}$ 在乘法器-积分器（⊗ + ∫）中完成乘加，经非线性 f 后读出、串行化并转换回光域进入下一层；右下插图：权重光 A_{ij} 与输入光 x_j 在平衡探测器上拍频得到 $A_{ij}{\cdot}x_j$。图源：Hamerly et al., *Physical Review X* **9**, 021032 (2019)，第 2 页图 1 · DOI `10.1103/PhysRevX.9.021032`。

6.5 本基质的特殊问题

把四条路径放回 McMahon2023 的审计框架，可以看出各自的「优势来源」与「致命开销」并不相同：MZI 网格动用的是无耗散传播 + 空间并行，代价是 N^2 相移器与热调静态功耗；广播-加权动用的是频（波长）复用并行，代价是非相干求和与电域非线性；CIM 动用的是分岔非线性 + 时间复用，代价是反馈回路里的光电转换；光电乘法动用的则是探测物理本身，代价是权重生成与电子学 I/O。这正是 McMahon2023 的核心论断——任何能兑现优势的光计算机都必须同时驾驭多个光学特征并避开 I/O 类陷阱（原文 p.717, 731）。三篇综述对此有分工明确的判断：Wetzstein2020 指出 1990 年代光学神经网络退潮的三个原因——模拟加速器只在超大网络上有用、非线性激活的电光实现不成熟、模拟权重难以可靠控制（原文 p.39），并强调全光非线性是「真正深」光子网络的关键缺口、电光转换能量是长期挑战（原文 p.39–41）；Shastri2021 把可级联性点为死结——全光神经元「输出必然、且常常大幅弱于其输入，以至于无法驱动哪怕单个下游神经元」，迄今所有光子神经元演示都依赖载波再生（原文 p.106），并把控制电子学与光源的协同封装列为最关键的技术挑战（原文 p.112）。

光子：已经站稳的与还欠着的

- **站稳的**：全光前向传播的芯片实现与精度实测（Shen2017，76.7% 及其噪声归因）；训练进光域的首个实验（Pai2023 原位反向传播，梯度=前向/伴随场干涉）；动力学同构判据（Tait2017 的 CTRNN cusp/Hopf 分岔验证）；全光脉冲神经元的物理机制对齐（Feldmann2019 的 PCM 阈值 ≈ ReLU 与全光学习规则）；CIM 从 4 自旋到 100 自旋全连接全可编程（Marandi2014 → McMahon2016 测量-反馈）；物理底线标定（Hamerly2019 的散粒噪声 SQL，50 zJ/MAC 量级）。
- **还欠着的**：$N \gtrsim 10^4$ 的规模化门槛（McMahon2023，$10^4 \times 10^4$ 才有实质吞吐优势，原文 p.731）；$O(N^2)$ 相移器与随规模放大的损耗/噪声/不完美（Wetzstein2020，原文 p.40）；可级联性死结（Shastri2021，全光神经元输出弱于输入，原文 p.106）；热调静态功耗与光源共封装（Shen ~10 mW/MZI、Tait 3.0 W；Shastri2021 点名电子学+光源协同封装，原文 p.112）；**噪声的两面性**——散粒噪声既是能效下限的设定者（Hamerly2019 的 SQL），也是模拟光学的精度障碍（Wetzstein2020 的误差积累分析），引用时必须分清说的是「极限」还是「实现」。
- **可预见形态**：光电混合。在非线性可级联与光源/控制电子共封装（Shastri2021 的两个关键工程挑战）解决之前，「全光」系统不存在；Pai2023 的混合架构与 Hamerly2019 的电域非线性事实上都接受了这一点——区别只在把 I/O 塞回哪个环节。

07 基质四 · 概率计算、Ising 机与热力学计算（原语 P3 + P2）

> **本章回答的问题：在所有其他基质都「抑制涨落」的时候，刻意放大涨落的系统在算什么？**
>
> 算的是**分布**。当计算语义从「求值」变为「采样」（§3 原语 P3），热涨落就从误差源变成引擎：Glauber 动力学的平稳分布是 Boltzmann 分布、Langevin 动力学的平稳分布是 Gibbs 分布，而**采样正是组合优化（在能量面上找最低态）与生成模型训练（对比散度需要模型相关样本）的公共原语**—— 一次物理弛豫同时服务两类负载。这也解释了本章在全书中的位置：§4–§6 的各条基质（VMM、CIM、OPO 等）都在与器件噪声搏斗， 而这里的主角把噪声请回舞台中央——涨落的统计规律本身就是计算模型。 本章沿实现层级推进（仿 Rajak2022「数值模拟 → 蒙特卡洛 → 硬件」的层级式写法）： §7.1 是磁学奠基与理论框架（Sutton2017，全部为经实验标定的仿真）；§7.2 是 FPGA 系统级三部曲（Chowdhury2022 的并行采样 → Niazi2024 的生成模型训练 → Nikhar2024 的标度定律收束）；§7.3 是热力学计算（Melanson2025 的连续变量硬件 + Aifer2024 的理论； 任务从 Ising 优化迁移到采样与线性代数）。器件层 s-MTJ p-bit 的物理实现已在 §5.1 展开，本章只在必要处引用，不重复。

7.1 磁学奠基：Sutton2017 的「内在优化」

Sutton2017（Purdue）在 s-MTJ 实验演示（§5.1）之前就确立了磁学版 Ising 机的完整理论框架，其动机写得很直白：大量 Ising 求解器只是「在软件里模仿 Ising 模型」——用随机数发生器产生噪声、用数字加法器做加权求和， 层层抽象把物理等价性（physical equivalence）的效率磨掉了（原文 p.2）。作者主张反其道而行：让硬件**自身就是** Ising 系统—— 每个单元是一个能量势垒 $\Delta \approx k_{\mathrm{B}}T$ 的随机纳米磁体，在 ±1 两个 Ising 态之间以 $\tau \sim \tau_0 \exp(\Delta/k_{\mathrm{B}}T)$、$\tau_0 \sim 0.1\text{–}1$ ns 的尺度电报式随机翻转（原文 p.1）， 问题的 Ising 编码直接写进器件耦合，统计力学自身完成搜索——不让硬件执行优化算法，而是让物理系统「内在地」优化。

前驱工作链（据其引言）：模拟退火（Kirkpatrick 等，1983）、DNA 计算（Adleman，1994）、量子退火 （Kadowaki & Nishimori，1998；Johnson 等，2011）、细胞神经网络（Chua 与 Yang，1988）、CMOS 退火芯片 （Yamaoka 等，2016，2 万自旋）、离子阱（2010）、机电系统（Mahboob 等，2016）、光学（McMahon 等，2016；Inagaki 等，2016） 以及磁学（Bhanja 等，2015；Behin-Aein 等，2016 的「硬件置信网络」构建块）。Sutton2017 的增量在于把「随机磁体 + 自旋电流耦合」 作为这些方案的物理底座，并用 Fokker–Planck 方程证明其平稳分布确为 Boltzmann 分布。

方法核心：把 Ising 哈密顿量

$$H = -\sum_{ij} J_{ij} S_i S_j - \sum_i h_i S_i \quad \text{（原文式(1)，p.1）}$$

编码进磁体网络后，作者从 N 磁体系统的 Fokker–Planck 方程出发，要求平稳分布为

$$\rho(m_1, \ldots, m_N) = \exp\left[-E(m_1, \ldots, m_N)/k_{\mathrm{B}}T\right], \qquad E = A\sum_i m_i^2 + \sum_i h_i m_i + \sum_{ij} J_{ij} m_i m_j \quad \text{（原文式(3)(4)，p.3）}$$

反解出势垒与温度的关系 $\Delta_k = -A/k_{\mathrm{B}}T$（原文式(8)，p.3）与所需的自旋电流偏置（原文式(2)，p.3）。 这一推导是整条路线的合法性证书：**器件的热涨落 + 对称耦合 = 严格的 Boltzmann 采样**，这正是 §3 原语 P3 的磁学版本。 退火不需要真正降温：连续调节耦合电流幅值即可等效升温/降温，室温运行。16 城 TSP 概念验证采用 ulysses16 数据集、$(N-1)^2 = 225$ 个随机纳米磁体（固定起点城市），退火调度 $T_{i+1} = 0.9\,T_i$、拉格朗日乘子 $\lambda = 0.9/W_{\max}(uv)$（原文 Methods，p.8）；判据有二：能量随 $\ln T$ 呈 S 型衰减，以及比热

$$C(T) = \left(\langle E^2(T)\rangle - \langle E(T)\rangle^2\right)/(k_{\mathrm{B}}^2 T^2) \quad \text{（原文 p.6）}$$

在临界温度出现明确峰——比热峰标记问题instance的特征温度，为退火调度提供了物理锚点（图 7.1b）——比热峰提示在该温度附近放慢降温最有利于跳出局域极小； 这正是把统计力学诊断量（⟨E⟩、C(T)）用作算法监控信号的第一例：硬件在退火，实验者在读图 7.1a 的能量曲线判断收敛进度。

值得强调「内在优化 vs 执行算法」的对比究竟意味着什么。数字 CMOS 退火机（如 Yamaoka 等，2016 的 2 万自旋芯片） 让 CPU 式的控制逻辑按预写的调度逐一更新自旋——物理只是算法的廉价载体；而 Sutton2017 的方案中不存在中央控制器： 每个磁体自己按 Boltzmann 统计掷骰子，搜索的「算法」就是统计力学本身，作者把这概括为消除抽象层后「硬件在其自然的、内在的运行中即解决问题」（原文 p.2）。这一立论决定了此后概率计算路线的评价体系： 硬件与 Ising/Gibbs 模型的偏离程度（采样是否正确、混合是否够快）取代了传统的每秒运算数，成为核心指标—— §7.2 三部曲与 §7.3 的热力学计算都是在这套评价体系内展开的。

关键数字：**全部为仿真级**（经实验标定的随机 LLG（Landau–Lifshitz–Gilbert）宏自旋模型，SPICE 求解）； 器件参数假设 $\Delta = 1\ k_B T$、PMA 直径 45 nm、$M_s = 300$ emu/cc、$\alpha = 0.01$（原文 Methods，p.8）； 100 µs 仿真完成 XOR 与 TSP；运行速度量级 GHz（模型假设）。TTS、功耗：未提供。 作者亦承认当时实验纳米磁体的翻转时间实为 µs–ms 量级，ns 量级有待器件缩小（原文 p.4）。 局限：全连接假设在小网络成立、大网络路由拥塞不可忽略；只演示了「直白退火」，未寻找最优退火调度（原文 p.3）； 且全部结果待硬件兑现。但它的两条设计公理——「器件随机性免费 + 耦合可重构」——定义了此后所有 Ising 机论文的问题词汇。

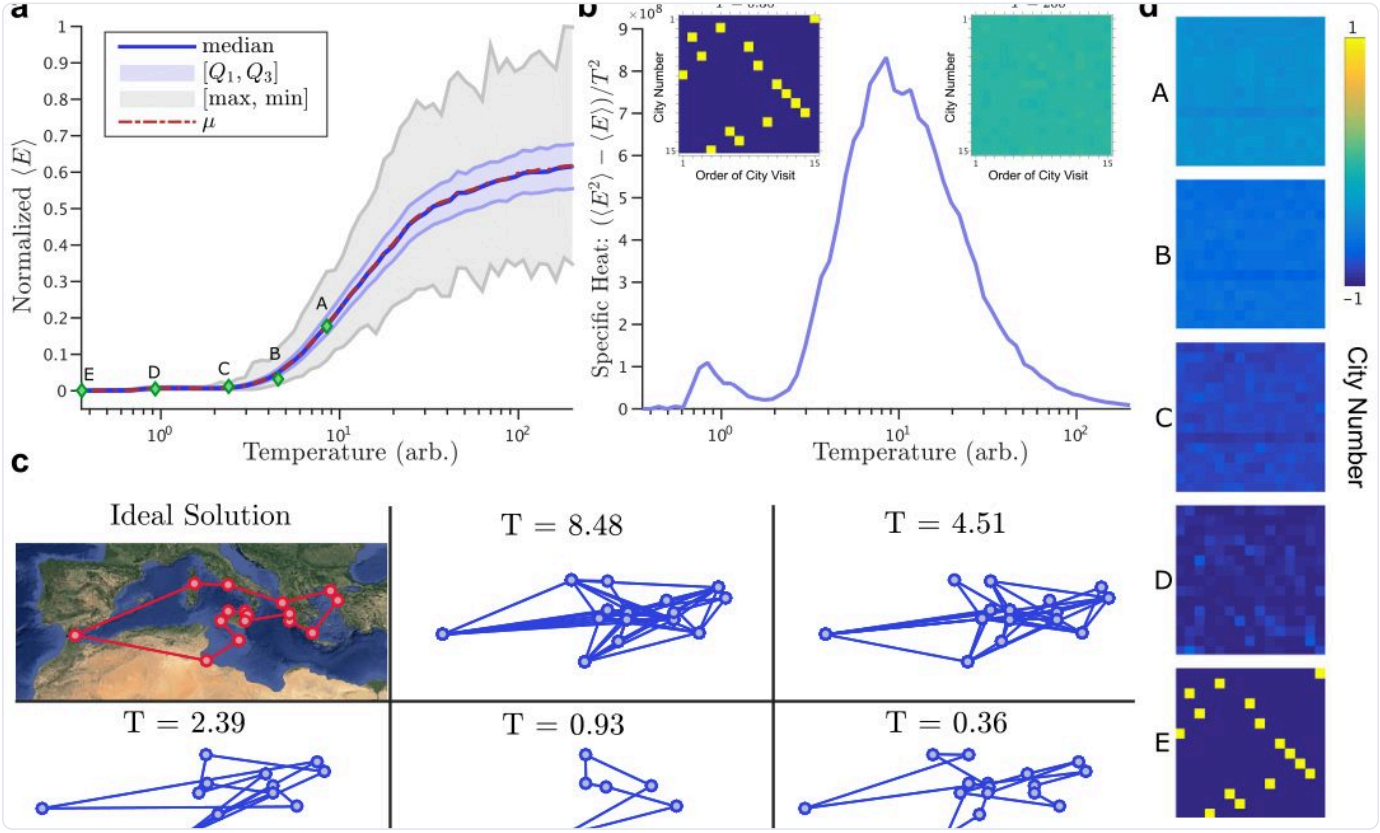


图 7.1 · 随机纳米磁体网络的「内在退火」解 16 城 TSP。(a) 归一化能量 ⟨E⟩ 随温度的退火曲线 （中位数 / 四分位 [Q₁,Q₃] / 极值带 / 均值 µ，A–E 五个状态点）； (b) 比热 $(\langle E^2 \rangle - \langle E \rangle^2)/T^2$ 出现双峰结构 （插图为 T = 0.98 与 T = 200 时的「城市 × 访问序」矩阵：低温下非对角出现稀疏亮点 = 有序路由）； (c) 路由演化： 左上为 ulysses16 理想解（地中海 16 城地图，红色路线），右侧为 T = 8.48 → 4.51 → 2.39 → 0.93 → 0.36 各温度下的路由快照，(d) 列为对应 A–E 状态点的磁体组态矩阵——「降温 = 物理系统收敛到低能量配置」的直接可视化。 图源：Sutton et al., *Scientific Reports* **7**, 44370 (2017)，第 6 页图 · DOI `10.1038/srep44370` 。

7.2 FPGA 系统级三部曲：Chowdhury2022 → Niazi2024 → Nikhar2024

在 s-MTJ 阵列实现之前，FPGA（field-programmable gate array，现场可编程门阵列）上的模拟 p-bit 承担了这条路线全部的系统级证据链。三篇论文恰好构成「采样 → 训练 → 标度」的递进： 第一篇解决**能不能并行**，第二篇解决**并行采样有什么用**（训练生成模型），第三篇回答**到底快多少、还差多少**。

Chowdhury2022（UCSB × Messina）的动机是 Gibbs 采样的串行瓶颈：相连 p-bit 必须逐个更新（否则网络振荡、 收敛不到 Boltzmann 分布），标准 MCMC（Markov chain Monte Carlo，马尔可夫链蒙特卡洛）教科书里就是嵌套 for 循环（原文 p.460）。 前驱链：Metropolis 算法（1953）与 RBM 训练（Hinton）确立 MCMC 在 AI 中的地位；D-Wave 量

子退火机已被用于优化之外的任务 （Dixit 等，2021）； 可逆逻辑 p-bit（Camsari 等，2017）； s-MTJ 整数分解（Borders 等，2019，10 bit）； GPU/TPU 上的棋盘格块更新采样（Fang 等，2014；Yang 等，2019）； 以及 HOGWILD!–Gibbs 异步采样理论（De Sa 等，2016）。

方法：以可逆逻辑构造稀疏问题图，

$$E = -\Big(\sum_{i<j} J_{ij} m_i m_j + \sum_i h_i m_i\Big), \quad I_i = \sum_j J_{ij} m_j + h_i, \quad m_i = \mathrm{sgn}\big[\tanh(\beta I_i) - \mathrm{rand}_{U(-1,1)}\big]$$ （原文式(1)(2)(3)，p.460）

保证状态访问概率 $p_i \propto \exp[-\beta E(\{m\})]$（原文式(4)，p.460）。两个关键机制：**图着色块并行**—— 用贪心着色算法 DSATUR 给图染色，同色 p-bit 互不相连、可同拍更新，多相位时钟轮询各色块即得精确 Gibbs 采样； **精确稀疏化**—— 把高度数 p-bit 用铁磁 COPY 门拆成两个，保持基态不变（Kaminsky & Lloyd，2004 思路）。 图密度 $\rho = 2|E|/(|V|^2 - |V|)$（原文式(5)，p.462）足够低时（≲1%），几百个邻居的不规则图也只需 4–8 种颜色。 稀疏化的经济账值得算清楚：32 bit 分解器从 784 个 p-bit（密度 1.03%、最大 32 邻居）化到 2,128 个 p-bit （密度 0.2%、最大 5 邻居），p-bit 数翻了近三倍，却换来加法器深度有界——在缩放的实现里， 单个 p-bit 几乎总比复杂互连便宜，且把每个 p-bit 的邻居数钉在常数 k 上后，加法延迟不再随系统规模增长， 可扩展性问题就从全局布线降级为局部通信（原文 p.461–462）。 关键数字（除注明外均为系统级 FPGA 实测，Xilinx VCU118）：翻转率随 p-bit 数**线性增长**——从 14 bit 分解的 5.99×10^9 flips/s 到 50 bit 的 8.06×10^{10}（CPU 串行 Gibbs 上限约 10^5，差最高六个数量级； 原文 p.463–464）； TTS（time to solution，求解时间）99% 口径下 50 bit 分解 1.84 ms，对 CPU 的 4,408.93 s 改善约 2.4×10^6 倍（原文 p.464）； 峰值 143.8 flips/ns（4,793 p-bit），较优化 GPU/TPU 快 5–18 倍（原文 p.463、465）； 精确分解随机半素数至 **32 bit**（$4{,}277{,}546{,}633 = 65{,}479 \times 65{,}327$），为当时所有优化式分解硬件之最； 近似 SAT（95% 子句）胜过 SAT 竞赛冠军求解器 4–700 倍（原文 p.465）。10^6 p-bit 器件版 10^6 flips/ns 的投影为模型预测 （原文 p.463）。功耗/TOPS/W：未提供。局限：精确求解 SAT 在 2,903 p-bit 以上即告失败（原文 p.465）； 并行性以稀疏为前提，稠密实例上消失；过频（overclocking）虽有可观的容错窗口，但最终偏离 Boltzmann 分布。

Niazi2024把并行采样对接到机器学习真正的公共负载上。动机：Boltzmann 机（Hinton 等，1984）因训练需要海量平衡样本 而退出主流深度学习（LeCun 等，2015）； 对比散度（Hinton，2002）与持久对比散度（Tieleman，2008）只是缓解； 用 D-Wave 退火机训练 RBM（restricted Boltzmann machine，受限玻尔兹曼机）的尝试（Adachi & Henderson，2015； Dixit 等，2021）受限于稀疏拓扑与采样质量；噪声注入模拟 Ising 机的采样（Böhm 等，2022）规模有限。 方法：混合「概率计算机 + 经典计算机」——FPGA 上的 p-bit 网络负责采样，CPU 负责算梯度（图 7.3 框架）。 采用 D-Wave 的 Pegasus/Zephyr 稀疏拓扑作固定网络，直接在全网络上训练（不分层逐层）， CD-n 的正相把可见 p-bit 钳位到训练图像、负相自由演化，梯度即两相关联之差：

$$\Delta J_{ij} = \varepsilon\big(\langle m_i m_j\rangle_{\text{data}} - \langle m_i m_j\rangle_{\text{model}}\big), \qquad \Delta h_i = \varepsilon\big(\langle m_i\rangle_{\text{data}} - \langle m_i\rangle_{\text{model}}\big)$$ （原文式(5)(6)，p.612）

采样时 $\beta = 1$（与优化任务逐步升温相反，原文 p.611–612）。网络为 4,264 个 p-bit（834 可见 = 784 像素 + 50 标签，3,430 隐层）的稀疏深度玻尔兹曼机，约 3 万参数（30,404），最大度 15–20，4 色并行；权重精度 10 bit。 关键数字（系统级 FPGA 实测，AMD Alveo U250）： 完整 MNIST（无降采样）100 epoch 分类精度 **90%**， 与约 **325 万**参数的优化软件 RBM 同精度——而同参数量（34,142）的 RBM 达不到 90%（原文 p.613–614）； 实测 50–64 billion flips/s（原文摘要、p.611）； 混合时间（mixing time）经验值约 10^4 sweeps，CD-n 最高做到 n = 10^7 sweeps/更新，超出软件实现能力（原文 p.614–615）； 训练后钳位标签位、从 β = 0 退火到 5， 能**生成**新手写数字与服饰图像——325 万参数的 RBM 在同样流程下生成失败（原文 p.614–615，图 7.3）； 索引随机化是稀疏网络独有的必要技巧：串行分布精度 <50%，随机分布恢复 90%（原文 p.616）—— 在全连接网络里任意两节点的图距离是常数，此问题根本不存在；稀疏拓扑中标签位与可见位的图距离直接决定相关联学习信号的质量。 混合时间研究还给出一个对软件 RBM 的「降维打击」：精度在 CD-10^4 以下急剧退化、CD-10^5 起饱和（原文 p.615）， 说明瓶颈确实在「每杆权重更新能采到多少平衡样本」——这恰是概率计算机的强项，64 billion flips/s 下 10^5 sweeps 只需毫秒量级，真正的瓶颈反倒是 FPGA-CPU 之间经 PCIe 的权重往返（100 epoch 约 20 h，原文 p.617）。 因 PCIe 往返开销，100 epoch 实际耗时约 20 h（原文 Methods，p.617）。sMTJ 版 10^6 flips/ns 的投影为模型预测、 「尚未实现」（原文 p.612）。能效（pJ/样本或 TOPS/W）： 未提供。局限：与卷积网络相比远非 SOTA（state-of-the-art，最先进）； 精度饱和受 FPGA 规模而非算法限制（作者自陈，原文 p.615）； 生成能力目前限于二值像素。

Nikhar2024做了标度定律层面的收束。动机：全连接拓扑虽好编程，但 $O(n^2)$ 的权重数在大规模下不可持续， 高阶项更是 $O(n^k)$——「某种形式的稀疏化不可避免」（原文 p.1–2）。前驱链：XORSAT 挑战 （Hen，2019 提出 equation planting；Kowalsky 等，2022 汇集了 D-Wave、东芝 SBM、富士通 DAU、SATonGPU 等全部对标数据）、 自适应并行退火（APT，adaptive parallel tempering；Mohseni 等，2021；Aadit 等，2023）。方法上提出**主图复用**： 把同一规模的 100 个稀疏 instance 合成一个稠密主图，用 instance 选择器逐个激活，邻居与相位时钟随实例复用—— 稀疏 instance 的并行性（全网络一拍更新，$T_{\mathrm{clk}} = 66.67$ ns，原文 p.6）与全连接的可重构性兼得。 作者刻意区分主图与静态全连接网络：主图任一时刻只激活一个稀疏 instance，加法器规模始终被邻居数 k 界定 （复杂度 $O(kn)$），而全连接为 $O(n^2)$——「从不完全激活」正是两者本质差异（原文 p.4）； 等价性验证也做得很足：100 个 instance × 每个千次运行，FPGA 主图与 CPU 全连接的逐 instance 成功概率与 平均交换接受率在小数点后三位内一致（原文 p.5）。 三阶（3-body）相互作用直接改写有效场：

$$I_i = \sum_{j<k} J_{ijk}^{(3)}\, m_j m_k + \sum_j J_{ij}^{(2)}\, m_j + h_i \qquad \text{（原文式(5)，p.3）}$$

由于 p-bit 是二值变量，三阶项用 AND 门即可实现、无需乘法，硬件复杂度随阶数仅对数增长（原文 p.6）； 副本交换概率按 Metropolis 判据 $P_{\mathrm{sw}} = \min(1, e^{\Delta E \Delta\beta})$（原文式(6)，p.3）。 性能以 XORSAT 挑战的标准形式拟合：

$$\langle \mathrm{TTS} \rangle_q \approx 10^{\gamma n + \eta} \qquad \text{（原文式(8)，p.6）}$$

关键数字（系统级 FPGA 实测，Alveo U250 单卡）：二阶 $\gamma = 0.0206(2)$、$\eta = -3.76(6)$（中位数， 原文 Table 1，p.8），实测规模 $n = 16$–112；三阶 $\gamma = 0.0201(2)$、$\eta = -4.30(0)$， 实测 $n = 16$–160（p.6、8）；对照 SATonGPU $\gamma = 0.0171(7)$、$\eta = -5.9(3)$， DAU $\gamma = 0.0185(4)$、$\eta = -3.56(7)$，D-Wave $\gamma = 0.08(4)$（Table 1，p.8）。 结论有三：**三阶化改善前因子（p-bit 数减半、η 更负）但不改标度指数**——判定并了 Kowalsky 等留下的开放猜想（原文 p.8）；这一结果颇有物理意味：辅助自旋把相空间指数级扩大、在解之间制造了额外的能量势垒与熵势垒，直觉上理应惩罚二阶化， 但 APT 的算法性能对这些「劣势」不敏感——对原生 k 阶问题，k 局部表述未必带来标度收益（原文 p.8）；APT 用更少副本达到与标准 PT 相当的算法性能（n = 208 时 11 个副本对 32 个，原文 p.6）； sMTJ 投影（10^6 p-bit、τ = 1 ns、单芯片 10–50 副本）斜率微升至 0.0218/0.0213——模型预测（原文 p.8）。 作者同时直言阈值所在：新兴 Ising 机「不仅要彼此超越，还必须超越最好的经典求解器」（原文 p.8， 指 GPU 上的贪心启发式 SATonGPU 仍全面领先）。功耗：未提供。局限：稠密图需 O(n) 色并行度归零， 必须先稀疏化；副本交换目前由外部 CPU 执行（TTS 计算中以两次全 sweep 作保守计入，原文 p.8）。

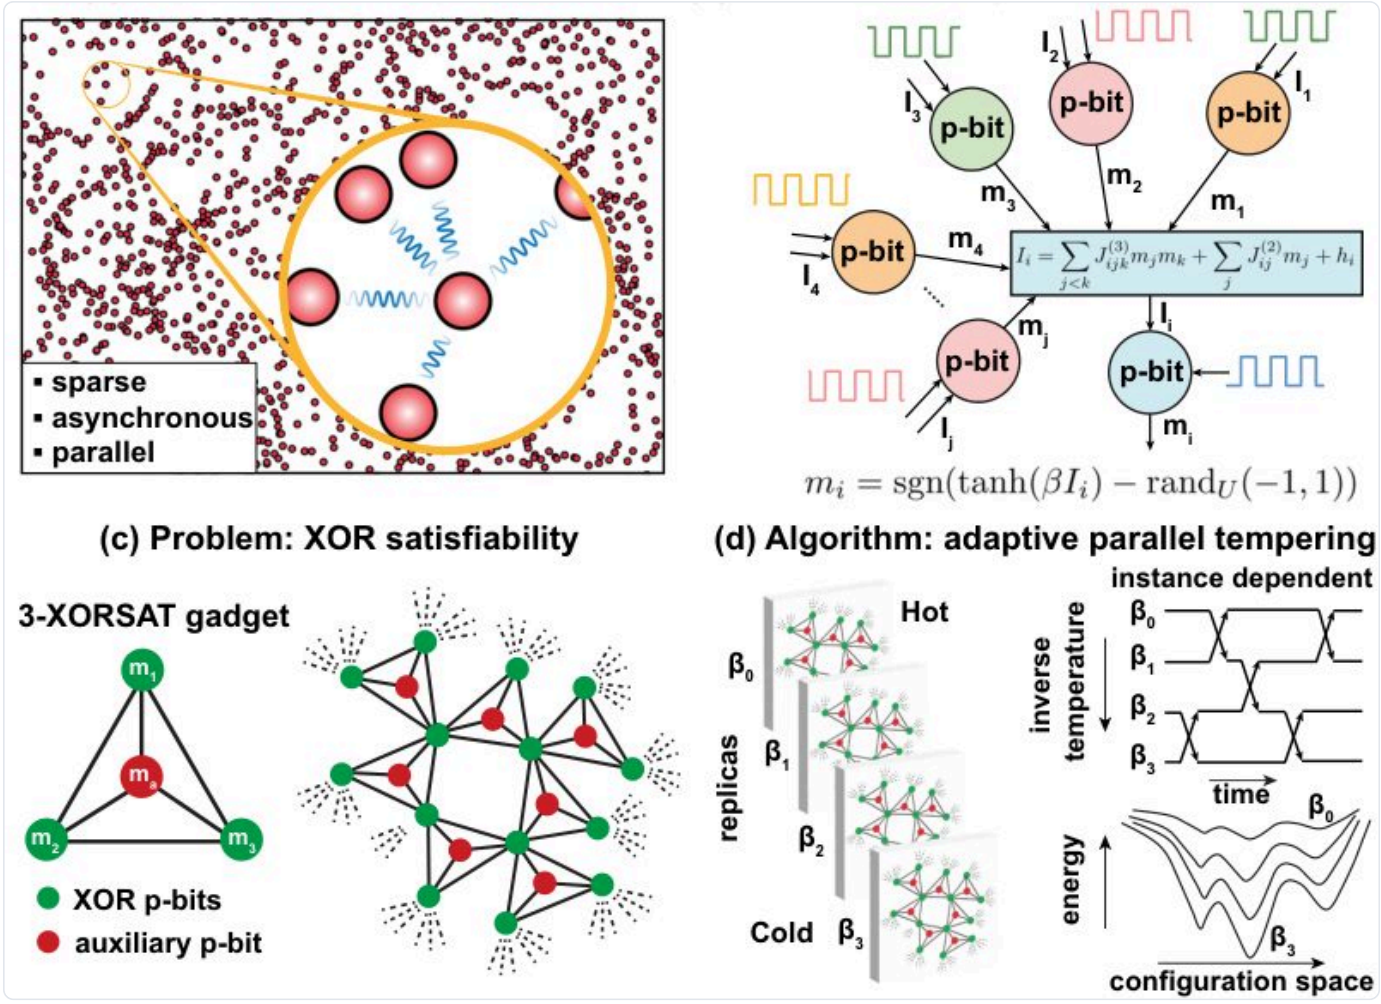


图 7.2 · p-bit Ising 机的机制全景。(a) 物理层：稀疏 / 异步 / 并行的相互作用粒子系统 （放大圈内为弹簧耦合的偶极粒子）；(b) 架构层：多相位时钟驱动的 p-bit 网络与三阶有效场 $I_i = \sum_{j<k} J^{(3)}_{ijk} m_j m_k + \sum_j J^{(2)}_{ij} m_j + h_i$，下方为 Glauber 更新式 $m_i = \mathrm{sgn}[\tanh(\beta I_i) - \mathrm{rand}_{U(-1,1)}]$；(c) 问题层：3-XORSAT gadget—— 三个绿色 XOR p-bit（m_1,m_2,m_3）夹一个红色辅助 p-bit（m_a），及其拼成的大规模稀疏实例图；(d) 算法层：自适应并行回火（APT）——β_0（热）到 β_3（冷）多副本按 Metropolis 判据交换状态， 右下为副本在能量面相邻谷间穿越的示意（instance dependent 的温度轮廓由 APT 预处理生成）。 图源：Nikhar et al., *Nature Communications* **15**, 8977 (2024)，第 2 页图 1 · DOI `10.1038/s41467-024-53270-w` 。



图 7.3 · FPGA p-bit 机训练的稀疏深度玻尔兹曼网络生成的手写数字（MNIST 0–9）。 黑底白像素、笔画带明显采样噪声：样本由钳位标签 p-bit、将网络从 β = 0 退火到 β = 5 自由演化产生， 是「网络学到的是数据分布而非判别面」的直接证据。约 3 万参数的稀疏网络能完成此生成任务， 而 325 万参数的软件 RBM 在同一退火流程下失败。图源： Niazi et al., *Nature Electronics* **7**, 610 (2024)， 第 2 页图 · DOI `10.1038/s41928-024-01182-4` 。

7.3 热力学计算：从 Ising 优化转向采样与线性代数（Melanson2025 + Aifer2024）

概率计算路线的下一跳是战略性的任务迁移：不做组合优化，做**机器学习的公共负载**——连续变量的采样与线性代数。这一步的动机来自概率 AI（贝叶斯推断、不确定性量化、扩散模型）在数字硬件上的计算困境 （Melanson2025 引 Izmailov 等，2021，原文 p.1），以及一个观察：概率 AI 的数学恰好与热力学同构 （Coles 等，2023 的「涨落前沿」纲领）。Mohseni2022 指出，今天在常见基准上表现最好的 Ising 硬件仍基于经典数字技术， 且性能高度依赖问题类型

（原文 p.2）——既然如此，与其在优化赛道上与成熟算法缠斗，不如开辟采样/线性代数赛道。 这也与 Albash2018 对量子退火的判读形成镜像：QA 领域用热涨落探索能量面的对应物正是模拟退火（原文 p.36）， 且量子退火早已被提议用于训练（R）BM（Neven 等，2008；Adachi & Henderson，2015；原文 p.40）—— 「采样即负载」并不是新想法，缺的是合适的硬件。

Melanson2025（Normal Computing）给出了当前最完整的端到端演示。随机处理单元（SPU，stochastic processing unit） 用 PCB（printed circuit board，印刷电路板）上的 8 个 RLC 电路单元全连接耦合，器件运动方程即 Langevin 方程

$$dx = M^{-1}p\,dt, \qquad dp = -\nabla U\,dt - \gamma M^{-1}p\,dt + N[0,\,2\gamma\beta^{-1}I\,dt]$$ （原文式(1)(2)，p.1–2）

其平稳分布为 Gibbs 分布 $f(x) = Z^{-1}e^{-\beta U(x)}$（原文式(3)，p.2）。电路-力学对应（原文式(6)–(10)，p.3）： 引入磁通 $\phi = Li$ 与电荷 $q = Cv$ 这对正则坐标后，ϕ 扮演位置、q 扮演动量、 电容矩阵 C 扮演质量、$1/R$ 扮演摩擦系数 γ、势能 $U(\phi) = \frac{1}{2}\phi^T L^{-1}\phi$， 平稳分布为 $\phi \sim N[0,\beta^{-1}L]$、$q \sim N[0,\beta^{-1}C]$。 关键工程自由度：噪声谱密度 κ_0 可由数字控制器人为加大到超过本征热噪声，$\beta = \gamma\kappa_0^{-1}$ 成为可编程的「有效温度」（原文 p.2）——室温下即可调温，这正是相对量子硬件的实用性优势。 器件实现细节也值得物理读者注意：单元电容用三值开关电容阵凑（1.0/3.2/4.3/6.5 nF，数值经优化选择）， 单元间耦合用 0.47 nF 开关电容、经中心抽头变压器切换正负极性实现双极耦合，电感 2.2 μH（原文 Methods，p.7）—— 全是用现货元件搭出的「可编程热浴」。 用法有二：**高斯采样**——把用户给的精度矩阵编码进电容，$C = kT\,P$，平衡电压即服从 $N[0, kT\,C^{-1}]$（原文式(15)(16)，p.3）； **矩阵求逆**——令 $C = kT\,A$，平衡电压协方差即 A^{-1}（原文式(17)，p.3）。 物理弛豫**天然完成采样**：相关时间 $\tau_{\mathrm{corr}} \approx Rc_{\max}$（$c_{\max}$ 为电容矩阵最大本征值， 原文式(11)，p.3）。端到端四段流程：GPU 算电容值 → 装载 → 模拟弛豫 → ADC 读回（原文 p.4）。 关键数字：高斯采样与 **8×8 矩阵求逆为硬件实测**（三块名义相同的 PCB、12,000 样本、最优采样率 12 MHz、 8 通道 10-bit ADC；原文 p.3–4 与 Methods p.7）——求逆实验即一次热力学线性代数演示；其余全部为模型预测： d ≈ 3000 交叉点（1 万样本情形）、$O(d^2)$ 对 GPU Cholesky 的 $O(d^3)$、d = 10^4 时时间与能耗各约 一个数量级优势，假设为 1 μs 物理时间常数、ADC 随维度扩展 10 MS/s、每单元 0.005 mW（由 ADC 主导） （原文 p.4–5）。局限（作者自陈）： 电感与变压器阻碍集成化——已提出 RC 单元 + 电阻耦合的替代架构， SPICE 25×25 与 Cadence d = 20（8-bit 电阻阵）仿真给出 ~2% 渐近误差（原文 p.5）； 全连接在 O(1000) 节点以上难以维持； 精度与可扩展性存在权衡。优势数字「代表数学模型，真正的热力学优势只有放大硬件才能证明」（原文 p.5）。

理论侧 **Aifer2024**为这条路线补上复杂性证明。动机：稠密矩阵的 LU/Cholesky 分解 $O(d^3)$ 仍是线性代数主流； HHL（Harrow–Hassidim–Lloyd，2009）量子算法虽对稀疏良态矩阵标称 log d，但资源需求远超现有硬件 （原文 p.1–2 及其引 Scherer 等，2017 的资源分析）。前驱链：数字蒙特卡洛线性代数（Forsythe & Leibler，1950 的 矩阵求逆）——热力学算法可视为其连续时间版本，但「物理基而非物理启发」的连续性恰是渐近加速的来源（原文 p.2）； 忆阻器 crossbar VMM 与模拟线性代数加速器（原文 p.2）。 方法：解 $Ax = b$ 只需把势能设为 $U(x) = \frac{1}{2}x^T Ax - b^T x$（原文式(2)，p.2）， 热平衡时 $x \sim N[A^{-1}b,\,\beta^{-1}A^{-1}]$（原文式(3)，p.2）——**均值给出解、协方差给出逆矩阵**： $\langle x\rangle = A^{-1}b$（原文式(4)，p.2）； 时间平均依各态历经假设收敛于系综平均（原文式(5)，p.2–3）； 行列式则经自由能差与 Jarzynski 等式 $e^{-\beta\Delta F} = \langle e^{-\beta W}\rangle$ 联通 （原文式(18)–(25)，p.4）——把统计力学的涨落定理（Jarzynski 等式本是单分子实验的招牌）变成矩阵算法，是这条路线 「物理内禀性」最漂亮的展示。核心结论（Table 1，p.2，模型预测口径）： 线性方程组 $O(d\kappa^2\varepsilon^{-2})$ 对数字最优 $O(\min\{d^\omega, d^2\sqrt{\kappa}\})$、矩阵求逆 $O(d^2\kappa\varepsilon^{-2})$ 对 $O(d^\omega)$、行列式 $O(d\kappa\ln(\kappa)^3\varepsilon^{-2})$ （$\omega \approx 2.3$，κ 为条件数，ε 为误差）——渐近加速随维度**线性增长。** 数值仿真证实收敛时间随 d 线性（解方程）/平方（求逆）增长，d = 1000–5000、大 κ 时优于共轭梯度与 Cholesky（仿真级，Nvidia RTX 6000/A6000 GPU 对照，原文 p.5–6）。理论还给出内禀的能量-时间乘积下界 $E\tau \gtrsim 2\kappa^2 d/(\varepsilon^2(1-P_\varepsilon))\cdot\beta^{-1}\tau_r$（过阻尼，原文式(35)，p.8）—— 时间与能量可以交换，乘积不可，这是数字复杂度理论中没有的约束形式。 局限（含假设，原文 Methods p.8）： 各态历经与快速平衡假设、势能瞬时切换与任意精度实现均为理想化； 计时模型中占主导的恰是 $O(d^2)$ 的数字编译步（原文 p.8）； 模拟器件的失配与非线性误差不在模型内 （误差缓解实验仅使求逆误差降 20%，原文 p.9）。

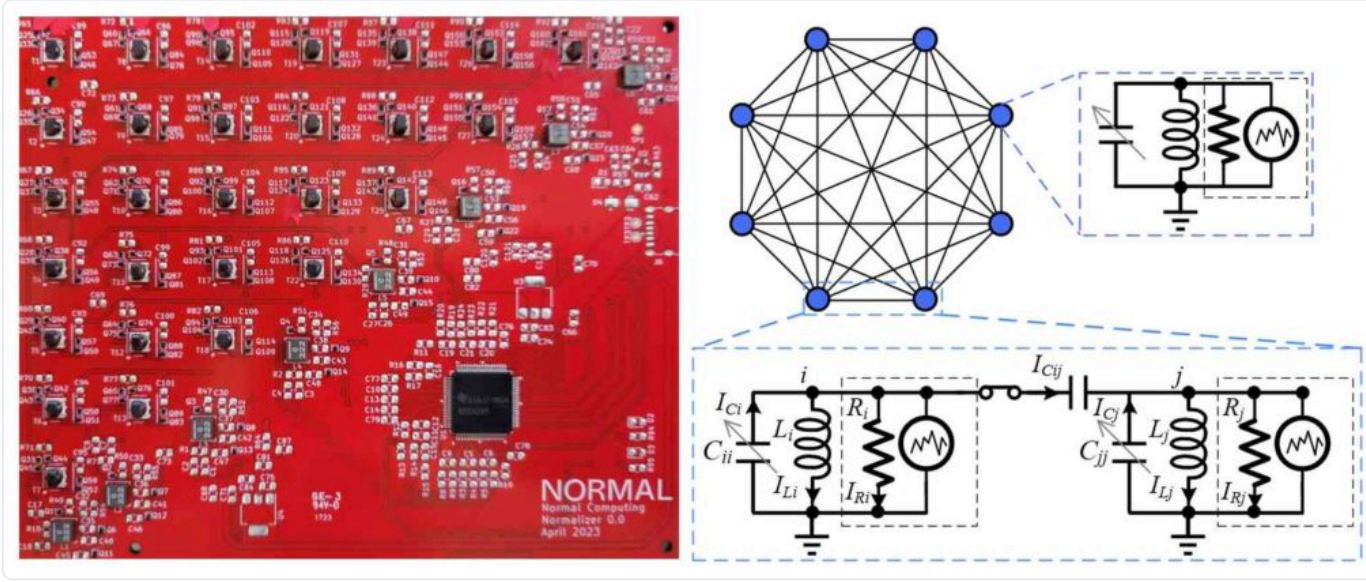


图 7.4 · 热力学计算 SPU 硬件。左：Normal Computing「Normalizer 3.0」PCB 实物 （2023 年 4 月版，8 单元版，右下角可见 FPGA 控制芯片）；右上：8 个单元的全连接耦合网络（蓝色节点） 与单单元 RLC 电路（可变电容 C = 质量、电感 L、电阻 1/R = 摩擦、噪声源 = 热浴）； 右下：两单元间的开关电容耦合支路 I_Cij（经中心抽头变压器实现双极性耦合）与完整电路—— Langevin 动力学的电路实现，平衡电压协方差即目标矩阵之逆。图源：Melanson et al., *Nature Communications* **16**, 3757 (2025)，第 2 页图 1 · DOI `10.1038/s41467-025-59011-x`。

7.4 本基质的特殊问题

概率/热力学：已经站稳的与还欠着的

- **站稳的**：p-bit 语法与器件化（§5.1）； FPGA「替身先行」的完整系统级证据链——并行采样（Chowdhury2022，fps 线性于规模）→ 生成模型训练（Niazi2024，全 MNIST 90% + 样本生成）→ 标度定律与跨硬件对标（Nikhar2024，γ/η 拟合、共用 XORSAT 挑战基准）； 热力学计算的端到端四段核算 （含 ADC）与线性代数落点（Melanson2025 硬件 8×8 求逆 + Aifer2024 复杂性证明与能量-时间下界）。 理论合法性早已封顶：Sutton2017 的 Fokker–Planck 推导保证「对称耦合 + 热涨落 = Boltzmann 采样」； 对这条路线特别有利的一点是，它的精度语义与数字硬件根本不同——采样任务的输出是分布而非单值， 器件级误差被统计平均稀释，这正是 Melanson2025 敢于宣称「对噪声 inherent 鲁棒」的底气（原文 p.2）。
- **还欠着的**：物理 s-MTJ 阵列（投影 10^6 p-bit @ 1 ns sweep）何时兑现——「物理涨落即计算」的卖点全部押在它上面， 目前三代 FPGA 论文都只能以模型预测收尾；稠密实例上并行性消失（图着色退化为串行），稀疏化只是转移而非消除困难； **必须过 GPU 这一关**——Nikhar2024 作者自陈「必须超越最好的经典求解器」，Mohseni2022 确认当前最强 Ising 硬件基于经典数字技术（原文 p.2）； 全路径无一报 TOPS/W，Sutton2017/Chowdhury2022/Niazi2024/Nikhar2024 功耗均未提供 ——Melanson2025 的含 ADC 核算是唯一开端，而其优势数字全部是模型预测口径。
- **高阶之争已收尾**（Nikhar2024：三阶改前因子不改标度指数），后续投入应转向稀疏拓扑、复用架构与稠密实例的稀疏化； 热力学侧则把「涨落是错误」翻转为「涨落是资源」，其能量-时间乘积下界提示了一条与数字复杂度理论正交的算法评价轴。

08 基质五 · 新兴与非常规计算基质（储备池范式）

> **本章回答的问题：还有哪些物理自由度能承载计算 —— 以及，一个新基质怎样用最低的门槛证明自己「能算」？**
>
> 前几章的基质（电子、光子、自旋）都有成熟的器件工艺与明确的性能指标；本章的两种基质 —— **机械形变**（§8.1）与**活体神经组织**（§8.2）—— 则代表「物理计算」概念的外边界：前者把计算压回 19 世纪计算机的原点（纯力学），后者把它推到生命物质。 两者的共同点是都选择了同一条入场协议：**储备池范式。**Tanaka2019（§8.3）给出这一范式的统一形式体系 —— 把物理系统的固有动力学当作固定的非线性特征映射，**只训练线性读出层**，训练成本被压到最低， 对器件一致性与可重构性的要求也最低。正因如此，它成为每个新基质自证「能算」的标准协议： Alu2025 的机械智能路线图把物理储备池计算列为机械域最具可行性的入口（§8.1）， Cai2023 的脑类器官则把它推到极端基质（§8.2）。本章语料最少（4 篇），全部处于演示级 —— 它的价值不在算力， 而在划定「physics for AI」的边界：什么样的物理系统、在什么最低条件下，可以被接纳为计算基质。

8.1 机械计算：Mei2023

研究动机。机械计算 —— 信息以形变状态存储、计算经由机构运动或形变演化完成 —— 的可行性自 Babbage（19 世纪）即已确立， 并具有抗电磁干扰与数据安全等独特优势（原文 p.1）。但 Mei2023 指出其真正瓶颈：非易失机械存储单元的读写 要么依赖复杂外围设备，要么需要全系统沿精心设计的能量景观走完状态转移路径， 记忆模块与计算模块之间的机械信号带宽因此受限（原文 p.1）。出路是**存内计算**：把计算嵌入机械记忆单元的相互作用网络， 读写接口即计算接口，消除长程数据传输。

前驱工作链。机械逻辑门已有多种实现：折纸机构（Treml et al. 2018；Meng et al. 2021）、屈曲梁 （Zhang et al. 2021，三稳态三元逻辑）、连杆系统（Merkle et al. 2018）；信号传播经由机械、机电 （El Helou et al. 2021, 2022）或机液接口（Preston et al. 2019；Drotman et al. 2021）； 可重编程的 von Neumann 式机械计算架构已由 Mei et al.（2021）演示；非易失机械存储基于双稳元件 （Yasuda et al. 2017；Chen et al. 2021）；电子域的存内计算（Ielmini & Wong 2018；Jung et al. 2022）提供了架构模板 （以上前驱链据原文 p.1–2 引用）。Mei2023 的增量在于：同时满足「分布式非易失可重编程存储 + 功能完备逻辑 + 神经形态兼容」三条要求 （原文 p.2）。

方法与公式。存储单元是预压缩屈曲梁：左拱为 0、右拱为 1，其力–位移曲线呈现双稳 （不稳定平衡点位移 u_M，图 8.1b）。系统由时间信号（周期性外力 F）驱动，仅靠三种基本相互作用即可构成功能完备集： **移位寄存器**（上游状态 $x_i^{(t)}$ 在时间信号作用下传给下游 $x_i^{(t+1)}$，条件 $\Delta > u_M$）、 **XNOR 门与感知机。**感知机的输入–输出关系为（原文式(1)，p.4）：

$$x_{n+1}^{(t+1)} = \varepsilon\left(\sum_{i=1}^{n} \alpha_i x_i^{(t)} - 1\right),$$

其中 α_i 是连接弹簧的无量纲刚度（弹簧并联使权重求和）， ε 是输出屈曲梁二值翻转给出的阶跃激活。 AND 门取 $n = 2, \alpha_i = 1/2$，OR 门取 $\alpha_i = 1$ —— 16 种两输入一输出真值表由此全部可达（原文 p.4–6）。 在此基础上，机械二值神经元 $x_j^{(l+1)} = \varepsilon\left(\alpha \sum_i w_{ij}^{(l)} \circ x_i^{(l)} - 1\right)$ （$\circ$ 为机械 XNOR；原文 p.4）与电子域二值神经网络（Courbariaux et al. 2016）逐位等价， 从而把训练好的 BNN（含 MNIST 手写数字判别）直接「翻译」成 3D 打印的机械二值神经网络（MBNN）。更进一步，按 Rosenblatt 感知机的更新律 $y = \varepsilon(\tilde{w}x + \tilde{b} - 1)$、 $\tilde{w} \leftarrow \tilde{w} + \mathrm{sign}(y^t - y)\, x\, \mathrm{d}\tilde{w}$（原文 p.7）， 用记忆单元自身的移位循环实现权重更新（原文式(2)，p.8），构成**机械自学习感知机** —— 学习行为完全发生在机构内部，无外部处理器。

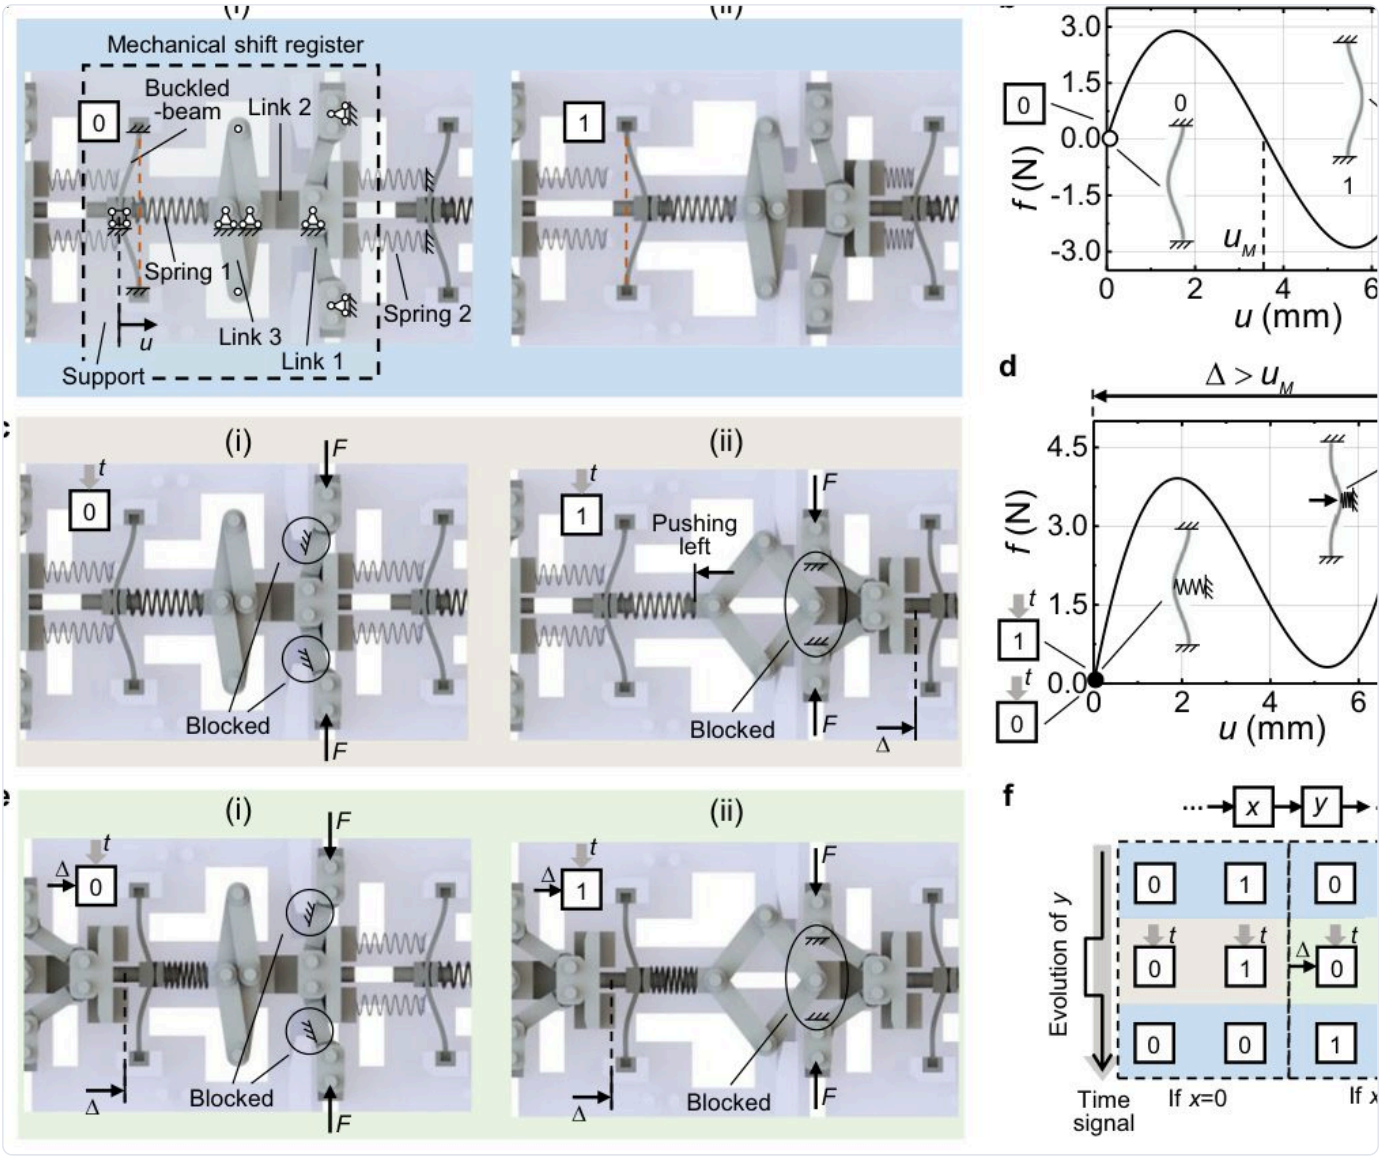


图 8.1 · 机械移位寄存器与机械逻辑。左列：(a) 移位寄存器结构 —— 双稳屈曲梁（buckled beam）、 连杆（Link 1–3）、弹簧（Spring 1/2）与支撑，状态 (i) 为 0、(ii) 为 1；(c)(e) 接收时间信号（外力 F）与 位移载荷 Δ 时的两种演化（Blocked / Pushing left）。右上：(b) 双稳力 f–位移 u 理论曲线 （幅值牛顿量级，不稳定点 u_M）；(d) 时间信号作用下变为单稳，$\Delta > u_M$ 保证状态写入。 右下：(f) 状态转移表 —— 上游 $x = 0$ 时下游 y 复位为 0，$x = 1$ 时 y 翻转为 1， 二值状态沿机构链传播。图源：Mei & Chen, *Nature Communications* **14**, 5204 (2023)，第 3 页图 2 · DOI `10.1038/s41467-023-40989-1`。

关键数字（全部为器件级/演示级实验，3D 打印厘米尺度）： 时钟速率 0.5 Hz， 受屈曲梁最低固有频率 $f_b \approx 1155$ Hz 限制（器件级，原文 p.10，式(7) 由有限元拟合预压缩比给出）； 机械自学习感知机在 10/20/30 输入三案例中约 3500 训练步收敛，权重收敛至 1/6、偏置收敛至 1 （$\alpha = \beta = 1/2, \gamma = -1/3$；器件级，原文 p.8）； MBNN 判摩尔斯码奇偶为直接实验演示， MNIST 判别经由 BNN 训练约 170 步收敛后映射（仿真级 + 器件级，原文 p.6）；能耗：**未提供**； 并行吞吐：**未提供。**

Alu2025 路线图的定位。Alu2025 以十二节路线图覆盖「材料→器件→系统」全谱系：波模拟计算超材料、神经形态超材料、 材料触觉逻辑、机械逻辑与自主材料、带记忆的机械超材料、软物质计算、形态计算、机械神经网络、植物启发智能、 小尺度磁软机器人物理智能、气动逻辑电路、以及经物理计算具身力学智能（原文 p.2 目录）。其结论有两点与本章直接相关： 其一，物理储备池计算（PRC）因「简单且鲁棒」被列为机械域首选计算入口 —— 声子超结构可借自身非线性动力学作储备池， 感知激励并自调谐带隙以隔离/通过弹性波（Zhang et al. 2023）； 折纸储备池无需中央控制器即可计算极限环、 产生蠕动爬行步态并估计身上载荷（Bhovad & Li 2021）（原文 p.36–37，§12）。其二，成熟度判断谨慎： 波基模拟计算等方向「仍面临重要挑战」，距「取代或增强数字计算」所需的成熟度尚远（原文 p.3–4，§1）。

局限。速度上限即结构固有频率（kHz 量级封顶，缩小尺寸可提升但受制造工艺限制）； 无统一能耗度量惯例；功能完备性已证，但大规模互连网络的制造与机械信号传播仍是工程瓶颈； 时间信号需分布式执行器（实验中为电磁铁序列）提供 —— 计算并非完全无源（原文 p.8）。

8.2 生物基质：Cai2023 的 Brainoware

研究动机。硅基神经形态芯片只能部分模拟脑功能；而人脑约 200 亿细胞、百万亿突触只耗约 20 W， 同等规模 ANN 的当前 AI 硬件耗电约 8 MW（引自 Mehonic & Kenyon 2022；原文 p.1）。 脑类器官（brain organoid）—— 由人多能干细胞自组织形成的类脑三维组织 —— 提供了硅芯片没有的四样东西： 复杂度、连接性、神经可塑性与神经发生（原文 p.1–2）。Cai2023 因此问：能否把活的神经组织直接用作计算基质?

前驱工作链。储备池计算框架（Lukoševičius & Jaeger 2009；Tanaka et al. 2019）提供了方法论； MEA 培养细胞的混合生物–硅储备池早已演示（见 Tanaka2019 §8.2，大鼠皮层细胞 + 读出分类器）； 脑类器官技术（Lancaster et al. 2013；Qian et al. 2016；Trujillo et al. 2019）使其具备三维结构与多样化细胞类型； 功能连接可经刺激重塑的证据（Giandomenico et al. 2019；Sharf et al. 2022）支撑了「训练发生在组织内部」的假设 （以上据原文 p.1–3 引用）。

方法与协议。Brainoware = 脑类器官贴装于高密度微电极阵列（high-density microelectrode array，HD-MEA）之上（MaxOne 系统），构成三层结构：**输入层**把信息编码为时空电刺激脉冲序列 $u(t)$； **自适应活体储备池**即类器官神经网络（organoid neural network，ONN），把输入映射到高维计算空间； **输出层**由 MEA 记录的神经活动经线性/逻辑回归读出 $y(t)$（原文 Methods，p.6）。 与常规物理 RC 的关键差别：储备池不是固定的 —— 重复刺激通过突触可塑性重塑 ONN 功能连接， 构成「无监督训练」； 用 CaMKII 阻断剂 K252a 阻断突触可塑性即可解耦这一效应（原文 p.3）。 储备池特性先经逐项验证：响应脉冲电压呈 Sigmoid 非线性（脉宽 $t_p \geq 200\,\mu$s）； 刺激后 100/300 ms 响应衰减（衰减记忆）；脉冲串下呈忆阻器样累积–弛豫 （$v_p = 200$ mV、$t_p = 300\,\mu$s）；互补空间图案 P1/P2（$v_p = 500$ mV、$t_p = 500\,\mu$s） 激发出可区分的栅格图（原文 p.3–4）。演示任务为语音识别（日语元音 /a/、/e/，8 名男声 240 段音频， 编码为时空脉冲）与 Hénon 映射 $x_{n+1} = 1 - 1.4\,x_n^2 + y_n,\ y_{n+1} = 0.3\,x_n$ （非线性混沌时间序列预测；方程据原文图 4a 标注，p.5）。

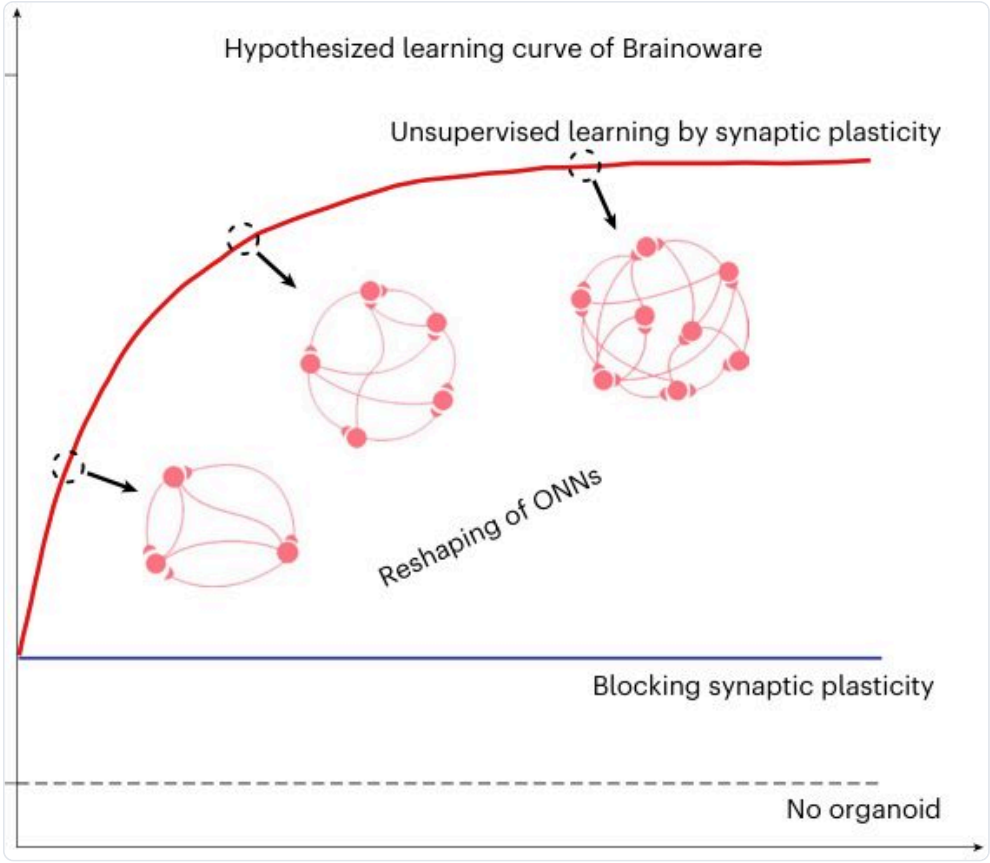


图 8.2 · Brainoware 的学习概念图。红色曲线为「假设的 Brainoware 学习曲线」（原文明确标注 hypothesized learning curve）：随训练进行，类器官功能连接（球状网络插图）经突触可塑性不断重塑 （Reshaping of ONNs）；下方两条对照线 —— 阻断突触可塑性（Blocking synaptic plasticity，性能维持但学习停止） 与无类器官基线（No organoid）。「学习发生在生物组织内部」在此是假设性表述，实验证据来自训练前后 功能连接变化的统计比较。图源：Cai et al., *Nature Electronics* **6**, 1032 (2023)，第 2 页图 1(d) · DOI `10.1038/s41928-023-01069-w`。

关键数字（全部为演示级，$n = 5$ 个类器官、三次独立批次的统计）：语音识别准确率 51.0±7.8%（训练前）→ 78.0±5.2%（4 个训练 epoch 后；原文 p.4）； Hénon 映射预测回归分 0.356±0.071 → 0.812±0.043（4 epoch 后），K252a 阻断对照组仅 0.310±0.072 → 0.385±0.063 —— 学习活性确实依赖神经可塑性（原文 p.5–6）； 训练次数比含 LSTM 的 ANN 减少 >90%（Brainoware 4 epoch vs ANN+LSTM 50 epoch，且后者略优； 原文 p.6）；训练期间功能连接变化（增强/减弱/新生/修剪）显著多于训练前（原文 p.5）； 能耗：器件本体低但外围设备（CO_2 培养箱、计算机）仍相当可观，具体功耗数字**未提供**（原文 p.6）。

局限。原文自陈（p.6）：类器官异质性高、生成吞吐低、坏死/缺氧与批次活力差异； 平面刚性电极只能刺激/记录类器官表面少量神经元，需发展三维软电极接口；时空编解码链路待优化。 另有该基质独有的维度 —— 类器官智能（organoid intelligence）的伦理争论（原文引用 Smirnova et al. 2023 等）。 本报告只陈述技术内容，但引用者应当知晓该维度存在。

8.3 统一框架：Tanaka2019 的物理储备池计算

研究动机。循环神经网络（recurrent neural network，RNN）适合时序数据处理，但训练依赖 时间反向传播（backpropagation through time，BPTT）或实时循环学习（real-time recurrent learning，RTRL）， 计算成本高且前者难以学习长程依赖（原文 p.6–7）。储备池计算（reservoir computing，RC）的解法是结构性的： 储备池（递归连接）固定不训练，只训练读出 —— 学习退化为一次线性回归， 训练成本大幅降低，且「固定」恰好匹配硬件：任何能对输入产生动力学响应的物理系统都可充当储备池， 无需为训练设计自适应机制（原文 p.4–5, 10）。

前驱工作链。回声状态网络（echo state network，ESN；Jaeger 2001）与液体状态机 （liquid state machine，LSM；Maass et al. 2002）独立提出、后统一为 RC 框架（Verstraeten et al. 2007； Lukoševičius & Jaeger 2009）；BPDC 学习规则（Steil 2004）亦被视为前身；更早的特殊情形可追溯至 序列联想记忆（Gallant & King 1988）、皮层–纹体模型

（Dominey 1995）与生物神经网络时序模式判别 （Buonomano & Merzenich 1995）（原文 p.4）。物理 RC 的「能算性」概念演示是水桶流体储备池： 电机扰动水面产生波纹，摄像机记录后训练软件读出，完成 XOR 与口语数字识别（Fernando & Sojakka 2003；原文 p.11–12, 图 2）。

方法与公式（ESN 谱系）。无输出反馈时，ESN 储备池状态演化为非自治动力系统（原文式(1)，p.7）：

$$x(n) = f\left(W^{\text{in}}u(n) + Wx(n-1)\right),$$

其中 n 为离散时间，$x(n)$ 为储备池状态向量，$u(n)$ 为输入， W^{in}、W 分别为输入连接与储备池内部递归连接权重矩阵（均固定），f 为逐元素激活函数。 输出为状态向量的线性组合（原文式(2)，p.7）：

$$y(n) = W^{\text{out}}x(n),$$

监督学习只训练 W^{out}。储备池需具备**回声状态特性**（echo state property）： 渐近消除初始条件的影响；经验判据是 W 的谱半径（最大特征值）小于 1（原文 p.8）。 回声状态特性与**衰减记忆**（fading memory，Boyd & Chua 1985）本质相同 —— 近期输入相近则输出相近，无论遥远过去如何（原文 p.8）。 LSM 谱系则从脉冲神经元出发：储备池状态 $x^{\text{M}}(t) = (L^{\text{M}}u)(t)$、 读出 $y(t) = f^{\text{M}}(x^{\text{M}}(t))$（原文式(3)(4)，p.8），其中 L^{M} 是把脉冲序列输入 变换为储备池状态的滤波器，f^{M} 是无记忆读出映射 —— 该谱系直接为脑微回路建模而生。 另一条硬件友好的路线是单非线性节点 + 时延反馈：$\dot{x} = F(t, x(t), x(t-\tau))$（原文式(5)，p.12）， 把延迟周期 τ 均分为 N 个虚拟节点（间隔 $\theta \equiv \tau/N$），以时间复用换取空间维度 （原文 p.12–13）—— §5 的光子延迟系统即由此而来。

储备池的四条要求与三类架构。一个物理系统要高效求解计算任务，需满足（原文 p.10–11）： (i) **高维性** —— 把输入映射到高维空间，使原本不可分的输入可分； (ii) **非线性** —— 实现非线性特征映射； (iii) **衰减记忆** —— 状态依赖近期输入而与远期无关； (iv) **分离性** —— 不同输入的响应可分，同时对噪声等非本质扰动不敏感； 参数宜设在混沌转变点附近（edge of chaos）。按架构分三类（原文 p.40–41）： **网络型**（相互作用的非线性元件：人工神经元、振荡器、忆阻元件、光节点、弹簧、生物细胞 —— 易按元件数扩展维度， 但大规模递归互连的制造困难）； **单节点时延型**（避免大规模互连、硬件友好，但延迟环设计不平凡）； **可激发介质型**（利用波的干涉/共振/同步传播，效率潜力最大但计算能力尚未被充分理解）。 按基质分类（动力学模型/电子/光子/自旋/机械/生物）正是本报告 §4–§8 分章逻辑的出处： 机械域中质量–弹簧网络的状态方程 $\dot{x}_1 = x_2,\ \dot{x}_2 = -p(x_1) - q(x_2) + u$ （原文式(10)(11)，p.32；p, q 为弹簧非线性、u 为外力）把柔软机体的复杂动力学「外包」为计算资源 （形态计算，Pfeifer & Bongard 2006）；张拉整体机器人 ReCTeR（24 根被动 + 6 根主动弹簧–缆索）以体传感状态 作储备池控制步态与地形分类；生物域中小脑颗粒层可视为储备池、浦肯野细胞视为读出 （Yamazaki & Tanaka 2007），离体培养细胞 + MEA 构成混合生物–硅计算机（原文 §7–§8）。

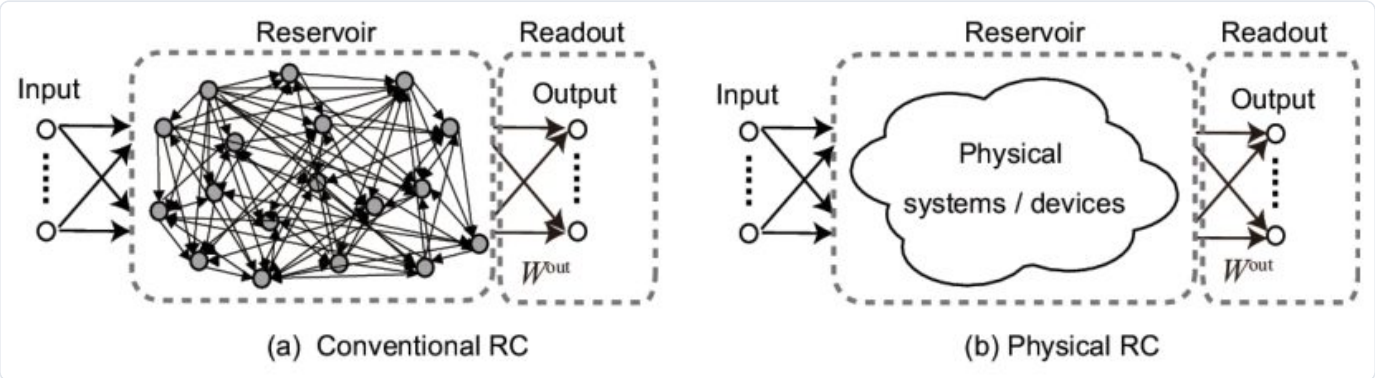


图 8.3 · 储备池计算的统一框架。(a) 常规 RC：固定权重 W^{in}、W 的递归网络作储备池 （全连接节点网络），输出层 W^{out} 是唯一被训练的部分；(b) 物理 RC：储备池整体替换为物理系统/器件 （云图），训练负担同样只落在读出层 W^{out} —— 这一步替换正是「physics for AI」最轻量的入场协议。 图源：Tanaka et al., *Neural Networks* **115**, 100 (2019)，第 6 页图 1 · DOI `10.1016/j.neunet.2019.03.005` 。

性能度量体系。RC 的计算性能按任务用分类精度/预测误差度量；储备池有效性另有两个模型论度量： kernel quality 与泛化能力（Legenstein & Maass 2007；Büssing et al. 2010）； 记忆性能的标准度量是**记忆容量**（memory capacity，MC；Jaeger 2002a）—— 衡量过去的输入信息在储备池动力学中被保留的时间长度（原文 p.42）； 需注意该综述只给出 MC 的文字定义与文献出处，未给出其显式求和公式（**未提供**）。 处理速度、功耗、可扩展性的评估框架见原文 p.41–42。

关键数字：本篇为方法论综述，无器件实验数字 —— 它的贡献是基准任务清单 （口语数字识别、NARMA-10 预测、时序 XOR、记忆容量；原文表 1/2，p.9–11） 与跨基质比较语言（高维性/非线性度/记忆容量），使 §5.4 的 skyrmion 储备池、§6.2 的广播–加权网络、 §8.2 的类器官可放进同一坐标系。

局限（原文结论，p.41–42）。物理 RC 依赖固有动力学、储备池不可训练 —— 性能取决于物理系统 是否「正好合适」；预处理与时空尺度匹配对性能至关重要；储备池优化与可扩展性缺乏系统方法； 即便储备池速度快，整体速度也被软件读出的训练速度限制（出路是物理化读出）； 不同物理 RC 之间就性能/速度/功耗/可扩展性的横向比较为时尚早 —— 本报告对全部基质的「演示级」定级 与 Tanaka2019 的这一自我判断一致。

8.4 本基质的特殊问题

新兴基质：已经站稳的与还欠着的

- **站稳的**：机械计算的功能完备性证明（16 逻辑门 + BNN 等价性 + 机构内自学习，Mei2023）； 储备池范式作为跨基质统一语言（状态方程、只训练读出、记忆容量 —— Tanaka2019）； 生物基质的系统级闭环（HD-MEA 刺激→响应→读出→任务，且学习依赖可塑性有 K252a 对照证据，Cai2023）。 三者的公共结构是：**新基质用储备池协议入场，把训练成本与器件一致性要求压到最低，先证明「能算」再谈「算得好」。**
- **还欠着的**：机械域速度封顶在结构固有频率（kHz 量级）、无统一能耗度量惯例（Mei2023 原文未提供功耗数字）； 生物基质存活期/批次差异/响应漂移 + 独有的伦理维度（类器官智能争论）； Tanaka2019 的自我诊断全部适用 —— 依赖固有动力学、记忆深度受衰减时间限制、停留器件级、缺统一基准。 Alu2025 补上宏观判断：机械智能的各分支（从波计算超材料到气动逻辑）距「取代或增强数字计算」所需的成熟度尚有根本性挑战，当前定位是极端环境下的被动/事件驱动/感算执一体场景，而非通用算力。
- **对本报告的意义**：本章划定了「physics for AI」概念的外边界 —— 一个物理自由度被接纳为计算基质的最低门槛 不是 VMM 吞吐或 TOPS/W，而是：能否在固定动力学中找到高维性、非线性、衰减记忆与分离性四要素，并让唯一的可训练部件（线性读出）落在成熟算法一侧。机械与生物基质恰好从两端测试了这条边界： 机械域用确定性机构补齐了逻辑完备性，生物域用活组织补上了「储备池自身可塑」这半个维度 —— 后者已经越出了 Tanaka2019 框架（储备池固定假设），提示统一框架的下一个扩展方向。

09 横向议题：任务、口径、可靠性与相邻领域的教训

以下议题跨基质才成立，因此集中在一章讨论（仿 Rajak2022 把「应用与对比」独立成章的做法）。

9.1 任务谱系与基准缺失

语料中出现过的任务可以排成一条谱系：**分类**（MNIST / Fashion-MNIST / CIFAR-10（Canadian Institute For Advanced Research 10 类图像数据集）/ 元音 / 人脸）、 **组合优化**（MAX-CUT / 3R3X / TSP / 整数分解）、**时序与感知**（语音识别 / 非线性方程预测 / Lorenz 动力学）、 **科学计算原语**（高斯采样 / 矩阵求逆 / 线性方程）。问题是**同一任务在不同基质上的口径不同**： Niazi2024 的「MNIST 90%」对比对象是同族 RBM 软件基线而非深度学习 SOTA（state of the art，当前最佳水平）； Litvinenko2025 对比表（图 5.5）里的能效数字混合三种口径。Nikhar2024（路径 ④）与 Shastri2021 / Tanaka2019（路径 ③⑤）用几乎相同的措辞抱怨「没有统一基准」—— 在基准出现之前，跨路线的能效/性能比较都应视为营销口径。

9.2 能效口径与「诚实核算」

第 3.3 节的口径规则在各章反复显形，汇总成一句话： **「器件级 → 系统级」的能效落差（2–30×）是本领域最稳定的规律。** 最干净的量化样板是 Ambrogio2023 的自曝（tile 20.0 → 全芯片 6.94 TOPS/W）； 外围电路是落差的主要来源（Jung2022 的供电-精度交换曲线把权衡写成了显式数字）。正向示范是 Melanson2025 —— 在「几乎无人报能效」的概率计算路径里 给出了含 ADC 的端到端核算。评测规范若跟进，双口径披露会从稀缺品变成常规。

9.3 可靠性工程数据

PCM 耐久性、RRAM 电导漂移与 RTN（random-telegraph noise，随机电报噪声）、s-MTJ 翻转率分布随温度/工艺的漂移、类器官存活期 —— 语料中几乎没有跨工艺批次的统计可靠性报告，而这是所有模拟路线走向产品的必经之路（Dieny2020 的工业视角：一致性、耐久性、保持性是产业化关键门槛）。

9.4 来自相邻领域的教训（对照轴的收获）

语料第六轴（11 篇，见姊妹篇第 8 节的逐篇条目）不属于主体，但提供了三面镜子：

- **瓶颈性质对照**：经典物理计算（路径 ①–⑤）的瓶颈是**工程与口径**（外围电路、基准缺失、一致性）； 量子侧的瓶颈是**物理资源**问题 （噪声、电路深度、纠错；Preskill2018 的 NISQ（noisy intermediate-scale quantum，含噪中等规模量子）框架）—— 两者的「距离实用」不在同一个数量级上。
- **可训练性对照**：量子系统的梯度会被噪声淹没（贫瘠高原：McClean2018 → Larocca2025，结构性障碍而非工程瑕疵）； 经典物理系统原则上可以反传（Pai2023 已在光域实验），但「梯度如何穿过不可微分的器件」仍是共同未解题（Momeni2025）。「物理自由度做计算」必须同时回答「可训练性」。
- **口径审查对照**：Tang2021 证明优势可以来自输入/输出假设而非物理本身 —— 这是给路径 ①–⑤ 的通用警报：本综述各章的 「峰值 vs 持续」「实测 vs 外推」「口径提示」都是这一教训在工程层的化身。量子侧用二十年学到的怀疑纪律，经典物理计算现在就该用。 Halverson 讲义（§1.2 的术语邻居）从另一侧佐证同一件事：当物理被严肃地映射进计算（他的 NN-QFT）时，对称性、相互作用、重整化等物理结构会成为可训练性的实际约束 —— 物理结构不是修辞，是有后果的。
- **AI-for-physics 侧的方法论镜像**：Batzner2022（NequIP（E(3)-equivariant graph neural network interatomic potential，E(3) 等变图神经网络原子间势），对称性先验换来最多 3 个数量级数据效率） vs Merchant2023（GNoME（graph networks for materials exploration，图网络材料探索），220 万新结构的规模化）—— 「先验 vs 数据」的张力对物理计算同样成立： 把物理对称性写进器件设计（Feldmann2019 的 PCM 阈值 ≈ ReLU 是个好例子）正是「先验」路线在硬件层的对应物。

10 总结与展望

10.1 已经站稳的结论

1. **三种计算原语都有物理实现，且深度不对称**：P1（线性映射）已到全芯片持续口径（存内、光子）；P2（能量最小化）止步于 100 自旋全可编程（CIM） 与 50 自旋（波层）；P3（采样）的系统级证据全部来自 FPGA 替身，物理器件阵列未兑现。
2. **「器件级 → 系统级」落差 2–30× 是全领域最稳定的规律**，外围电路（ADC/DAC/TDC/反馈）是主要来源 —— 存内与光子两条路径已给出显式量化。
3. **「涨落是资源还是误差」由计算语义决定**：路径 ④ 把热涨落当采样器，路径 ①③ 花大力气抑制它 —— 同一物理事实的两面。
4. **储备池范式是新基质的最小可行闭环**：只训练读出层 —— Tanaka2019 的框架统一了电子、光、自旋、机械、生物五类基质的入门姿势（§8.3）。
5. **训练问题有了三条真实线索**：光域伴随梯度（Pai2023）、硬件采样 + 对比散度（Niazi2024）、芯片在环渐进微调（Wan2022）—— 但「梯度如何穿过不可微物理系统」仍无通用解（Momeni2025）。
6. **跨路线比较在统一基准出现之前不成立**：三篇权威综述与 Nikhar2024 作者立场一致；本综述因此全程不做排名。

10.2 开放问题（未来 3–5 年的看点）

1. **统一评测基准**：跨基质、跨口径的公共任务集 —— 缺它则一切比较失真（§9.1）。
2. **物理 s-MTJ 阵列**：10^6 p-bit @ 1 ns sweep 的投影何时变实物 —— 决定「物理随机性免费」是否成立（§5.1 / §7.2）。
3. **耦合可编程性**：波层 Ising 机需要自己的「测量-反馈」时刻（光学 CIM 已示范该架构，§6.3）；all-to-all 与稀疏并行的矛盾待解（§7.2）。
4. **可级联非线性**：全光神经元的输出常弱于输入（Shastri2021）—— 解决前「全光」只是修辞（§6.5）。
5. **训练的形式化**：梯度如何穿过不可微器件（§3.4）—— 三条线索（伴随法 / 硬件采样 / 芯片在环）之外是否出现第四条。
6. **可靠性工程**：跨批次统计（耐久性、漂移、存活期）—— 所有模拟路线的共同短板（§9.3）。

11 图版来源清单

图号	论文	出处（PDF 页序）	DOI
图 1.1	自绘 SVG（领域总览）		—
图 2.1	自绘 SVG（卷积滑窗算例）		—
图 3.1	自绘 SVG（三种计算原语）		—
图 3.2	自绘 SVG（crossbar VMM 原理）		—
图 4.1	Yao et al., 2020, Nature **577**, 641	第 2 页图	10.1038/s41586-020-1942-4
图 4.2 / 4.3	Wan et al., 2022, Nature **608**, 504	第 3 页图（扩展数据）	10.1038/s41586-022-04992-8
图 4.4	Ambrogio et al., 2023, Nature **620**, 768	第 2 页图	10.1038/s41586-023-06337-5
图 4.5	Jung et al., 2022, Nature **601**, 211	第 3 页图	10.1038/s41586-021-04196-6
图 4.6	Rao et al., 2023, Nature **615**, 823	第 2 页图	10.1038/s41586-023-05759-5
图 5.1	Camsari et al., 2017, Phys. Rev. X **7**, 031014	第 6 页图 4（全图）	10.1103/PhysRevX.7.031014
图 5.2	Borders et al., 2019, Nature **573**, 390	第 2 页图 1	10.1038/s41586-019-1557-9
图 5.3	Kumar et al., 2025, Nat. Phys. **21**, 245	第 2 页图	10.1038/s41567-024-02728-1
图 5.4	Litvinenko et al., 2023, Commun. Phys. **6**, 227	第 3 页图 1	10.1038/s42005-023-01348-0
图 5.5	Litvinenko et al., 2025, Commun. Phys. **8**	第 8 页图	10.1038/s42005-025-01969-7
图 5.6	Prychynenko et al., 2018, Phys. Rev. Applied **9**, 014034	第 3 页图	10.1103/PhysRevApplied.9.014034
图 6.1	Shen et al., 2017, Nat. Photonics **11**, 441	第 3 页图	10.1038/nphoton.2017.93
图 6.2	Pai et al., 2023, Science **380**, 398	第 2 页图 1	10.1126/science.ade8450
图 6.3	Tait et al., 2017, Sci. Rep. **7**, 7430	第 4 页图	10.1038/s41598-017-07754-z
图 6.4	Feldmann et al., 2019, Nature **569**, 208	第 2 页图	10.1038/s41586-019-1157-8
图 6.5	Marandi et al., 2014, Nat. Photonics **8**, 937	第 3 页图	10.1038/nphoton.2014.249
图 6.6	自绘 SVG（测量-反馈 CIM 架构，依 McMahon2016 补充材料描述；原文献 Science **354**, 614）		10.1126/science.aah5178
图 6.7	Hamerly et al., 2019, Phys. Rev. X **9**, 021032	第 2 页图 1	10.1103/PhysRevX.9.021032
图 7.1	Sutton et al., 2017, Sci. Rep. **7**, 44370	第 6 页图	10.1038/srep44370
图 7.2	Nikhar et al., 2024, Nat. Commun. **15**, 8977	第 2 页图 1	10.1038/s41467-024-53270-w
图 7.3	Niazi et al., 2024, Nat. Electron. **7**, 610	第 2 页图	10.1038/s41928-024-01182-4
图 7.4	Melanson et al., 2025, Nat. Commun. **16**, 3757	第 2 页图 1	10.1038/s41467-025-59011-x
图 8.1	Mei & Chen, 2023, Nat. Commun. **14**	第 3 页图	10.1038/s41467-023-40989-1
图 8.2	Cai et al., 2023, Nat. Electron. **6**, 1032	第 2 页图 1（概念面板）	10.1038/s41928-023-01069-w
图 8.3	Tanaka et al., 2019, Neural Networks **115**, 100	第 6 页图 1	10.1016/j.neunet.2019.03.005

> 抽取与核验方法：以 PyMuPDF 定位 PDF 各页内嵌位图（阈值 ≥450×300 px）或矢量图形簇（邻近度聚类），按原位裁剪渲染（170 dpi）； 每幅候选图经人工目检后确定图注 —— 图注只描述画面可见元素。图源 PDF 全部来自语料库 `papers/01–06`（出版社官方版本， 验证管线见姊妹篇第 10 节）。抽取失败的矢量图论文（McMahon2016 正文缺失、其余以自绘 SVG 或文

字叙述覆盖）已在正文注明。 本综述引用的三篇范式参考：Tanaka et al., Neural Networks 115, 100 (2019)（语料内）； Rajak et al., Phil. Trans. R. Soc. A 381, 20210417 (2022)（出版方 PDF，用户提供）； Halverson, "Oxford Lectures on Physics for AI"（2025 讲义，用户提供）—— 仅取其组织思路与术语划界，未纳入 55 篇语料计数。

免责声明与使用说明 —— 本篇是**叙述式文献综述**：理解「物理用于 AI 计算」的文献脉络。 不包含 PI 排名、招生信号、申请建议。所有嵌入图版复制自语料库中的出版社官方 PDF（papers/01–06）， 仅用于学术评述性引用，版权归原出版商，引用请回溯原始文献（DOI 见第 11 节清单）。 文中数字沿用姊妹篇 `physics_for_ai_technical.html` 已核验的口径标注（器件级/单片级/系统级/仿真级/外推/模型预测）， 原文未提供者写「未提供」，不推算、不补全。公式以服务端 KaTeX 渲染为原生 MathML（离线可读）。 第 3 版（2026-09-28）：新增 §2 预备知识章；§4–§8 各代表工作按「动机 → 前驱工作链 → 方法与公式 → 关键数字 → 局限」深读； 全部专业缩写于首次出现处给出全称。第 2 版（2026-09-24）按 Tanaka2019（框架→基质）、 Rajak2022（问题形式化→实现→难题→展望）与 Halverson 讲义（Question→Answer 行文、术语划界）的组织思路重构。