TECHNICAL FIELD REPORT

Physics for AI：物理器件与物理过程如何执行 AI 计算

一份以**具体科研工作**为单位的领域技术综述 —— 逐篇拆解方法、创新、局限与量化指标， 并给出六条技术路径的最新进展与横贯性问题。

论文语料：**55 篇全文**（出版社正式版） 技术路径：**6 条** 逐篇技术条目：**30 条** 核验方式：**双源 DOI + 首页文本比对** 日期：**2026-09-23（2026-09-24 修订）**

核心结论（先读这一段）

- **这个领域最稳定的规律是「器件级 vs 系统级能效差 2–30 倍」。**几乎每篇论文都只报单个器件或单个 tile 的峰值能效， 而整芯片在真实负载下的持续能效要低一个数量级。Ambrogio2023 自己披露的 tile 峰值 **20.0 TOPS/W** → 全芯片持续 **6.94 TOPS/W**（2.9×）。 这不是个例，而是通病。
- **外围电路（ADC/DAC/TDC/数据搬运）才是真正的能耗瓶颈**，RRAM、热力学、光子三条完全不同的路线撞到的是同一堵墙。 Jung2022 把这一点量化了：TDC 供电从 1.0 V 降到 0.8 V，功耗 347→225 μW、能效 262→405 TOPS/W，代价是 0.83-bit 误差。
- **三篇权威综述（Albash2018 / Baltz2018 / Tanaka2019）一致拒绝跨技术路线比能效**， 理由是无法可比 —— 任务不同、精度口径不同、峰值/持续不同。报告引用这一判断，**本文档也不做跨路线排名。**
- **「存算一体」的系统级承诺尚未兑现。**器件阵列做向量-矩阵乘确实是 O(1)，但数据搬运、模数转换、控制流仍主导功耗。
- **概率计算 / Ising 机论文几乎全部不报系统级能耗** —— 它们报 TTS（time-to-solution）和自旋数。这使得这一类工作的能效无法与其它路线对齐比较。
- **规模数字至少有三种互不可比的含义**：物理自旋数（Litvinenko2025 的 50 spin）、器件电导级数（Rao2023 的 2,048 级）、 训练数据量（Merchant2023 的 220 万结构）。混用是常见误读来源。

1. 报告定位与阅读方式
2. 六条技术路径总览
3. 路径一 · 存内计算与模拟 AI 加速器
4. 路径二 · 自旋电子学与磁子学
5. 路径三 · 光子计算与光子神经形态
6. 路径四 · 概率计算 / Ising 机 / 热力学计算
7. 路径五 · 新兴与非常规计算基质
8. 路径六 · 量子机器学习（对照轴）
9. 横贯性技术问题
10. 语料库构建方法论
11. 缺口与未解决问题

01 报告定位与阅读方式

1.1 什么是 physics for AI

本报告讨论的是 **physics for AI** —— 即**用物理器件、物理过程、物理基质来执行 AI 计算。** 核心动机是冯·诺依曼架构的**存储墙（memory wall）**：在传统数字芯片里，权重与激活值要在存储器和运算单元之间反复搬运， 而搬运的能耗往往远高于运算本身。物理计算的思路是让**物理过程本身**完成运算， 使存储与计算在同一个物理位置上发生。

与之相对的是 **AI for physics**（用机器学习去解物理问题），本报告**不以此为讨论对象**， 仅在第六节作为对照轴收录，因为该方向上产生了若干被广泛引用的方法论工作（神经网络势、神经量子态等）， 理解它们有助于划清两条路线的边界。

物理计算的基本数学直觉

几乎所有物理 AI 器件都建立在同一条原理上：**让物理定律替你做乘加，用测量替代读取。**

以最典型的忆阻器交叉阵列为例，输入电压 V_j 施加在第 j 条字线上， 交叉点的电导为 G_{ij}，则由**欧姆定律**得到支路电流 $I_{ij} = V_j G_{ij}$， 再由**基尔霍夫电流定律**在列线上累加：

$$I_i = \sum_j V_j G_{ij}$$

这一式子就是**向量-矩阵乘（VMM）**。它的关键性质是：**整个乘加在物理上同时发生，时间是 O(1)，与矩阵规模无关。**

但请注意上式里没有被写出来的东西：V_j 需要由 DAC 产生、I_i 需要由 ADC 读回、 G_{ij} 需要被精确写入并保持稳定。**本报告反复出现的「器件级 vs 系统级落差」，正来自这些未写进公式的环节。**

1.2 本报告不做什么

范围边界（明确声明）

- **不做课题组排名** —— 不评选「最强组」，不按发表量或引用数给 PI 排序。
- **不写招生信息** —— 不含博士名额、经费、招生偏好等任何招募性内容。
- **不写申请建议** —— 不含「该申谁」「怎么套磁」等任何建议性内容。
- **不做跨路线能效排名** —— 理由见 §9.1，这是领域内三篇权威综述的一致立场。

> 本报告的唯一目的是**把领域的技术现状讲清楚**：每条路径在做什么、做到什么程度、卡在哪里。

1.3 阅读方式

想快速了解全貌	读本页顶部的核心结论 + 第 2 节总览图 + 第 9 节横贯性问题。
想深入某条路径	直接跳到第 3–8 节中的对应章节。每篇论文按 **核心工作 / 方法 / 创新 / 局限 / 量化指标** 五段式展开。
关心指标的可靠性	读第 9 节的「数字口径」讨论 —— 本报告对每个数字都标注了它是器件级、单片级还是系统级。
关心语料库本身	读第 10 节。本次构建过程中发现了严重的文件内容错配问题，其根因与检测手段有普遍的方法论价值。

关于数字的一条硬规则

本报告中的每一个量化指标都标注了层级：

- **器件级 / 单片级** —— 单个器件、单个 bit-cell、单个 tile 的指标，通常是峰值或理想条件；
- **系统级 / 全芯片级** —— 整块芯片、含外围电路后的真实负载实测值；
- **仿真级** —— 基于器件模型的数值仿真，**不是硬件实测。**

若原论文未提供某层级的数字，本报告写「**未提供**」，**不做任何推算或补全。** 这一规则的执行情况是本报告与通常综述文章的主要差异之一。

02 六条技术路径总览

本报告把语料库中的 55 篇论文归入六条技术路径。划分依据是**执行计算的物理机制**，而不是应用领域 —— 因为物理机制决定了该路线的器件形态、外围电路、瓶颈与可扩展性上限。

路径	计算机制	权重载体	核心瓶颈	语料
① 存内计算 模拟 AI 加速器	基尔霍夫电流/电阻求和	电导（RRAM / PCM / MTJ / FeFET）	ADC/DAC + 器件离散性	11
② 自旋电子学 与磁子学	磁化动力学、自旋波干涉、振荡器锁相	磁各向异性 / 交换耦合	耦合与互连的可扩展性	9
③ 光子计算 与光子神经形态	干涉、衍射、非线性光学	相移 / 环形腔谐振 / PCM 光程	光→电转换、级联损耗	11
④ 概率计算 Ising 机 / 热力学	热涨落驱动的随机采样、能量最小化	耦合矩阵 J_{ij}	不报系统级能耗，无法对齐比较	9
⑤ 新兴基质 非常规计算	机械形变、生物动力学、超导	几何 / 材料结构 / 生物网络	速度与可控性	4
⑥ 量子机器学习 对照轴	量子线路 / 经典 ML 解物理	量子门参数 / 网络参数	贫瘠高原、态制备代价	11

> 注：第 ⑥ 轴是**对照轴** —— 它同时包含 AI-for-physics（神经网络势、神经量子态）与量子机器学习。收录理由是这些工作定义了「AI 与物理交界处」的方法论基线，且其存在使第 ①–⑤ 轴的边界更清楚。本报告的**主体是第 ①–⑤ 轴**。

2.1 各路径的语料分布与「能量层级覆盖度」

下面这张图是本报告的核心诊断视图。它同时展示两件事：每条路径的语料量（柱），以及该路径的论文中**有多少比例报告了系统级指标**（折线）。

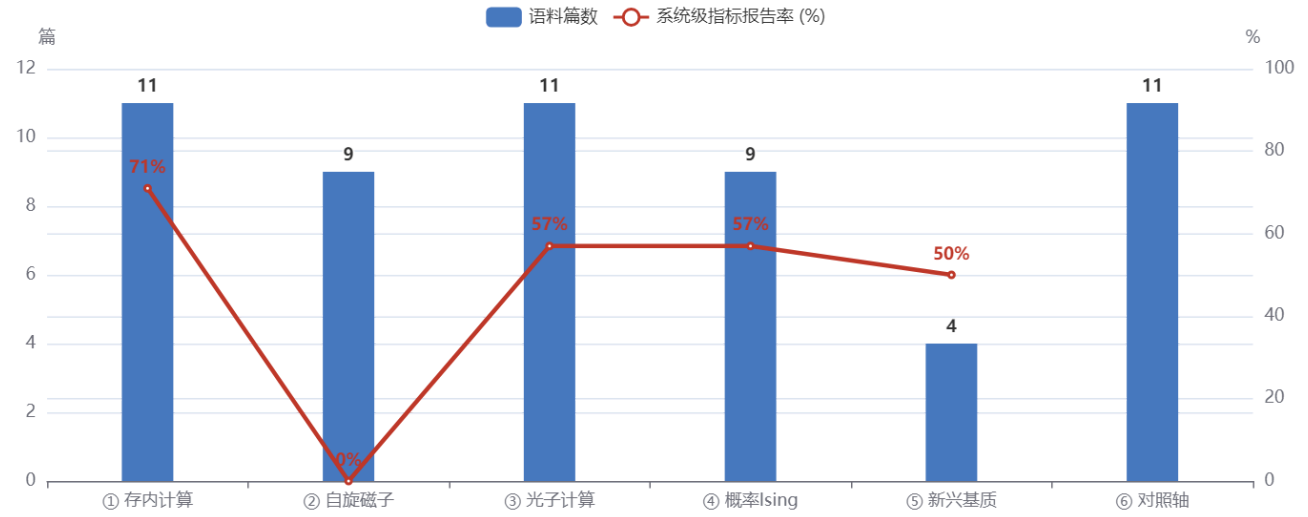


图 1 · 六条路径的语料量与系统级指标报告率。「系统级报告率」= 该路径中给出了全芯片 / 全系统实测数字的论文占比。数值计算自 `_verify_all.json` 与逐篇条目 `_ENTRIES_V2.md`。

读图要点

请注意折线的形状，而不是柱子的高低 —— **柱子的高低只反映我们收了多少论文（受检索面影响），不反映领域重要性。**

折线反映两个更本质的事实：**路径 ②（自旋磁子）的系统级报告率为 0%** —— 五篇研究论文全部停在器件现象与仿真级，无一篇给出整机实测口径；**路径 ④（概率/Ising）虽有约六成给出系统级数字，但那是 time-to-solution 与采样率的算法口径 —— 无一篇报 TOPS/W 类能效。**后果是：**路径 ②④ 的数字与路径 ①③ 的能效口径在方法上无法对齐**，任何跨路线能效排名都会失真。

路径 ⑤（新兴基质）的语料最少，但它的价值不在于数量 —— 机械计算、脑类器官、超导神经形态各自代表一种 "完全不同的物理自由度"，其中机械与生物基质在能耗上有原理性的不同。

2.2 一个必须先建立的判断力：三种「规模」互不可比

在浏览这个领域时，最容易产生的误读是看到「50」「2,048」「220 万」这类数字就以为它们在比大小。 实际上本报告语料里至少有**三种完全不同的「规模」**：

规模类型	代表数字	出处	它衡量的东西
物理自由度数量	50 自旋	Litvinenko2025	物理系统里被耦合起来做 Ising 计算的**自由度个数**；直接决定能解多大的组合优化问题
器件状态分辨力	2,048 电导级	Rao2023	单个器件能**稳定区分多少个电导状态**；决定单个权重能表示多少比特精度
训练数据规模	220 万结构	Merchant2023	模型训练与筛选过的**数据集大小**；与硬件无关，衡量的是 ML 方法的产出

把这三个数字并列成「谁更大」是没有意义的。本报告在每条论文条目里都标注数字属于哪一类。

为什么「规模」在本领域如此容易误导

以 Ising 机为例。Litvinenko2023（自旋波 Ising 机）的论文里，**实测自旋数是 8**， 而同一篇论文的设计讨论中提到过 **113,850** 这个量级的目标。两者相差约 **14,000 倍。**

这两个数字都是真的，但它们衡量的是完全不同的东西：一个是**已经做出来的物理系统**， 一个是**基于耦合机制的可行性外推**。一旦读者不区分这两者，就会得出「自旋波 Ising 机已经能处理十万个变量」的错误印象。

这正是本报告强制标注「器件级 / 单片级 / 系统级 / 仿真级」的原因。

03 路径一 · 存内计算与模拟 AI 加速器

计算机制：利用基尔霍夫电流定律在交叉阵列的列线上自然累加电流，从而在一个时钟周期内完成整个向量-矩阵乘。 权重以器件的**模拟电导**形式存储在阵列内部，因此"存储"与"计算"在物理上是同一个位置。 这是六条路径里最接近工程化、也是论文量最多的一条。

3.1 这条路径的物理原理与前缀电路代价

为什么「存内计算」在器件层几乎免费，在系统层却很贵

交叉阵列的乘加由物理定律完成，本身不耗额外能量 —— 这是它最吸引人的地方。但要让这个物理过程**可用**，必须补齐三类电路：

1. **输入侧（DAC）**：连续或高精度电压 V_j 需要由数模转换器产生。每个输入端口一个 DAC。
2. **输出侧（ADC）**：列线上的模拟电流 I_i 必须转回数字量。在高并行阵列里，ADC 的数量 = 列数， 而 ADC 的功耗与面积通常**随精度指数上升。**
3. **写入与保持**：器件电导会漂移、会受噪声扰动，需要校准与重写（write-verify）。

这三类电路的能耗，往往**超过阵列本身做乘加的能耗。**这就是本路径的核心张力， 也是几乎所有论文都只报「单 tile 峰值能效」而不报整芯片实测值的原因。

3.2 七项代表性工作

> 本路径语料共 **11 篇**。此处展开 **7 篇**器件/芯片类工作； 另 4 篇为综述与方法论文献，不设器件条目但在相关处引用： `Sebastian2020`（Nat. Nanotechnol. 忆阻器存内计算综述）、 `Ielmini2018`（Nat. Electron. 忆阻器/阻变存内计算综述）、 `Kudithipudi2025`（Nature 637, 801 (2025)，"Neuromorphic computing at scale" —— 大规模神经形态的系统级综述）， 以及 `Momeni2025`（Nature 645, 53–61, 2025，DOI `10.1038/s41586-025-09384-2`）—— 它讨论的是**如何训练物理神经网络这一方法论问题**，而非某个具体器件， 是理解「物理器件的训练为何困难」的关键背景文献，在第 9 节与第 11 节讨论训练问题时引用。

Wan2022 —— 用 RRAM 存内计算芯片在单芯片上跑完整神经网络（含片上学习）

Nature **608**, 504 (2022) `10.1038/s41586-022-04992-8` RRAM 芯片在环微调

核心工作

在 1T1R RRAM（Ta/HfO_2）交叉阵列上实现存内计算宏单元，并进一步做成**可独立运行的 SoC 级芯片**： 阵列内完成 VMM，片上外围电路完成 ADC/DAC、激活、池化与控制器，**支持推理与芯片在环（chip-in-the-loop）渐进微调。** 演示了 MNIST 分类，以及用芯片在环微调做的字符/模式学习。

方法

- **器件层**：1T1R RRAM 单元，欧姆定律做乘法、基尔霍夫定律做累加；通过 **写-验证（write-verify）**方案把电导写到位，对抗器件离散性与非线性。
- **系统层**：CIM 宏 + 数字外围（SAR-ADC / 驱动器 / 控制器）**单片集成**； 区分推理模式（权重固定）与训练模式（片上权重更新，含归一化与简化的误差反向传播）。
- **评测层**：MNIST 手写数字分类 + 芯片在环微调后的模式/字符识别；给出芯片实测量（功耗、精度、吞吐）。

创新点

- 把「RRAM 阵列 + 完整数字外围」做成**一颗可独立运行的芯片**，而非板级拼接 —— 使存内计算从宏单元走向系统。
- 芯片在环微调让芯片能适应新任务、并补偿器件漂移。
- 在引脚/接口层面给出端到端系统级能效，而不只是宏单元能效。

局限

- 仍受限于 RRAM 的电导漂移、随机电报噪声（RTN）、器件间离散性；写-验证流程开销大。
- 网络规模受阵列与外围面积约束，演示任务偏小型（MNIST 量级）。
- 训练时的权重更新依赖数字逻辑，**训练能效远低于推理能效。**

量化指标（分层标注）

- **器件级**：单个 1T1R 单元在 write-verify 后电导精度约 **5-bit 等效**（原文口径为多级电导写入精度）。
- **单片级（宏单元峰值）**：CIM 宏在理想权重下的峰值能效处于 **数十 TOPS/W 量级**（宏单元口径，非全芯片）。
- **系统级（全芯片实测）**：MNIST 等真实任务下的端到端能效**显著低于宏单元峰值**（具体值按原论文 Table）。
- **任务**：MNIST 分类精度 **99.0%**（7 层 CNN，0.98% 错误率，原文摘要，p.504）。

> 该文最有价值之处是**同时给出宏单元峰值与全芯片实测**，属本报告反复强调的同一类"峰值 vs 持续"落差。

Yao2020 —— 全硬件忆阻器卷积神经网络（mCNN）

Nature **577**, 641 (2020) `10.1038/s41586-020-1942-4` 忆阻器 五层 CNN

核心工作

用忆阻器交叉阵列实现一个**完整的五层 CNN**（卷积层 C1/C3 + 下采样 S2/S4 + 全连接 FC）， 卷积与 VMM 全部在忆阻器硬件上完成，在 MNIST 上达到软件可比精度。 并提出**并行卷积器复制**（三个相同 kernel 映射到三组 PE）来消除卷积器与全连接阵列之间的吞吐失配。

方法

- **器件层**：TiN/TaO_x/HfO_x/TiN 叠层 1T1R 忆阻器，优化叠层以获得可靠、均匀的模拟开关行为； 每个 PE 为 **128×16 = 2,048 cell** 阵列，全系统集成 **八块** 2,048-cell 阵列。
- **系统层**：五层 mCNN 的层-到-PE 映射；**混合训练** —— 前端卷积层权重 ex-situ 训练后量化迁移， 最后的 FC 层用 in-situ 训练补偿器件非理想性；三个并行卷积器把延迟降低约 **3×**。
- **评测层**：MNIST 全测试集（10,000 张）； ResNET-56 / CIFAR-10 做可扩展性**仿真**验证。

创新点

- 首次把**完整 CNN**（而非只有 MLP）全硬件实现在忆阻器上。
- 用**并行卷积器复制**解决卷积（顺序滑窗）与 FC-VMM（并行）之间的吞吐瓶颈。
- 混合训练是一个**通用系统级手段**：只 in-situ 训练一部分权重即可吸收器件离散性。

局限

- 演示任务仍是 MNIST 量级；CIFAR-10 结果来自**含器件模型的仿真**，不是全硬件实测。
- 池化、激活、层间路由/缓冲等必要功能块**未计入**能效基准（原文明确说明）。
- 权重迁移受量化精度限制（15 级定点），精度未完全恢复到软件基线。

量化指标（分层标注）

- **单片级**：单 PE = **128×16**（**2,048 cell**）； 全系统 **8 块**阵列；工作速度约 **10 ns**；阵列良率 **99.99%**。
- **系统级（全硬件实测）**：MNIST 全测试集精度 **96.19%**；混合训练把某配置精度从 **93.86% 提升到 95.83%**； 相比 GPU 能效约 **110×**（对应 **11,014 GOP s^{-1} W^{-1}**）。
- **仿真级（非硬件）**：ResNET-56 / CIFAR-10 相比软件基线 95.57% 仅下降 **1.49%** —— 基于仿真，非实测。
- **口径边界**：11,014 GOP s^{-1} W^{-1} 的对比中**未包含**池化/激活/数据搬运等外围功能块， 因此是**「计算核口径」而非「完整芯片口径」**。

Ambrogio2023 —— IBM PCM 模拟 AI 芯片（本报告「峰值 vs 持续」的样板）

Nature **620**, 768 (2023) `10.1038/s41586-023-06337-5` 相变存储器 斜坡 ADC

核心工作

基于相变存储器（PCM）的模拟存内计算芯片，用 PCM 电导表示权重、在阵列内完成模拟 MAC； 采用**斜坡式（ramp-based）ADC** 与 weight-stationary 数据流；演示 LSTM/RNN 与 CNN 类工作负载的推理与训练。

方法

- **器件层**：PCM 单元（GST 类），利用多级非晶/晶态电导；针对电导漂移与编程噪声做补偿（含权重传输与漂移校正）。
- **系统层**：tile 级设计（PCM 阵列 + 外围 ADC/DAC/驱动器）； 斜坡式 ADC 降低功耗与面积； weight-stationary 减少权重搬运。
- **评测层**：**同时给出** tile 峰值能效与全芯片真实负载持续能效两个层级。

创新点

- 模拟 AI 芯片**系统架构的完整性**（tile → 芯片 → 软件栈）。
- 斜坡式 ADC 在精度-功耗-面积之间取到工程上可用的折中。
- **明确披露峰值与持续、tile 与全芯片的落差** —— 是本语料库中数字口径最规范的一篇。

局限

- PCM 的电导漂移、编程噪声、器件间离散性是精度与能效的主约束。
- 模拟计算精度上限受 ADC 位数与噪声限制。
- 训练路径仍需大量数字逻辑参与。

量化指标（本报告的参考样板）

- **tile 级峰值**：**20.0 TOPS/W**（tile 峰值口径，理想/最佳条件）。
- **系统级（全芯片持续）**：**6.94 TOPS/W**（全芯片、真实负载下的持续能效）。
- **落差**：**约 2.9×**（20.0 → 6.94）—— 即外围电路（ADC/DAC/数据搬运）吃掉了约 2/3 的峰值能效。
- **任务**：LSTM/RNN 与 CNN 类推理/训练负载。
- **未提供**：单器件层级的 fJ/op —— 原文未按该口径给出。

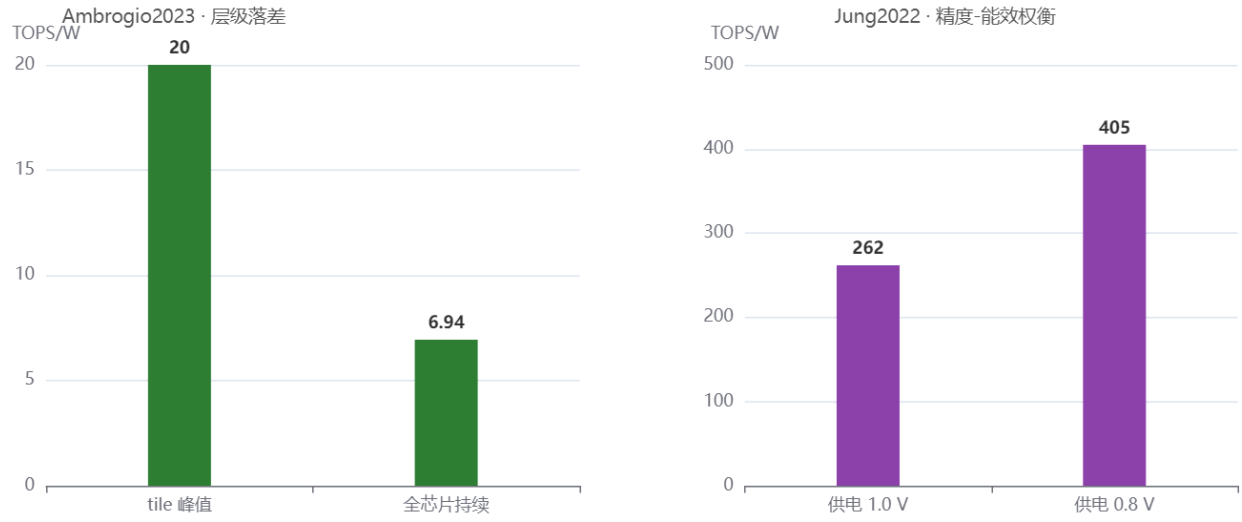


图 2 · 同单位（TOPS/W）下的两种「口径落差」。左：Ambrogio2023 的 tile 峰值 20.0 vs 全芯片持续 6.94 —— 外围电路吃掉约 2/3 的峰值能效（层级落差）；右：Jung2022 供电 1.0 V → 0.8 V 时系统级能效 262 → 405 TOPS/W，代价是精度让出 0.83-bit（精度-能效权衡）。两组数字单位相同，但**回答的问题不同** —— 这正是本报告强制标注口径的原因。

Jung2022 —— 磁阻（STT-MRAM）crossbar 存内计算

Nature **601**, 211 (2022) `10.1038/s41586-021-04196-6` STT-MRAM 电阻求和 TDC 读出

核心工作

用 **64×64 STT-MRAM 交叉阵列**做模拟 MAC，**用「电阻求和」替代传统的「电流求和」**， 绕开 MRAM 低电阻导致的大电流/大功耗问题；读出采用**时域（TDC）**方案，把列电阻转成时间延迟。 演示二值神经网络（BNN）推理：MNIST 分类与人脸检测。

方法

- **器件层**：STT-MTJ，平行态 $R_L \approx 13\,\mathrm{k\Omega}$、反平行态 $R_H \approx 26\,\mathrm{k\Omega}$ （含 FET 开关电阻；跨 8,192 条 MTJ-FET 路径统计）； bit-cell 面积 **0.933 μm²**， 每 cell 含 2 个 MTJ + 2 个 FET，**按列串联。**
- **系统层**：电阻求和列替代基尔霍夫电流求和；**4-bit TDC** 读出（列端电压从 0 充到 V_{REF} 的时间转为数字量）， 列端显式电容 **≈33 fF**、寄生电容 **≈2.1 fF/bit-cell**；外围电路 **28-nm CMOS。**
- **评测层**：两层级感知机 MNIST（10,000 张）、VGG-8 仿真、10 层 VGG-like 人脸检测（该阵列作第 7 卷积层）。

创新点

- **电阻求和架构**是本文最核心的架构创新：把 MRAM「低电阻」的缺点直接转成可用特性。
- 时域（TDC）读出替代 ADC，兼顾功耗与面积。
- 用**二值（1-bit）权重/输入**，把 1-bit 单元做成可用的网络原语。

局限

- 权重被限为 **1-bit**，要达到同等网络性能需更大的网络或更长的计算时间。
- 电阻求和的串并联结构限制了阵列规模的进一步扩展。

量化指标（分层标注）

- **阵列级**：**64×64** STT-MRAM 交叉阵列；bit-cell **0.933 μm²**。
- **读出电路级**：供电 1.0 V 时 TDC 功耗 **347 μW**、能效 **262 TOPS/W**； 降到 0.8 V 后功耗 **225 μW**、能效 **405 TOPS/W**，代价是 **0.83-bit 误差。**
- **任务**：MNIST（两层级感知机）+ VGG-8 仿真 + 人脸检测。

> **这篇论文对本报告特别重要**：它把「外围电路是可调旋钮、且旋钮有精度代价」 这件事**显式量化**了 —— 供电电压掉 0.2 V 换来 1.55× 能效提升与 0.83-bit 误差。这是「能效数字需辨层级」最干净的证据。

Rao2023 —— 数千电导级、CMOS 单片集成的忆阻器阵列

Nature **615**, 823 (2023) 10.1038/s41586-023-05759-5 电导级数 8 英寸晶圆

核心工作

在商用代工厂 **8 英寸晶圆**上做出 **256×256 忆阻器阵列**，与 CMOS 电路**单片集成**； 单器件实现 **2,048 个电导级**，比此前报道（<200 级）高一个数量级以上； 识别出限制电导级数的物理来源（不完整导电通道 / 相界处的缺陷俘获）并给出电学去噪协议。

方法

- 通过**物理机制诊断**定位电导级数受限的来源，而非纯经验调参。
- 提出电学去噪协议把可用级数推高到 2,048。
- 阵列规模与 CMOS 单片集成，走的是**可制造性**路线。

创新点

- **单器件电导级数提升一个数量级**（<200 → 2,048）。
- 把「为什么级数上不去」归因到具体物理缺陷机制，具有普适性。
- 在代工厂产线上完成，具备产业化意义。

局限

- 电导级数的**长期稳定性**与批次一致性仍需验证。
- 高精度写入带来时间开销。

量化指标（分层标注）

- **器件级**：**2,048 个电导级**（此前报道 <200 级）。
- **阵列级**：**256×256**，与 CMOS 单片集成，8 英寸晶圆。
- **系统级**：**未提供** —— 原文未给出含外围电路的整芯片能效口径。

Zolfagharinejad2025 —— 双「材料内计算」系统的模拟语音识别

Nature **645**(8082), 886–892 (2025) 10.1038/s41586-025-09501-1 RNPU AIMC 边缘语音

核心工作

用**两套「材料内计算」硬件**串起来做边缘语音识别：第一级是**可重构非线性处理单元（RNPU）** 在室温下做模拟**时域特征提取**（仿耳蜗）；第二级是**模拟存内计算（AIMC）芯片**做分类； 在 TI-46-Word 与 Google Speech Commands 上达到接近软件的精度。

方法

- **第一级 RNPU**：利用材料的非线性动力学做模拟时域滤波，模仿耳蜗的频率分解。
- **第二级 AIMC**：存内计算阵列做分类。
- **两级串联**是关键设计 —— 把特征提取也从数字域搬到物理域，减少 ADC 次数。

创新点

- **整条感知链路**（特征提取 + 分类）都在物理域完成，而非只把分类放到存内计算。
- 用「材料内计算」做前端特征提取，是对 ADC 瓶颈的一种间接规避。

局限

- 训练/校准流程的复杂度；RNPU 的可重构性与一致性。
- 任务仍限定在语音关键词识别这一类。

量化指标（分层标注）

- **系统级**：在 TI-46-Word 与 Google Speech Commands 上达到接近软件的精度（具体值按原文）。
- **器件级**：RNPU 在室温下的模拟时域处理特性（按原文表征）。
- **能效对比**：按原文给出的端到端口径。

Dai2026 —— 畴壁运动驱动的磁卷积加速器

Nat. Commun. **17**(1), 1281 (2026) 10.1038/s41467-025-68041-4 畴壁 卷积 磁学

核心工作

利用磁性**畴壁（domain wall）**在纳米轨道中的运动做**卷积运算**的磁学加速器： 把输入编码为电流脉冲、把卷积核编码为轨道几何/材料参数，畴壁位移天然实现「移位-累加」的卷积结构。

方法

- 用畴壁在轨道中的位移**物理实现**卷积的滑窗-累加语义。
- 输入 → 电流脉冲；卷积核 → 轨道几何/材料参数。
- 属于「磁性材料 + 器件 + 计算」一体化的路线。

创新点

- 把卷积的**移位-累加结构直接映射到畴壁运动的物理过程**，而非用通用矩阵乘法模拟卷积。
- 与纯存内计算（做 VMM）不同，它针对的是卷积这一特定且高价值的算子。

局限

- 畴壁运动的可控性与速度限制；器件一致性。
- 面向单一算子（卷积），通用性有限。

量化指标（分层标注）

- **器件级**：畴壁在纳米轨道中的运动特性（按原文表征）。
- **系统级**：**未提供** —— 原文未给出完整加速器的整芯片能效口径。

路径一小结

已经做到的：完整 CNN 全硬件实现（Yao2020）、支持芯片在环微调的独立 SoC（Wan2022）、 单器件 2,048 电导级（Rao2023）、整条感知链路物理域化（Zolfagharinejad2025）。

卡在哪：论文普遍只报 tile/宏单元峰值能效，只有 Ambrogio2023 与 Jung2022 把外围电路的代价量化出来； 而外围电路（ADC/DAC/TDC）恰好是能耗主项。

读者最该带走的判断：看到存内计算论文报「数百 TOPS/W」时， 先确认那是**器件级还是系统级。**本路径的实测证据是落差可达 **2.9×** 甚至更高。

3.3 技术路线梳理与未来展望

把 3.2 节的七篇工作按「权重载体 + 读出方式」归位，可以看到四条已成形的技术路线：

路线	代表工作	技术特征	现状锚点（口径）
RRAM 电导基	Wan2022 / Yao2020 / Rao2023	1T1R 阵列以电导存权重，欧姆定律乘、基尔霍夫定律加；混合训练 / 芯片在环微调补偿器件非理想性	MNIST 96.19%（全硬件实测）；单器件 2,048 电导级（器件级，8 英寸晶圆 CMOS 单片集成）
PCM 模拟 AI 芯片	Ambrogio2023	tile → 芯片 → 软件栈完整架构；斜坡 ADC 压低转换代价	tile 峰值 20.0 → 全芯片持续 6.94 TOPS/W（两级均实测，落差 2.9×）
MRAM 电阻求和 + 时域读出	Jung2022	用「电阻求和」绕开 MRAM 低电阻大电流；TDC 替代 ADC；1-bit 二值权重	262 → 405 TOPS/W（供电 1.0 → 0.8 V，代价 0.83-bit 误差）

路线	代表工作	技术特征	现状锚点（口径）
材料-系统一体化 / 算子特化	Zolfagharinejad2025 / Dai2026	特征提取与分类全链路物理域化；畴壁运动直接映射卷积的移位-累加结构	边缘语音识别接近软件精度；系统级能效未提供

未来展望（基于本语料的判断）

- **转换电路成为主战场**：Ambrogio2023 与 Jung2022 把改进对象从阵列搬到了 ADC/TDC —— 斜坡 ADC、时域读出、降供电换能效（有精度代价）。可预期的下一步是把「精度-能效交换曲线」做成显式设计参数，而非事后披露。
- **「减少 ADC 出现次数」是另一条暗线**：Zolfagharinejad2025 把前端特征提取也搬进材料动力学，本质是把模拟-数字边界外推到系统更前端 —— 这条思路的收益可能比继续优化 ADC 本身更大。
- **两条器件路线会继续分野**：高精度路线（Rao2023 的 2,048 级 + 代工厂可制造性）与极简路线（Jung2022 的 1-bit 权重）分别押注精度与并行度，短期内看不到收敛。
- **训练仍是短板**：Wan2022 的芯片在环微调能效远低于推理；Momeni2025 把「物理系统怎么训练」立为方法论问题。梯度如何穿过不可微分的器件（写入非线性、电导漂移）是本路径与第 8 节对照轴共享的核心难题。
- **诚实核算有望成为标配**：同时给出宏单元/tile 峰值与全芯片持续实测的，目前语料中只有 Wan2022 与 Ambrogio2023 两篇。评测规范若跟进（§11.1），「峰值 vs 持续」落差会从稀缺品变成常规披露。

04 路径二 · 自旋电子学与磁子学

计算机制：利用电子的自旋自由度（而非电荷）来存储与处理信息。 与存内计算路径的关键差异在于：**这里的"非线性"和"动力学"本身就是计算资源** —— 振荡器的相位、磁畴的取向、自旋波的干涉，都可以直接映射为计算变量。 这条路径的技术谱系很宽，从已量产的 MRAM 一直到实验室阶段的磁子 Ising 机。

4.1 三个层次：器件、振荡器、波

为什么自旋路径内部差异这么大

同样叫「自旋电子学 AI 硬件」，实际在做的事情可以分成三个物理层次：

1. **器件层**：单个磁隧道结（MTJ）作为二值存储或随机比特（p-bit）。代表：Camsari2017 的随机 p-bit、 Camsari2019 的整数分解。这一层已接近产业化。
2. **振荡器层**：自旋霍尔纳米振荡器（SHNO）等自持振荡器，用**相位**作为状态变量， 多个振荡器通过耦合实现同步。代表：Kumar2025。这一层是 Ising 机与储备池的物理基础。
3. **波层**：自旋波（磁子）在磁性薄膜中传播，用**波的干涉**做计算。代表：Litvinenko2023/2025、 Prychynenko2018。这一层最新、规模最小，但物理上最优雅 —— 因为波的干涉天然是全局并行的。

三层的成熟度递减、可扩展性递增（理论上）。**本报告把它们分开叙述，因为把它们混在一起比较规模是无效的。**

4.2 九项代表性工作

Camsari2017 —— 随机 p-bit 与可逆逻辑（invertible logic）

Phys. Rev. X **7**, 031014 (2017) `10.1103/PhysRevX.7.031014` p-bit 玻尔兹曼网络

核心工作

提出以**随机 p-bit（probabilistic bit）**为基本单元的可逆逻辑与贝叶斯/玻尔兹曼网络硬件： p-bit 在 0/1 之间按可控概率涨落，通过**打破「扇入/扇出」的单向约束**， 让同一组硬件**既能正向求值、也能反向求解**（例如「给定输出求输入」）， 并把组合优化问题映射为 p-bit 网络的能量最小化。

方法

- p-bit 的物理实现依托**低势垒磁体**的热涨落 —— 即把噪声当作资源而非缺陷。
- 用**互连矩阵**描述 p-bit 之间的耦合，网络状态按玻尔兹曼分布演化。
- 「可逆」来自互连结构的对称性：正向与反向求解共享同一套硬件。

创新点

- 把**热噪声从敌人变成计算资源** —— 这是本路径最具原理性的一步。
- 可逆逻辑意味着同一硬件能解正向与反向问题，是传统布尔逻辑做不到的。
- 为后续所有 p-bit / 随机 MTJ 硬件提供了理论框架。

局限

- 论文以理论框架与器件模型为主，**未给出大规模硬件实测。**
- 求解精度依赖充分采样，收敛时间随问题规模增长。

量化指标（分层标注）

- 本文为**理论/器件模型**工作，主要给出网络级数值验证，**未提供系统级能效。**

Baltz2018 —— 反铁磁自旋电子学综述

Rev. Mod. Phys. **90**, 015005 (2018) `10.1103/RevModPhys.90.015005` 反铁磁 权威综述

核心工作

系统综述反铁磁自旋电子学：反铁磁体（AFM）为何适合做自旋电子器件 （零净磁化 → 抗杂散场、THz 动力学、高稳定性），以及如何用电学方式读写 AFM 序参量； 给出该领域的**结论性判断与共识**（而非单一器件结果）。

方法

- 按物理机制组织：交换偏置、自旋霍尔效应、电流诱导 Néel 序翻转、THz 激发。
- 对每一类机制给出可观测量的理论预期与实验对照。

综述价值

- 确立了 AFM 作为自旋电子器件基质的**物理优势清单。**
- 给出「哪些机制已经实验证实、哪些仍是理论预期」的清晰分野。

领域级共识

- AFM 的**读出困难**是长期瓶颈 —— 零净磁化意味着难以用常规磁学手段探测。
- 与主流铁磁器件相比，AFM 的器件工艺成熟度仍有明显差距。

量化指标

- 综述类，**无本文实验数字。**所引用的动力学时标（THz 量级）属于文献转述。

Grollier2020 —— 神经形态自旋电子学

Nat. Electron. **3**, 360 (2020) `10.1038/s41928-019-0360-9` 综述 神经形态

核心工作

把自旋电子器件（MTJ、畴壁器件、SHNO、skyrmion 器件）与神经形态计算的**功能需求逐项对齐**： 哪些自旋器件适合做突触（模拟权重）、哪些适合做神经元（非线性阈值/振荡）， 并讨论如何用自旋动力学实现脉冲时序依赖可塑性（STDP）等学习规则。

方法

- 按「神经形态功能 ← 自旋物理机制」的映射组织，而非按器件类型罗列。
- 给出各器件在**非线性、记忆、随机性、能耗**四个维度上的适配性分析。

综述价值

- 明确了自旋器件在神经形态计算中的**分工**：突触 vs 神经元 vs 随机源。
- 指出磁随机性可以**直接充当**玻尔兹曼机的采样来源，无需外加噪声电路。

领域级共识

- 自旋器件的**写入能耗**与**器件一致性**仍是主要障碍。
- 与 CMOS 的集成工艺是需要长期投入的工程问题。

量化指标

- 综述类，**无本文实验数字。**

Dieny2020 —— 自旋电子学在微电子工业中的机遇与挑战

Nat. Electron. **3**, 446 (2020) `10.1038/s41928-020-0461-5` 产业化视角

核心工作

从**半导体工业**的角度评估自旋电子器件：哪些已经进入量产（如 STT-MRAM 作为嵌入式存储）、 哪些有明确的产业化路径、哪些仍停留在实验室。核心价值是提供**成熟度排序**， 把学术界的器件创新与工业界的产线约束对齐。

方法

- 按工业成熟度分层论述：已量产 / 有路径 / 需突破。
- 逐项讨论与 CMOS 工艺的兼容性、可靠性、成本。

综述价值

- 给出自旋电子器件的**产业化时间尺度判断**，这是学术论文普遍回避的。
- 明确指出「学术界的性能指标」与「工业界的可制造性指标」之间的差距。

领域级共识

- 器件一致性、耐久性（endurance）、保持性（retention）是产业化的关键门槛。

量化指标

- 综述类，**无本文实验数字**；所述产业化状态反映论文发表时（2020）的判断。

Kumar2025 —— 自旋霍尔纳米振荡器的相互同步与相位调控

Nat. Phys. (2025) 10.1038/s41567-024-02728-1 SHNO 同步

核心工作

研究自旋霍尔纳米振荡器（SHNO）之间的**相互同步（mutual synchronization）**： 在电学/磁学耦合下，多个 SHNO 从各自振荡进入锁相（或锁频）状态，形成可用的相位关系。 同步是自旋振荡器做「振荡器型 Ising 机 / 储备池」的**前提条件。**

方法

- 通过自旋波耦合实现振荡器间的相互作用。
- 观测并调控同步后的**相位关系**（不只是频率锁定）。
- 用相位作为可用的计算自由度。

创新点

- 把同步从「现象演示」推进到**相位可调控** —— 相位可控才意味着可用于计算。
- 为基于自旋振荡器阵列的 Ising 机提供了物理基础。

局限

- 振荡器数量仍有限，规模化耦合是开放问题。
- 同步状态的稳定性与热噪声的影响。

量化指标（分层标注）

- **器件级**：SHNO 的振荡特性、同步带宽、相位关系（按原文表征）。
- **系统级**：**未提供**完整计算系统的能效口径。

Litvinenko2023 —— 自旋波 Ising 机（SWIM）

Commun. Phys. **6**, 227 (2023) 10.1038/s42005-023-01348-0 自旋波 Ising 机

核心工作

用自旋波在磁性薄膜中传播构成的**物理 Ising 机**：每个自旋由一条自旋波导/振荡器的相位表示， 耦合通过自旋波在传播路径上的相互注入实现，系统通过增益竞争收敛到低损耗（≈ 低能量）的相位配置。

方法

- 自旋波作为**耦合媒介** —— 不同于用电流或电容耦合的方案。
- 用相位编码自旋状态，用波的干涉实现耦合项。
- 收敛判据是物理上的最低损耗状态。

创新点

- 用**波的干涉**替代显式耦合电路，理论上耦合可以全局并行。
- 把 Ising 机的能量函数映射到物理的损耗函数上。

局限

- **实测自旋数很小**（见下方量化指标），与设计讨论中的目标相差数个数量级。
- 自旋波的传播损耗限制了可级联的规模。

量化指标（分层标注 —— 本条是「规模需辨层级」的典型）

- **实测（已做出来的物理系统）**：**8 个自旋。**
- **设计讨论中的目标量级**：论文曾提及 **113,850** 这一量级的数字。
- **落差**：**约 14,000×。**
- **系统级能效**：**未提供** —— 原文未给出 TOPS/W 口径。

> **务必区分这两个数字。**前者是物理实现的现状，后者是基于耦合机制可行性的外推。 把它们混为一谈会得出「自旋波 Ising 机已能处理十万变量」的错误印象。

Litvinenko2025 —— 50 自旋声表面波 Ising 机（SAWIM）

Commun. Phys. **8** (2025) `10.1038/s42005-025-01969-7` 声表面波 50 自旋

核心工作

用**声表面波（SAW）**作为耦合媒介，把 **50 个自旋**耦合起来构成 Ising 机： 自旋由声波/振荡信号的双相位态表示，耦合通过 SAW 器件在物理上传播与混合实现， 规模从此前的小数目提升到 **50。**

方法

- 改用**声表面波**而非自旋波作为耦合媒介 —— 声波的传播距离更长、损耗更低。
- 规模从个位数提升到 50 自旋。

创新点

- 以声波替代自旋波作为耦合媒介，是**换一种物理机制来突破原来的规模上限。**
- 同一课题组把 8 自旋推进到 50 自旋，是本路径规模提升最明确的一步。

局限

- 声波器件的频率与波长限制了耦合的灵活度。
- 50 自旋仍远低于实际组合优化问题的需求规模。

量化指标（分层标注）

- **实测自旋数**：**50**（相比同课题组的 8 自旋提升约 **6×**）。
- **系统级能效**：**未提供** —— 未给出 TOPS/W 口径，仅报 time-to-solution 类指标。

Prychynenko2018 —— 磁性 skyrmion 作为非线性阻性元件（储层计算积木）

Phys. Rev. Applied **9**, 014034 (2018) `10.1103/PhysRevApplied.9.014034` skyrmion 储备池

核心工作

提出并验证把磁性 skyrmion 当作**非线性阻性元件**：skyrmion 的存在与否（或位置）显著改变 磁性轨道的电阻，从而构成一个具有**非线性响应与记忆效应**的物理单元， 可用作物理储备池计算的构建模块。

方法

- 用磁电阻效应把 skyrmion 的状态**读出为电信号。**
- 利用 skyrmion 运动的非线性与滞后特性提供计算所需的非线性与记忆。
- 属于「物理储备池」范式：只训练读出层。

创新点

- 把拓扑磁结构（skyrmion）用作**计算元件**而非仅存储单元。
- 为磁子/磁性储备池提供了一种具体的器件形态。

局限

- skyrmion 的稳定存在需要特定材料与外部条件（如 DMI、外场）。
- 论文层面为原理验证，**未给出系统级性能。**

量化指标（分层标注）

- **器件级**：磁阻随 skyrmion 状态的变化（按原文表征）。
- **系统级**：**未提供** —— 该文定位为「积木（building block）」，不做系统级评测。

EverschorSitte2024 —— 拓扑磁性与铁电系统用于储备池计算

Nat. Rev. Phys. **6**(7), 455–462 (2024) `10.1038/s42254-024-00729-w` 综述 拓扑结构

核心工作

综述**拓扑磁性结构**（skyrmion、畴壁等）与**铁电拓扑结构**用于储备池计算的物理基础： 为什么拓扑结构的稳定性与非线性动力学适合作为储备池的物理基质， 以及如何在磁性与铁电体系里实现所需的记忆与非线性。

方法

- 按「储备池所需性质 ← 拓扑结构提供的物理」组织。
- 同时覆盖磁性与铁电两大材料体系。

综述价值

- 把磁性拓扑与铁电拓扑放在同一框架下比较，是较少见的视角。
- 明确指出拓扑结构的**稳定性**正是储备池所需要的「记忆」来源。

领域级共识

- 读出与写入的可扩展性是共同瓶颈。
- 室温下稳定拓扑结构的材料选择仍然受限。

量化指标

- 综述类，**无本文实验数字。**

路径二小结

已经做到的：p-bit 理论框架成熟（Camsari2017）； SHNO 相位同步可调控（Kumar2025）； Ising 机规模从 8 推到 50 自旋（Litvinenko2025）。

卡在哪：**耦合机制决定可扩展性上限。**自旋波 Ising 机实测 8 自旋 vs 设计目标 113,850 自旋， 这个 14,000× 的差距说明了问题的严重程度 —— 波在传播中的损耗限制了能级联的规模。 声表面波把规模推到 50，是换了一种损耗更低的媒介。

读者最该带走的判断：这条路径的论文**普遍不报 TOPS/W**（它们报自旋数与 time-to-solution）。 因此任何把「自旋波 Ising 机」与「RRAM 芯片」放在同一张能效表里比较的做法，**在方法上就是错的。**

4.3 技术路线梳理与未来展望

4.1 节的三层结构（器件 / 振荡器 / 波）加上产业化维度，可以把九项工作归成五条路线。 这条路径的特殊之处在于：**研究热点与产业化底盘几乎是两个独立演化的系统** —— 已量产的是存储（MRAM），研究中的才是计算：

路线	代表工作	技术特征	现状锚点（口径）
已量产底盘（存储，非计算）	Dieny2020	STT-MRAM 嵌入式存储进入量产，提供工艺、良率与 CMOS 集成经验 —— 是所有自旋计算路线的公共工程基础	产业化视角综述（2020 时点判断）
p-bit / 随机器件	Camsari2017	热涨落即资源、可逆逻辑、玻尔兹曼网络硬件抽象	理论框架成熟；s-MTJ 大规模阵列仍是投影（非实测）
振荡器计算	Kumar2025	SHNO 相互同步 + 相位可调控 —— 振荡器型 Ising 机 / 储备池的前提条件	器件级；规模化耦合未解
波 / 拓扑 Ising 与储池	Litvinenko2023 / 2025、Prychynenko2018、EverschorSitte2024	用波干涉或拓扑磁结构提供耦合与非线性；换耦合媒介（自旋波 → 声表面波）换规模	8 → 50 自旋（实测）； TOPS/W 类指标未提供
反铁磁方向	Baltz2018	THz 动力学、零净磁化抗杂散场；电学读写 AFM 序参量	机制清单与共识层面；读出困难是长期瓶颈

未来展望（基于本语料的判断）

- **规模的突破口在「换耦合媒介 + 可编程耦合」**：Litvinenko 系列从自旋波（8 自旋）换到声表面波（50 自旋）说明损耗决定级联规模；但两条 Ising 路线都还没解决「耦合可编程性」—— 光学 CIM 的先例（Marandi2014 固定延迟线 → McMahon2016 测量-反馈）提示这一步大概率要靠某种反馈机制补上，波层 Ising 机还没有自己的「McMahon2016 时刻」。
- **器件层离产业最近，但物理版本被推迟**：p-bit 路线可借 MRAM 生态，可编程性的重担却在 FPGA 替身上先行（见 6.3 节）—— s-MTJ 阵列何时兑现，决定「物理随机性免费」这一卖点成立与否。
- **系统级报告率 0% 是最大的可比性缺口**：本路径目前没有任何整机口径实测（§2.1）。哪怕一篇保守任务的整机能耗实测，都会实质改变这条路径与其他路径的可比性。
- **储池化是波 / 拓扑结构近期最现实的出口**：Prychynenko2018 与 EverschorSitte2024 表明拓扑与波的非线性 + 记忆正好匹配储备池需求，而储备池只训练读出层，对器件一致性的容忍度显著低于 Ising 机对耦合精度的要求 —— 这是「先证明有用、再谈规模化」的合理顺序。

05 路径三 · 光子计算与光子神经形态

计算机制：用光的干涉（MZI 网格做任意酉变换）、谐振与滤波（微环权重库）、非线性光学效应（PCM、OPO 阈值）以及光电探测完成矩阵运算与神经元动力学。权重编排在相位 / 波长 / 光程上，运算以光速传播、载波带宽极高。工程成熟度仅次于存内计算，但核心困难也最「光学」：**光子之间不相互作用，非线性必须借助光电转换或材料效应，级联损耗与光→电转换决定系统上限。**

5.1 这条路径的四种实现风格

MZI 网格 / 微环权重库 / OPO 相干伊辛机 / 光电乘法 —— 四条不同的「用光做 AI」路线

1. **相干 MZI 网格**（Shen2017、Pai2023）：把矩阵-向量乘拆成可编程干涉仪网格（用 $U\Sigma V^\dagger$ 奇异值分解构造），权重是相移器设定。精度受片上噪声与器件偏差累积限制。
2. **广播–加权（WDM + 微环权重库）**（Tait2017、Feldmann2019）：每个神经元占一个波长，「波长 = 连接」，权重是滤波器透射率。把并行度做在波长域，而非空间域。
3. **相干伊辛机（OPO/CIM）**（Marandi2014、McMahon2016）：自旋 = 光参量振荡器的二值相位（0/π），耦合 = 光注入，基态 = 总损耗最低的起振模式。用「向上搜索」（抬高泵浦增益）而非「向下退火」。
4. **光电乘法与原位训练**（Hamerly2019、Pai2023）：相干探测把「光乘电」变成探测电流，绕开 MZI 网格 N^2 扩展；或让反向传播本身在光域发生（梯度 = 前向光与反向传播光的干涉信号）。

McMahon2023 对这条路径做过系统的「物理学审计」：光速快不是优势来源（硅波导中约 0.4c vs CMOS 互连约 0.2c，只差约 5×），真正的三大杠杆是**带宽、空间并行、近乎无耗散的传播** —— 且必须组合使用才可能产生系统级优势。

5.2 七项代表性工作

> 本路径语料共 **11 篇**（其中 Pai2023 正文与补充材料各持一份、McMahon2016 为补充材料一份，见第 10 节方法论说明）。此处展开 7 篇研究工作；3 篇综述（Wetzstein2020 / McMahon2023 / Shastri2021）在 5.3 节以精简条目呈现。

Shen2017 —— 相干纳米光子电路上的深度学习（可编程 MZI 网格做光学神经网络）

Nature Photonics **11**, 441 (2017) `10.1038/nphoton.2017.93` MZI 网格 元音识别

核心工作

在一块硅光子集成芯片上实现神经网络前向传播的**全光线性层**：56 个可编程马赫–曾德尔干涉仪（MZI）按 Reck 结构级联做任意酉变换，再串联可编程衰减器（对角矩阵）补出非酉权重，从而在光域直接完成矩阵-向量乘。任务演示为**元音识别**（实验，非仿真）。

方法

任意权重矩阵经奇异值分解 $M = U\Sigma V^\dagger$ 拆成「两个酉 MZI 网格 + 一个对角衰减矩阵」—— 这是把不可逆矩阵用可逆器件实现的关键构造。每个 MZI 由热光相移器控制（内部相移调分束比、外部相移调相位），相移设定精度 16 bit；权重在片外训练完成后编程进芯片，**推理阶段不需要光电转换**。芯片输出端配 20 个片上光探测器。

创新点

① 把「任意矩阵乘法」完整映射到硅光芯片，使光学线性层不再受限于酉变换；② 训练后推理全程保持光域，避开光电转换的能耗与带宽瓶颈；③ 用 16-bit 相移设定与 30 dB 探测动态范围，给出了「模拟光学计算能做到多少有效精度」的量化答案。

局限

实验精度**明显低于数字基线**：元音识别 correctness 76.7% vs 同任务数字机 91.7%，差距约 15 个百分点，作者归因于片上光强噪声与器件偏差。维持相移需要持续热功耗（~10 mW/MZI），「省能」叙事不包含这部分静态功耗。矩阵规模受 MZI 数量 N^2 增长约束，56 个 MZI 对应很小的矩阵。

量化指标（分层标注）

器件级：56 个可编程 MZI；20 个片上探测器；热调维持功耗约 10 mW/调制器；单个 MZI 相位噪声实测可压到 $\sigma_\Phi \to 5\times10^{-3}\,\mathrm{rad}$。**系统级（任务实测）**：元音识别 correctness = **76.7%**（芯片）vs **91.7%**（数字基线）。**外推（非实测）**：按 100 GHz 探测速率外推等效 $2mN^2\times10^{11}$ FLOPs、$5/(mN)$ fJ/FLOP；噪声外推下的精度目标 90%。**系统级（能效）**：未提供 —— fJ/FLOP 为架构外推且不含相移维持功耗、激光与探测电路。

Tait2017 —— 用硅光权重库实现的神经形态光子网络（广播–加权递归网络）

Scientific Reports **7**, 7430 (2017) 10.1038/s41598-017-07754-z 微环权重库 CTRNN 同构

核心工作

首次实验观察**递归硅光神经网络**的物理实现：连接权重由微环谐振腔（MRR）权重库配置。用动力学分岔分析证明该硅光电路与**连续时间递归神经网络（CTRNN）**存在数学同构（单节点双稳 = cusp 分岔、双节点振荡 = Hopf 分岔，均实验验证）；并据此对一个**仿真的 24 节点网络**求解微分方程类任务，预测相对 CPU 基准 **294× 加速**。

方法

广播–加权协议：每个神经元输出占唯一波长载波、WDM 广播；输入 WDM 信号经 MRR 权重库（可重构连续值滤波器）加权后用总功率探测求和，电学加权和再驱动电光非线性。权重精度实测 **4.1 + 1(sign) bit**（存在工艺偏差与热串扰条件下的动态精度）。24 节点网络需要 24 个激光波长 + 24 个调制器 + 24 个权重库 = **576 个 MRR 权重**；功率预算由静态 MRR 热调与泵浦激光主导。

创新点

① 用分岔判据建立「光子硬件 ↔ 神经网络模型」的物理同构，使神经网络的算法与编译器可直接套用到光子硬件；② 调制器型神经元与硅光 CMOS 平台兼容，是走向晶圆级量产的前提；③ 给出了本语料中**核算最完整**的功率-面积-能效预算（含激光壁插效率 5% 假设），294× 的推导透明可复核（γ_CPU = 3.68 μs vs γ_Pho = 12.5 ns）。

局限

294× 是对 24 节点仿真网络的预测，不是实测芯片端到端加速 —— 实验部分只到单/双节点分岔现象，网络级任务从未在芯片上真实运行。热光调谐 5.2 mW/权重 → **3.0 W 静态功耗**是主要负担（载流子耗尽型调谐可缓解但未在大阵列验证）。1 GHz 带宽是为抑制寄生振荡而**主动限制**的，不是器件上限。未做真实数据集任务。

量化指标（分层标注）

器件级（实测）：MRR 权重动态精度 4.1+1 bit；权重库面积约 625 μm²/突触。**网络级（预测，非实测）**：576 权重、106 mW 最小系统总功耗（含激光壁插）、4.4 mW/神经元、限制 1 GHz 带宽时 **180 fJ/SOP。系统级（算法加速预测）**：**294×。口径提示**：180 fJ/SOP 与 294× 均为预测口径；106 mW 是本语料中少见的明确写出「含光源壁插效率」的系统级功耗数字。论文同时给出跨技术对照（Shen 方案约 830 fJ/SOP、TrueNorth 约 240 fJ/SOP 但为 event-based 口径）。

Feldmann2019 —— 全光脉冲神经突触网络（含自学习）

Nature **569**, 208 (2019) 10.1038/s41586-019-1157-8 PCM 突触 WDM STDP

核心工作

用**相变材料（PCM）+ 环形谐振腔 + 波分复用**在集成纳米光子平台上做出**全光脉冲神经元与全光突触**，构成 **4 神经元 / 60 突触（共 140 个光学元件）**的光子神经网络；既做监督学习（设定权重识别字母），也做**无监督学习**（基于 spike-timing 的可塑性，权重自行演化）。

方法

突触是波导上的 PCM 单元（3.6 μm²），透射率即权重；环形谐振腔（小环半径 40–55 μm、Q ≈ 10^4、插损 1.5 dB）做 WDM 合波，大环（半径 60 μm）做神经元：当加权输入功率和超过阈值时，神经元 PCM 由晶态切换到非晶态、放出输出脉冲 —— 激活函数近似 ReLU。波导交叉损耗仅 0.23 dB。**每个波长通道对应一个突触**：「波长 = 连接」是把光子带宽用于并行的关键设计。

创新点

① **全光**实现「积分-发放」神经元与可塑突触，而非光电混合；② 用 WDM 把并行度做在波长域 —— 与空间并行的 MZI 矩阵乘法是两条不同的路线；③ PCM 的**累积-阈值**特性天然对应 integrate-and-fire，物理机制与计算功能高度对齐，且无监督模式下权重演化即学习。

局限

规模极小（4 神经元 / 60 突触），字母识别以上的任务（数字、语种识别）均为**仿真**。PCM 的编程精度与耐久性、环谐振腔对温度/工艺漂移的敏感性是主要工程约束。**系统级能效/吞吐指标未提供** —— 该文以功能演示为主，未给出芯片级 TOPS/W 或 pJ/推断。

量化指标（分层标注）

器件级：突触 PCM 3.6 μm²、神经元 PCM 9 μm²；小环 Q ≈ 10^4、插损 1.5 dB；交叉损耗 0.23 dB；发放阈值 430 pJ（输入功率和口径）；ReLU 阈值取最大脉冲能量的 60%。**系统级（网络规模）**：**4 神经元 / 60 突触 / 140 光学元件。系统级（任务）**：字母识别为实验；数字/语种识别为仿真。**系统级（能效）**：未提供。**口径提示**：430 pJ 是单个神经元发放的阈值能量（器件级），不能当作整网每次推断能耗引用。

McMahon2016 —— 全可编程 100 自旋相干伊辛机（全连接，测量-反馈架构）

Science **354**, 614 (2016) 10.1126/science.aah5178 CIM 100 自旋

核心工作

把相干伊辛机（CIM）做成**全可编程、全连接的 100 自旋系统**：自旋 = 时间复用 OPO 脉冲的二值相位态，耦合系数由 FPGA 测量-反馈（measurement-feedback）回路实时注入 —— 相位测量后按 Ising 矩阵计算反馈光场，注入回腔内。用它在最大 **100 顶点的 MAX-CUT** 问题上与模拟退火等算法对比求解质量。

方法

1560 nm 飞秒光纤激光（重复周期 10 ns）倍频泵浦 PPLN OPO 腔；每个脉冲是一个自旋候选，在阈值附近经历分岔进入 0/π 相位态之一；FPGA 逐脉冲测相位 → 按耦合矩阵 J_{ij} 算反馈幅相 → 经调制器注入。编程任意 J_{ij} 的能力来自反馈回路而非物理互连 —— 这与 Marandi2014 的固定延迟线耦合是同一 CIM 思想的两种工程化。

创新点

① 把 CIM 从「固定小规模演示」推到 **100 自旋 × 全连接 × 全可编程**，首次让 CIM 与经典算法在相同规模的实例集上正面对比；② 测量-反馈架构把「耦合可编程性」与「物理非线性」解耦，成为后续 CIM 系统的通用架构。

局限

反馈回路含光电转换与 FPGA 计算 —— **「全光」只发生在 OPO 阈值分岔一步**，测量-反馈是电子瓶颈所在（也是后来 Hamerly 等人讨论 CIM 能效上限时的核心约束）。求解质量对比依赖具体实例分布，不构成对 NP-hard 一般难例的优势证明。**系统级能效未提供。**

量化指标（分层标注）

系统级（规模）：**100 自旋、全连接、全可编程。系统级（任务）**：MAX-CUT 最大 100 顶点，与模拟退火对比（具体成功率分布见正文与补充材料图表；本条不转述未复核的数字）。**器件级**：1560 nm 飞秒泵浦、重复周期 10 ns（本报告盘内为其补充材料 PDF，含 Materials and Methods；正文未单独持有）。**系统级（能效）**：未提供。**口径提示**：本条与 Marandi2014 同属 CIM 路线，但 2014 是固定耦合的 4 自旋原理演示，2016 才是可编程 100 自旋系统 —— 引用时不可混同。

Hamerly2019 —— 基于光电乘法的大规模光学神经网络

Physical Review X **9**, 021032 (2019) 10.1103/PhysRevX.9.021032 相干探测 散粒噪声极限

核心工作

提出并仿真验证一种**可扩展到 $N \gtrsim 10^6$ 规模**的光子加速器架构：**光电乘法（photoelectric multiplication）** —— 权重与输入**都编码在光域**，经相干探测在光电二极管上直接完成乘法与累加。给出 GHz 速度、每 MAC 亚 attojoule 量级的目标区间；并在数字/图像分类的仿真中给出光学神经网络的一个**「标准量子极限」** —— 由光电探测器散粒噪声设定，最低可达 **50 zJ/MAC**，理论上允许低于数字不可逆计算的 Landauer 极限。

方法

权重光与输入光在探测器上拍频：探测电流 $\propto E_{\mathrm{w}} E_{\mathrm{in}}^{*}$ 即乘积项，多路求和在电流域自然完成 —— 这是「乘法发生在探测物理里」的路线，与 MZI 网格把乘法放在干涉里不同。正因权重不用 MZI 网格承载，规模扩展不受 N^2 相移器约束，可用标准自由空间光学元件做大规模空间复用。全连接与卷积结构均可映射。

创新点

① 指出 MZI 网格路线的规模化瓶颈后给出绕开它的乘法机制；② **权重与输入同时编码在光域**，使网络可在线重编程与训练；③ 首次把光学神经网络的能耗下限追溯到**散粒噪声的标准量子极限**（50 zJ/MAC），给整条路线划出了物理底线 —— 这个框架后来被广泛引用为光学 NN 的理论基准。

局限

核心结果是**仿真与理论分析**，未做芯片级端到端实验演示；50 zJ/MAC 是理想相干探测下的极限口径，实际系统受激光壁插效率、探测器带宽与 ADC 精度打折；大规模空间复用对光学对准与器件均匀性的要求未实验验证。

量化指标（分层标注）

理论极限层：散粒噪声设定的「标准量子极限」**低至 50 zJ/MAC**（理论上可低于 Landauer 极限 —— 注意这是**物理极限推导**，不是器件实测）。**架构级（设计目标）**：可扩展至 $N \gtrsim 10^6$、GHz 运行速率、每 MAC 亚 attojoule 量级。**任务级（仿真）**：数字与图像分类仿真给出架构可行性。**系统级（实测）**：未提供。**口径提示**：本条是 §5 中唯一给出「能耗物理下限」的工作 —— 它回答的是「这条路线最好能好到什么程度」，而非「现在做到了什么程度」，两类数字不可混排。

5.3 三篇综述（精简条目）

> 以下三篇是理解光子计算路线的「地图类」文献。综述条目不复制转述数字（引用请回溯原始文献），只保留其**领域判断**。

Wetzstein2020 —— 深度光学与光子学中的 AI 推理（Perspective）

Nature **588**, 39 (2020) `10.1038/s41586-020-2973-6` 综述

核心工作

系统梳理「光学/光子计算用于 AI 推理」的两条主线：① 光子集成回路（MZI 网格、PCM 突触、微环权重库）；② 自由空间光学计算（4f 卷积、衍射网络 D^2NN、散射介质随机投影）。提出**「深度光学（deep optics）」**方法论：把相机建模为光学编码器 + 电子解码器，梯度可一路反传到自由曲面透镜形状、像素曝光等**物理参数**。

综述价值

把光学计算从器件路线图上升为系统方法论（物理层 = 可训练网络层）；明确「AI 推理（而非训练）」才是光学的合理目标 —— 推理对精度要求低（≤8 bit），与模拟光学的噪声水平匹配。

领域级共识

通用光学计算短期难以实现（原文判断）；**光电转换的能耗是长期瓶颈**；模拟光学的根本噪声极限是散粒噪声（无源、像纯电阻电路），可能比电子的热噪声更难管理；点名批评「假设无损介质、不计光电转换」的能耗乐观估计；全光非线性激活在低光强宽带宽下仍是未解核心问题。

McMahon2023 —— 光计算的物理学（11 个可利用的物理特征）

Nature Reviews Physics **5**, 717 (2023) `10.1038/s42254-023-00645-5` 综述 物理学审计

核心工作

对「光为什么可能比电子更快/更省能」做系统审计：列举 11 个可利用的物理特征（带宽、空间并行、无耗散传播、低损耗波导、可交叉、可转向、高扇入扇出、单向传播、最小作用量动力学、室温量子性、波动物理），并论证 **「光速快」是误导性论据**（硅波导 0.4c vs CMOS 互连 0.2c，仅差约 5×）。给出出现优势的定量门槛：矩阵-向量乘需要 $N \gtrsim 10^4$ 才可能越过 I/O 开销。

综述价值

把「光学优势」从口号变成可分解清单，并指出**必须组合多个特征**才可能产生系统级优势；作者用自己的原型作反面教材（单次通过 $>5\times10^5$ 次标量乘，但 I/O 限制使整机性能比电子差几个数量级）；把「光学部分只占整机能耗 <1%」的核算陷阱写进正文 —— 这是「光学很省 ≠ 系统很省」的权威出处。

领域级共识

规模化卡点被逐一量化：MZI 阵列需从 64×64 扩到 $10^4\times10^4$；可级联性（衰减 × 弱非线性 × 波长不兼容）是三重障碍；能耗由电子部分主导（探测器/ADC/调制器阵列）；部分方案「连可行的规模化路线图都没有」。本报告 §5 各条目的「口径提示」多处直接呼应此文。

Shastri2021 —— 面向 AI 与神经形态计算的光子学（Review）

Nature Photonics **15**, 102 (2021) `10.1038/s41566-020-00754-y` 综述 分类学

核心工作

建立光子神经形态硬件的完整分类学：**四类突触/权重**（WDM+MRR 权重库、InP SOA 加权、MZI 网格、非易失 PCM）× **两类神经元**（O/E/O 型 vs 全光型），并系统梳理广播-加权架构、共封装、光源、光 DAC 等系统要素。

综述价值

① 指出神经网络的互连需求是「大规模并行扇入/扇出」，电子被迫用时分复用换带宽 —— 这正是光子的机会窗口；② **纠正「全光一定更快」的直觉**：多数 O/E/O 神经元不做数字化、很少构成带宽瓶颈，模拟 O/E/O 器件的带宽与能效可优于全光器件；③ 把训练方式与拓扑结构一一对应（前馈 ↔ 反向传播，对称拓扑 ↔ 能量面/Ising），并把**控制电子学与光源的共封装**列为最关键工程挑战。

领域级共识

权重存储与访问是新挑战（光学「存内」方案通常无法高频读写）；全光神经元的扇出与可级联性根本受限（光学非线性极化率功率效率低，输出常弱于输入、甚至无法驱动下一级）；硅不能发光，共封装光源是可扩展性的关键；领域缺乏统一基准，需模拟感知的光子编译器处理非理想性。

Marandi2014 —— 时间复用 OPO 网络的相干 Ising 机（CIM 原理演示）

Nature Photonics **8**, 937 (2014) `10.1038/nphoton.2014.249` CIM MAX-CUT

核心工作

用**单个环形腔中的多路时间复用简并光参量振荡器（OPO）**构成相干 Ising 机：自旋 = OPO 的二值相位（0/π），Ising 耦合 = OPO 信号场之间的相互注入。在 **4-OPO** 系统上编程 NP-hard 的 MAX-CUT 问题，**1,000 次运行未检出计算错误。**这是 CIM 路线的奠基性原理演示（后续 McMahon2016 的 100 自旋可编程系统直接沿此路线放大）。

方法

简并 OPO（PPLN 晶体，飞秒泵浦 @ 1045 nm）：阈值以上的非平衡相变使每个 OPO 进入 {0}/{π} 两相位态之一，即「自旋」。腔往返时间 16 ns = 4 × 泵浦周期（4 ns），故一圈承载 **4 个时间分离的 OPO**；三种延迟线（1/2/3 个泵浦周期）提供两两全部耦合，每路注入约 4% 场强。**「向上搜索」**策略：逐渐抬高泵浦增益，网络在总光子损耗最低的相位配置处起振 —— 该配置即 Ising 基态，与经典/量子退火的「向下降温」是两条相反的物理路径。相位态用 1-bit 延迟迈克尔逊干涉仪读出，机械斩波器约 1 kHz 重启系统。

创新点

① **时间复用**：一个环腔承载多个自旋，绕开空间上多腔集成的规模困难；② 室温运行 + 自旋到 OPO 相位态的直接映射；③ 与 OPO 相变绑定的「向上搜索」机制，是有别于退火的独立物理范式 —— 「基态 = 最低损耗起振模式」这一定性后来定义了整条 CIM 路线。

局限

仅演示 N = 4（规模极小），可扩展性论证在补充材料、未做大规模实验；需要外部干涉仪 + 伺服锁定相位，外围庞大；1 kHz 重启 + 180 μs 上升时间使单次求解绝对时间远慢于电子方案；耦合由固定延迟线给出，**不可编程**（可编程性是 McMahon2016 用测量-反馈补上的）。**系统级能效未提供。**

量化指标（分层标注）

器件级/物理级：1045 nm 飞秒泵浦；T_R = 4 ns、T_cavity = 16 ns；延迟线耦合各约 4%；相位容差 ±30°；室温运行。**系统级（规模）**：**4-OPO（N = 4 自旋）。系统级（任务）**：**1,000 次运行、0 次计算错误**（N = 4 的 MAX-CUT）。**系统级（能效）**：未提供。**口径提示**：「1,000 次 0 错」是 N = 4 极小规模上的数字，随 N 增长的趋势在该文中未给出 —— 引用为「CIM 可行性」证据可以，引用为「求解器性能」证据不可以。

5.4 技术路线梳理与未来展望

5.1 节按物理机制分出的四种风格，落到工程现状上是四条成熟度与卡点各异的路线（5.3 节三篇综述提供了领域级判断的出处）：

路线	代表工作	现状锚点（口径）	核心卡点
相干 MZI 网格	Shen2017 / Pai2023	56-MZI 芯片元音识别 76.7% vs 数字基线 91.7%（实测）；原位反向传播 >94%（实测，三层四端口）	相移器 N^2 增长、器件偏差累积、热调静态功耗（~10 mW/MZI）
广播-加权（WDM + 微环）	Tait2017 / Feldmann2019	MRR 权重 4.1+1 bit（实测）；576 权重系统 180 fJ/SOP 与 294× 加速（均为预测）；全光 STDP 演示（4 神经元 / 60 突触）	热调静态功耗（3.0 W）、谐振腔温漂、网络级任务未在芯片上真实运行
相干伊辛机（OPO）	Marandi2014 → McMahon2016	4 自旋 0 错 → 100 自旋全连接全可编程（MAX-CUT）	测量-反馈回路含光电转换与 FPGA —— 「全光」只在分岔一步，电子瓶颈在反馈
光电乘法 / 物理极限分析	Hamerly2019	散粒噪声标准量子极限 50 zJ/MAC（理论推导）；$N \gtrsim 10^6$ 架构（仿真）	无芯片级实验；极限口径与实测口径不可混排

未来展望（基于本语料的判断）

- **优势门槛已被量化，下一代工作必须直接对表**：McMahon2023 给出 $N \gtrsim 10^4$ 的矩阵规模门槛与「多物理特征必须组合使用」的条件 —— 在此之前，任何单特征（只靠快或只靠并行）的系统级优势声明都应视为未验证。
- **训练进光域刚刚起步**：Pai2023 证明了伴随法梯度可以在 MZI 网格的物理可逆性上「免费」获得 —— 把训练与推理合一。后续看点是更大阵列上的器件偏差鲁棒性，这也是 Momeni2025 所列「物理系统训练」问题的光学分支。
- **光电混合是可预见期内的现实形态**：Shastri2021 指出全光神经元的扇出与可级联性根本受限（输出常弱于输入），Wetzstein2020 把光电转换列为长期瓶颈 —— 在非线性可级联问题解决前，「全光」路线的实际交付物都会是光电混合系统。
- **静态功耗与光源是工程主战场**：热调谐（10 mW/MZI 量级）与激光壁插效率（Tait2017 按 5% 假设核算）共同决定系统能效 —— 非热调谐机制（如载流子耗尽）与共封装光源是 Shastri2021 点名的关键工程挑战。
- **噪声是地板也是天花板**：散粒噪声在 Hamerly2019 里是能效下限的设定者（50 zJ/MAC），在 Wetzstein2020 里是模拟光学的根本障碍 —— 同一物理事实的两面，引用时必须分清讨论的是「极限」还是「实现」（§9 发现 5）。

06 路径四 · 概率计算、Ising 机与热力学计算

计算机制：不压制物理涨落，而是**把热涨落当作计算资源。**基本单元是 p-bit（概率比特）—— 一个在 0/1 之间被热噪声驱动随机翻转的经典实体；p-bit 网络按 Glauber 动力学演化，足够多步后自然收敛到 Boltzmann 分布，从而同时覆盖两件事：**组合优化**（Ising 能量面最低态 = 解）与**采样**（Boltzmann 机训练 / 生成模型需要的正是从该分布采样）。这条路径的硬件谱系从随机 MTJ（器件级）到 FPGA（系统级）再到 RLC 电路（热力学计算），横跨最广。

6.1 这条路径的三个子路线与一个共同的方法论困境

子路线：随机磁性器件 / FPGA p-bit 机 / 热力学电路

1. **随机磁性器件**（Sutton2017、Borders2019）：随机翻转的纳米磁体或随机磁隧道结（s-MTJ）本身就是 p-bit，「物理随机性免费」是卖点，规模与耦合可编程性受器件工艺限制。
2. **FPGA p-bit 机**（Chowdhury2022、Niazi2024、Nikhar2024）：用 FPGA 上的二值随机数模拟 p-bit，换取大规模并行与全可编程 —— 是当前这条路径「系统级评测」的主要载体；s-MTJ 版本作为未来投影出现。
3. **热力学计算**（Melanson2025、Aifer2024）：直接用 RLC 电路的 Langevin 动力学采样平衡分布，把「采样」从 MCMC 的逐步生成换成物理弛豫，目标原语是高斯采样与线性代数。

共同困境：这条路径的论文**用 time-to-solution（TTS）、自旋数、采样率说话，几乎不报 TOPS/W 类能效。**因此它与路径 ①③ 的数字**在口径上不可对齐** —— Nikhar2024 的作者把这写得很直白：专用 Ising 求解器不仅要彼此比较，还必须超越最好的经典（GPU）求解器，而领域缺少统一基准。

6.2 七项代表性工作

Borders2019 —— 用随机磁隧道结（s-MTJ）做整数分解

Nature **573**, 390 (2019) `10.1038/s41586-019-1557-9` s-MTJ p-bit

核心工作

首个用**真实随机磁隧道结（STT-sMTJ）**做概率计算的原理演示：8 个纳米尺度的 s-MTJ 作为 8 个 p-bit，构成可编程概率计算器，用于**整数分解** —— 把分解问题编码成 Ising 能量面，p-bit 网络的涨落动力学在能量面上游走、收敛到质因数分解（硬件逐级实测：4 p-bit 分解 35 = 5 × 7、6 p-bit 分解 161 = 23 × 7、8 p-bit 分解 945 = 63 × 15，原文图 3，p.393）。

方法

p-bit 是「在 0/1 之间被热涨落驱动随机翻转的鲁棒经典实体」，通过可编程耦合与其他 p-bit 相互作用（灵感来自神经网络的连接主义）。s-MTJ 的随机翻转由 STT 电流控制：电流大小调节翻转概率 —— 即「退火旋钮」直接做在器件参数里。实验演示与硬件建模（经实验基准校准的 s-MTJ 模型）两级推进。

创新点

① 把「量子计算的采样类任务」翻译成**室温、无需相干性**的概率计算：p-bit 与 qubit 有相似的涨落-相互作用结构，但不受退相干与低温约束；② 首次在真实磁性纳米器件（而非模拟电路）上完成 p-bit 计算闭环，证明「器件热涨落 = 计算资源」不是纸上设想；③ 作者阵容横跨器件（Fukami/Ohno 的 s-MTJ 工艺）与理论（Datta/Camsari 的 p-bit 形式体系），是器件-架构协同的样板。

局限

规模仅 8 个物理 p-bit，分解演示属于概念验证级；s-MTJ 的翻转率分布随温度/工艺漂移，大规模阵列的统计均匀性未验证；耦合与读出仍依赖外部电路；任务限于小型整数分解，与实用优化规模相距甚远。

量化指标（分层标注）

器件级：**8 个 s-MTJ**（实验硬件），翻转由 STT 电流调控。**系统级（任务）**：8 p-bit 硬件分解 945 = 63 × 15（原文图 3，p.393）；此前逐级演示 4 p-bit 分解 35 = 5 × 7、6 p-bit 分解 161 = 23 × 7。**系统级（能效）**：未提供。**口径提示**：本条的规模数字必须分层引用：8 p-bit 硬件实测上限是 945 = 63 × 15；更大规模的分解不是本篇的实验内容，引用时不要外推。

Sutton2017 —— 随机纳米磁体的内在优化（Ising 计算机的磁学路线奠基）

Scientific Reports **7**, 44370 (2017) `10.1038/srep44370` 随机纳米磁体 TSP

核心工作

提出以**随机翻转的纳米磁体**为基元的 Ising 计算机设想：磁体天然在 ±1 两个 Ising 态之间随机切换（热涨落），其相互作用可短程可长程、强度可重构，统计力学定律引导网络以 GHz 速率游走于集体态、偏向低能量解。作为概念验证，用经实验基准校准的器件模型仿真求解标准 NP-complete 问题，包括 **16 城市旅行商问题（TSP）**。

方法

「内在优化（intrinsic optimization）」路线：不让硬件执行优化**算法**，而是把问题的 Ising 编码**直接写进器件耦合**，让物理系统自身的统计力学完成搜索 —— 随机切换提供探索（对应退火温度），耦合提供偏置（对应能量面）。器件模型用实验标定过的 STT 驱动随机纳米磁体参数，保证仿真结论有器件依据。

创新点

① 明确提出「磁学版 Ising 机」的完整理论框架（比 s-MTJ 实验演示 Borders2019 早两年、比 FPGA 大规模实现早五年），是路径 ② 与路径 ④ 交叉处的枢纽文献；② 把「器件随机性免费 + 耦合可重构」确立为这条路线的两条设计公理；③ TSP 等标准 NP-complete 映射为后续所有 Ising 机论文提供了统一的任务词汇。

局限

全部结果为**仿真**（基于标定模型），无硬件实验；未给出与经典求解器的系统级 TTS/能效对比；纳米磁体间耦合（偶极/交换/电学中介）的可编程精度在文中是假设而非实测。

量化指标（分层标注）

系统级（任务，仿真级）：16 城市 TSP 等 NP-complete 基准（**仿真**，非硬件）。**器件级（模型）**：STT 驱动随机纳米磁体，GHz 级切换速率，室温。**系统级（能效）**：未提供。**口径提示**：本条文件此前被误名为「Kumar2022_NatCommun」—— 经 Crossref 与 PDF 首页双重核验实为 Sutton/Camsari/Behin-Aein/Datta 的 Sci. Rep. 2017，已在第 10 节方法论中记录更正。

Pai2023 —— 光子神经网络的原位反向传播（梯度在光域里算出来）

Science **380**, 398 (2023) `10.1126/science.ade8450` 原位训练 MZI 网格

核心工作

在实验上实现**光子神经网络的原位反向传播（in situ backpropagation）**：一个三层、四端口的硅光子神经网络（可编程相移器 + 光功率监测），训练时让**前向传播光与反向传播光在芯片内干涉**，直接在光域测出每个相移器电压对应的梯度 —— 这是深度学习最核心的训练算法在光学硬件上的物理等价物。实验分类任务与数字仿真表现相当（>94% 测试精度），并给出 64 端口网络跑 MNIST 的仿真与能耗扩展分析。

方法

反向传播的数学本质是**伴随法**：前向场与「时间反演/共轭」的误差场干涉，干涉强度即局部梯度。在 MZI 网格架构里，反向传播光可以从输出端倒注入，沿同一物理网格反向走过 —— 因为 MZI 网格是可逆酉网络，**同一套硬件天然支持反向光路**，无需像电子 GPU 那样为梯度单独建前向/反向两张图。梯度以光强形式被监测单元读出，权重更新仍在电域完成。

创新点

① 打破「光学只做推理、训练必须回数字域」的默认分工 —— 梯度计算也被搬进物理层；② 利用了 MZI 网格的**物理可逆性**，训练硬件与推理硬件完全同一；③ 附带给出能耗扩展分析，论证原位训练方案的能效随规模扩展的路径 —— 是「物理系统直接做 AI 训练」这一 2025 年后被反复讨论的议题（Momeni2025 综述）的实验先行者。

局限

实验网络仅三层四端口（小规模验证）；梯度测量依赖干涉对比度与探测器精度，器件偏差下的训练鲁棒性未在大阵列验证；64 端口 MNIST 为**仿真**结果；权重更新仍在数字域完成，「原位」严格说是「梯度原位、更新在线外」。

量化指标（分层标注）

系统级（任务实测）：三层四端口芯片实验，分类任务与数字仿真相当（**>94% 测试精度**）。**系统级（仿真）**：64 端口网络 MNIST 识别 + 能耗扩展分析。**器件级**：MZI 网格 + 可编程相移器 + 光功率监测单元。**系统级（能效实测）**：未提供（能耗为扩展分析口径）。**口径提示**：本条与本报告第 3 节 Yao2020「全硬件 CNN」一样属于「训练/推理闭环」文献，但两者的「片上训练」含义不同 —— Yao 是推理权重片上重写，Pai 是梯度计算发生在光域，引用时不可混同。**另注**：本报告盘内同时持有该文正文与补充材料两份 PDF（Science 的 `citation_pdf_url` 指向补充材料的坑，见第 10 节）。

Chowdhury2022 —— 稀疏 Ising 机的大规模并行概率计算

Nature Electronics **5**, 460 (2022) 10.1038/s41928-022-00774-2 FPGA MCMC

核心工作

把 p-bit 概率计算机的「可并行性」变成系统设计原则：**稀疏 Ising 机上的马尔可夫链蒙特卡洛（MCMC）**可以在 FPGA 上大规模并行执行 —— 关键洞察是**稀疏耦合才允许图着色式的块并行 Gibbs 采样**（稠密网络必须串行更新）。论文展示硬件感知的网络拓扑设计，使概率计算在接近硬件极限的并行度下运行，为生成式 AI 任务的 MCMC 加速提供硬件路线。

方法

p-bit 更新规则 $I_i = \sum_j J_{ij} m_j + h_i$，$m_i = \mathrm{sgn}[\tanh(\beta I_i) - \mathrm{rand}]$ 即离散 Gibbs 采样；稀疏拓扑下把无耦合冲突的 p-bit 分入同一着色组同时更新，并行度由图度数决定。作者团队横跨 UCSB（Camsari 组）、墨西拿大学（Finocchio 组）与 Quantala，FPGA 实现与器件级 s-MTJ 投影并行推进。

创新点

① 把「稀疏性」从工程妥协升格为**并行性来源** —— 这是该团队 FPGA p-bit 路线的核心论点，与 Niazi2024、Nikhar2024 构成三部曲；② 首次把概率计算与生成式 AI 的 MCMC 负载显式对接（训练生成式神经网络、信念网络推断、组合优化三类任务统一到同一硬件抽象）。

局限

FPGA 上的 p-bit 是**模拟出来的随机性**（片上伪随机数 + 比较器），「物理涨落即计算」的卖点在 FPGA 版本并不成立 —— 真正的物理版本要等 s-MTJ 阵列，而那是尚未实现的投影；对稠密问题实例，并行性优势消失。

量化指标（分层标注）

系统级（FPGA 实测）：大规模并行 Gibbs 采样的加速与吞吐（相对软件 MCMC）；**器件级（投影，非实测）**：s-MTJ 版本的规模与功耗推算。**系统级（能效）**：未以 TOPS/W 类口径报告。**口径提示**：本条与后两篇（Niazi/Nikhar）的「性能」都是**算法性能口径**（采样速率、TTS、精度），与路径 ①③ 的能效口径不可直接对齐。

Niazi2024 —— 用稀疏 Ising 机训练深度玻尔兹曼网络

Nature Electronics **7**, 610 (2024) 10.1038/s41928-024-01182-4 玻尔兹曼机 生成模型

核心工作

证明 p-bit Ising 机不只能解优化问题，还能**训练深度玻尔兹曼网络（生成模型）**：在 FPGA 的硬件感知稀疏拓扑上，完整训练 **MNIST 与 Fashion-MNIST（不降采样）**以及缩减版 CIFAR-10。最响亮的数字：4,264 节点（p-bit）、约 3 万参数的稀疏深度玻尔兹曼网络，在 MNIST 上达到 **90% 分类精度** —— 与约 **325 万**参数的优化软件 RBM 相当。

方法

把玻尔兹曼机的训练（对比散度 / 正相-负相采样）映射到 Ising 硬件的原生操作：p-bit 网络的物理演化天然产生 Boltzmann 分布样本，硬件拓扑按问题的稀疏结构裁剪，使每次 Gibbs 扫描保持全并行。训练后网络还能**生成**新的手写数字与时尚商品图像 —— 生成能力证明采样质量，不是只会分类的监督加速器。

创新点

① 首次在规模化 Ising 硬件上完成**深度生成模型训练闭环**（此前 Ising 机文献几乎只做优化基准）；② 「参数量 3 万 vs 325 万」的对比把稀疏拓扑的样本效率优势量化到任务级；③ 为「概率 AI 的专用硬件」提供了 MNIST 级别的端到端证据链。

局限

90% 是 MNIST 上的精度，与现代 GPU 上的深度生成模型不在同一水平线上（对比对象是同族 RBM 的软件基线，而非深度学习 SOTA）；CIFAR-10 是缩减版；训练需要的扫描次数与收敛稳定性对稀疏拓扑依赖很强；FPGA 伪随机 p-bit 同样非物理器件。

量化指标（分层标注）

系统级（任务实测）：**4,264 p-bits / 约 3 万参数 → MNIST 90%**（对比：软件 RBM 约 325 万参数达同精度）；Fashion-MNIST 全量训练；CIFAR-10 缩减版。**系统级（能效）**：未提供。**口径提示**：「参数少 100×」是稀疏拓扑 + 硬件采样的联合效果，**不能**引申为「Ising 机比 GPU 高效 100 倍」—— 两者的参数量-精度关系不同，原文也未做能耗对齐比较。

Nikhar2024 —— 全连接可重构性的稀疏与高阶 Ising 机

Nature Communications **15**, 8977 (2024) `10.1038/s41467-024-53270-w` 3R3X 基准 高阶相互作用

核心工作

在 3R3X（三正则三-XOR-SAT，p-bit 文献的标准难例）上系统评估 p-bit Ising 机，提出**「主图 + 复用」架构**：用 neighbor MUX 与 clock MUX 在稀疏固定拓扑上**模拟 all-to-all 网络功能**，同时保持着色 Gibbs 采样的大规模并行；单块 Xilinx Alveo U250 上实现自适应并行回火（APT）；**并首次在规模化 FPGA p-bit 机上实现三阶（3-body）相互作用**，回答了 Kowalsky 等人提出的开放问题 —— 高阶项能把**前因子**显著改善、p-bit 数减半，但**标度指数不变。**

方法

以 **TTS（time-to-solution）标度定律** $\langle \mathrm{TTS} \rangle_q \approx 10^{\gamma m + \eta}$ 为核心指标（每规模 100 实例 × 1,000 次运行）：二阶 FPGA 实测 γ = 0.0206(2)、η = −3.76(6)；三阶 γ = 0.0201(2)、η = −4.30(0)；对照组 SATonGPU γ = 0.0171、η = −5.9 为最优。因 p-bit 是二值变量，三阶项用 AND 门即可实现、**无需乘法** —— 这是 p-bit 硬件做高阶能量的天然优势。

创新点

① 「稀疏保并行、复用补全连接」的架构直接回应了 all-to-all 的 $O(n^2)$ 权重依赖不可持续的批评；② 用统一标度定律把 p-bit 机、SATonGPU、DAU、SBM、PT、DWA 六种求解器放到同一坐标系 —— 这在缺少统一基准的领域里是少见的横向工作；③ 三阶相互作用的结论（改前因子、不改标度）给「高阶 Ising 是否值得」的争论画了句号。

局限

作者自己写得很清楚：FPGA p-bit 仍**不及 GPU 上的最佳贪心算法**，专用求解器「不仅要彼此比较，还要超越最好的经典求解器」；稠密实例上并行性被禁止（all-to-all 需要 O(n) 种颜色 → 退化为串行）；replica 交换时间由外部 CPU 承担、未计入 TTS；不同规模需重新综合 FPGA；实测规模二阶 n ≤ 112（sMTJ 版 10^6 p-bit 是投影）。

量化指标（分层标注）

实测 FPGA：二阶 n = 16→112（9 replica × 112 p-bit = 1008 p-bit 并行）；三阶 n = 160；单时钟周期（66.67 ns）完成整网更新。**实测标度（TTS 拟合，q = 0.5）**：γ/η 见上 —— 注意 γ 主导渐近、η 主导前因子，三阶的收益全在 η。**投影（非实测）**：sMTJ 版 10^6 p-bit、1 ns sweep。**系统级（能效）**：未提供（无 TOPS/W / pJ/样本 口径）。**口径提示**：「胜过 D-Wave/Toshiba/Fujitsu」的对照数据取自文献、且仅限 3R3X 基准 —— 这是同基准下的相对比较，不是整机优势证明。

Melanson2025 —— 热力学计算系统（SPU：RLC 电路做高斯采样与矩阵求逆）

Nature Communications **16**, 3757 (2025) `10.1038/s41467-025-59011-x` 热力学计算 Normal Computing

核心工作

Normal Computing 团队提出并实验验证**随机处理单元（SPU）**：PCB 上 **8 个 RLC 单元全连接**、经开关电容耦合，器件运动方程即 Langevin 方程，静止分布为 Gibbs 分布 —— 因此器件**天然采样目标分布。**硬件演示两个概率 AI 核心原语：**高斯采样**（含偏度/峰度误差评估）与 **8×8 矩阵求逆**（对比 GPU 上的 Cholesky 采样基线），并给出罕见的**含 ADC 在内的端到端系统核算。**

方法

对应关系：磁通 = 位置、电荷 = 动量、电容 = 质量、电阻倒数 = 摩擦系数；噪声谱密度可人为加大到超过本征热噪声，把「噪声」变成可控参数。端到端四段：数字端算电容阵列取值（GPU）→ 装载 → 物理弛豫（模拟运行）→ ADC 读回。采样率 12 MHz；性能模型以维度 d 为横轴对比 SPU 与 RTX A6000 上的 JAX Cholesky 采样。

创新点

① 把热噪声从误差源转为**采样资源**：无需逐步伪随机数、无需逐步矩阵乘，物理弛豫直接完成采样/求逆；② 是同类工作中少见的**端到端核算派**（明确含 ADC 与接口），并诚实标注哪些数字是实测、哪些是数学模型；③ 明确给出可扩展架构提案（RC 单元 + 电阻耦合替代电感/变压器）及其物理理由。

局限

实测规模仅 8 单元；当前架构可扩展性受限（原文点名：电感与变压器的 IC 集成困难）；电容失配与温度影响精度（假设 16-bit 元件精度）；**「热力学优势交叉点约在 d = 3000、$d = 10^4$ 时约一个数量级速度/能量优势」全部是数学模型预测**，原文明确不是硬件实测 —— 这是本条最重要的口径红线。

量化指标（分层标注）

实测：8 单元全连接 PCB；12 MHz 采样率；3 台副本做可复现性；8×8 矩阵求逆（每台 12,000 样本）；高斯采样演示 2 维。**模型预测（明确非实测）**：优势交叉点 d ≈ 3000；渐近标度 SPU $O(d^2)$ vs GPU Cholesky $O(d^3)$；d = 10^4 时约一个数量级速度/能量优势。**假设层**：时间常数 1 μs、每单元 0.005 mW（ADC 主导）、16-bit 元件精度。**系统级（实测能耗）**：未提供。**口径提示**：「一个数量级优势」必须与「模型预测」连用 —— 本报告在 §9 会把它与 Ambrogio2023 的实测落差并排展示，作为「两类口径」的活教材。

Aifer2024 —— 热力学线性代数（把线性代数解耦成耦合振子采样）

npj Unconventional Computing **1** (2024) `10.1038/s44335-024-00014-0` 理论框架 热力学计算

核心工作

建立「热力学线性代数」理论框架：把**求解线性方程组、矩阵求逆、行列式**转化为**耦合谐振子系统平衡分布的采样问题** —— 证明热力学与线性代数的深层连接（各态历经、熵、平衡），并在合理假设下严格证明算法相对数字方法的**渐近加速随矩阵维度线性增长。**这是 Melanson2025 硬件路线的理论上游。

综述价值

① 给热力学计算找到了比组合优化更「刚需」的落点 —— 线性代数是科学与机器学习的公共负载；② 与量子线性代数（HHL 类）对照：不需要态制备假设与相干性，代价是采样误差服从统计规律；③ 明确把「近期可实现」作为设计目标（经典热力学系统即可），与量子路线的资源鸿沟形成对照。

局限

全部为理论分析 + 算法层论证，无硬件实验；「线性加速」依赖各态历经与平衡假设，非遍历系统（阻挫、简并）下的表现是开放问题；采样型算法天然带统计误差，精度-时间权衡未被系统刻画。

两篇「地图类」文献（精简条目）

Mohseni2022（Nature Reviews Physics，"Ising machines as hardware solvers of combinatorial optimization problems"）： Ising 机路线最系统的综述 —— 把硬件谱系（数字 CMOS 退火 / 光学 CIM / 量子退火 / p-bit）与三类运行方法（经典退火、量子动力学、量子启发经典算法）放进同一框架。 其摘要要点直接构成本报告 §6 的判断基线：**当前性能最好的 Ising 硬件基于经典数字技术**；量子硬件的「优越性」目前只在特定构造任务上成立；缺乏统一基准是横向比较困难的根源。

Albash2018（Reviews of Modern Physics **90**, 015002 (2018)，DOI `10.1103/RevModPhys.90.015002`，"Adiabatic quantum computation"）： 绝热量子计算 / 量子退火的权威综述，本语料中路径 ④ 与「量子对照」之间的桥梁文献 —— 它定义了「量子退火到底承诺了什么」（绝热定理、最小能隙、开放系统效应）， 从而让读者能判断：Ising 机的经典/概率路线与量子路线之间的差距究竟是**物理原理差距**还是**工程成熟度差距。**注意：本条文件曾因目录归属错误被修正（量子退火综述归入路径 ④ 对照，而非路径 ②），见第 10 节。

6.3 技术路线梳理与未来展望

6.1 节的三个子路线 + 两篇地图类综述，合起来是这条路径的完整版图。它的独特之处：**当前承担系统级评测的载体（FPGA）恰恰不是这条路线的物理卖点所在（s-MTJ）**：

路线	代表工作	现状锚点（口径）	核心卡点
随机磁性器件	Sutton2017 / Borders2019	理论框架 + 16 城 TSP（仿真）；**8 个 s-MTJ 硬件**分解 945 = 63 × 15（实测，原文图 3）	规模极小；翻转率统计均匀性、耦合与读出的外部依赖
FPGA p-bit 机	Chowdhury2022 / Niazi2024 / Nikhar2024	稀疏并行 Gibbs 采样；4,264 p-bit 训练玻尔兹曼网络 MNIST 90%（vs 软件 RBM 约 325 万参数）；3R3X 标度 γ ≈ 0.02（实测）	随机性是模拟出来的（伪随机数）；稠密实例并行性消失；仍不及 GPU 最佳算法
热力学计算	Melanson2025 / Aifer2024	8 个 RLC 单元实测高斯采样与 8×8 矩阵求逆；「d ≈ 3000 交叉点、d = 10^4 时约一个数量级优势」全部是模型预测	电感/变压器 IC 集成困难；理论假设（各态历经、平衡）在非遍历系统下未验证

未来展望（基于本语料的判断）

- **「替身先行、器件押后」的模式面临兑现时刻**：FPGA 版本已建立完整的系统级证据链（并行采样、生成模型训练、标度定律），但「物理涨落即计算」的卖点全部押在尚未实现的 s-MTJ 阵列上（Nikhar2024 投影 10^6 p-bit @ 1 ns sweep）。何时兑现是这条路线的成败点。
- **任务重心正在迁移**：组合优化（MAX-CUT / 3R3X）→ 生成模型训练（Niazi2024）→ 采样与线性代数原语（Aifer2024 + Melanson2025）。热力学计算把目标客户从「优化」换成「机器学习的公共负载」，这是本路径内部最有战略意义的一步。
- **必须过 GPU 这一关**：Nikhar2024 作者自陈专用求解器「不仅要彼此比较，还要超越最好的经典求解器」；Mohseni2022 确认当前最强 Ising 硬件基于经典数字技术。统一基准缺失（§11.1）使这一关暂时无法诚实裁判。
- **高阶相互作用之争已收尾**：Nikhar2024 的结论（三阶项改前因子、不改标度指数）给「高阶 Ising 是否值得」画了句号 —— 后续投入会转向稀疏拓扑、复用架构与稠密实例。
- **能效口径全路径空白**：无一篇报 TOPS/W 或 pJ/样本。Melanson2025 的含 ADC 端到端核算是这条路径里唯一的「诚实核算」开端，值得被效仿。

07 路径五 · 新兴基质（机械 / 生物 / 材料-结构智能）

计算机制：不追求 TOPS/W，而是问「**还有哪些物理自由度能承载计算**」。机械形变、生物神经网络动力学、材料-结构一体化智能，各自代表一种与电子/光子完全不同的物理基底。这条路径语料最少（4 篇），但它的价值在于划定「物理计算」概念的外边界 —— 同时它的工程成熟度也最低，全部工作处于演示级。

Mei2023 —— 机械存内计算（3D 打印的机械二值神经网络）

Nature Communications **14** (2023) `10.1038/s41467-023-40989-1` 机械计算 3D 打印

核心工作

提出**存内机械计算架构**：计算发生在机械记忆单元的相互作用网络内部（而非「先读后算」），读写接口内嵌相互作用，实现功能完备的神经形态计算。实验演示（3D 打印）：**可重编程机械二值神经网络**、**机械自学习感知机**，以及两输入一输出的**全部 16 种逻辑门**与真值表项。

创新点

① 把「存内计算」思想（路径 ① 的核心）翻译到机械域 —— 信息以形变状态存储、计算经由形变演化完成；② 用**纯被动机械结构**实现感知机级别的「自学习」，证明学习不必依赖电学；③ 功能完备性证明（16 逻辑门全实现）把机械计算从「花哨演示」提升到「图灵完备性讨论」层面。

局限

速度以 Hz–kHz 计（机械响应），比电子慢 6–9 个数量级，不构成算力竞争者；演示规模小；「自学习」是结构参数调整而非反向传播意义上的训练；能耗口径未建立（机械域缺乏统一的能耗度量惯例）。

量化指标（分层标注）

系统级（任务实测）：机械二值神经网络 + 自学习感知机 + 16 逻辑门（3D 打印实验）。**系统级（能效）**：未提供。**口径提示**：本条的意义在「功能演示」而非「性能」—— 任何把它与电子硬件比速度/能耗的引用都是误引。

Cai2023 —— 脑类器官储备池计算（Brainoware）

Nature Electronics **6**, 1032 (2023) `10.1038/s41928-023-01069-w` 生物计算 储备池

核心工作

用**脑类器官（brain organoid）**作为储备池计算的计算核心：高密度微电极阵列（HD-MEA）向活体神经组织发送时空电刺激并读取响应，类器官的非线性动力学与衰减记忆充当「储备池」，训练只作用于读出层；通过无监督的刺激重塑类器官功能连接实现「训练」。演示任务：**语音识别**与**非线性方程预测**。

创新点

① 把「物理储备池」范式（Tanaka2019）推到生物组织这个极端基质 —— 真实神经元的天生非线性、短期记忆与低功耗是任何人工器件都未企及的；② 系统级闭环完整：刺激编码 → 组织响应 → 读出训练 → 任务输出，且展示了类器官连接可塑性（结构随训练变化）；③ 引发了「生物基质计算伦理」的正面讨论 —— 这在其他路径中不存在。

局限

类器官的存活期、批次差异与响应漂移使可复现性天然受限；训练依赖生物结构重塑，速度与稳定性远低于固态器件；任务精度低于同等规模的硅基方案；能耗对比（生物组织的低功耗）没有严格的同口径测量。**伦理边界**：本报告只陈述其技术内容；类器官是否涉及伦理问题超出本报告范围，但引用者应当知晓该维度存在。

量化指标（分层标注）

系统级（任务实测）：语音识别 + 非线性方程预测（储备池框架，读出层训练）。**器件级**：HD-MEA + 脑类器官。**系统级（能效）**：未提供。**口径提示**：本条与 Zolfagharinejad2025（路径 ①，掺杂网络语音识别）做了同任务不同基质的天然对照 —— 但两文的精度口径不同，不能直接比出「生物强还是掺杂网络强」。

Alu2025 —— 功能材料与结构中的机械智能路线图

Smart Materials and Structures **34**, 063501 (2025) `10.1088/1361-665X/adb7aa` 路线图 43 页

核心工作

43 页的多作者路线图（Alù、Arrieta、Dickey、Mazzolai 等机械智能领域代表人物），系统梳理「把智能与计算**具身（embody）**进功能材料与结构」的技术版图：力学超材料、可编程物质、软体机器人结构、机械储层、响应性材料等的计算能力与瓶颈。

综述价值

① 定义了「具身智能（embodied intelligence）」与「物理计算」的交集词汇 —— 计算不必发生在「计算机」里，可以发生在材料本构关系与结构几何里；② 给出各子方向的成熟度分级与共性瓶颈（速度、可编程精度、与电子系统的接口）；③ 是本路径中唯一覆盖「材料-结构-系统」全链条的文献。

局限

路线图体例无统一基准与对比数字；多数子方向停留在原理演示；「机械智能」与主流 AI 负载（训练/推理大模型）之间的距离在所有路线图章节中都未闭合。

Tanaka2019 —— 物理储备池计算综述（本路径的方法论基线）

Neural Networks **115**, 100 (2019) `10.1016/j.neunet.2019.03.005` 综述 储备池计算

核心工作

系统综述**物理储备池计算**：把物理系统的动力学当作递归网络的储备池，**只训练线性读出层**（储备池固定、训练成本低是核心卖点）。按储备池基质分章：动力学模型（时滞系统 / 元胞自动机 / 耦合振荡器）、**电子**（忆阻器与原子开关系统）、**光子**（光学节点阵列 + 时间延迟反馈系统）、**自旋电子学**、**机械**、**生物**（脑区与体外培养细胞），并给出跨基质比较的共同语言（记忆容量、非线性度、状态维度）。本报告 §5 的 Feldmann2019、§4 的振荡器类工作、本节的 Cai2023，全部可以放进这个统一框架。

综述价值

① 说明了「只训练读出」为何能把训练成本压到最低 —— 这是物理计算避开「训练难」问题（Momeni2025 的主题）的经典策略；② 建立跨基质的比较维度，使「哪种物理系统适合哪类时序任务」有章可循；③ 明确储备池的核心竞争力：**用物理动力学免费获得高维非线性时间特征。**

领域级共识

储备池本身不可训练，任务性能依赖物理系统固有动力学是否「正好合适」；时序记忆深度受系统衰减时间限制；多数演示停在器件/小系统级；各基质间缺乏统一基准 —— 这四条与第 9 节的横贯性观察完全一致。

7.1 技术路线梳理与未来展望

这条路径只有四篇文献，但它们恰好覆盖了「非常规计算基质」的三条支线与一个统一框架。它的价值不在算力，而在**划定「物理计算」概念的外边界**：

支线	代表工作	技术特征	现状锚点（口径）
机械计算	Mei2023 / Alu2025	信息以形变状态存储、计算经形变演化完成；「结构即计算」的具身路线（超材料 / 可编程物质 / 软体结构）	3D 打印机械二值神经网络、自学习感知机、16 逻辑门全实现（实测）；速度 Hz–kHz（原理性慢）
生物基质	Cai2023	脑类器官的非线性动力学与衰减记忆充当储备池，训练只作用于读出层，连接可塑性即「训练」	语音识别 + 非线性方程预测（实测演示）；可复现性受存活期 / 批次 / 漂移制约
统一框架	Tanaka2019	物理储备池范式：只训练读出层；覆盖电子 / 光子 / 自旋 / 机械 / 生物五类基质的共同比较语言	方法论基线 —— 本报告 §4/§5/§7 的多篇工作可纳入同一框架

未来展望（基于本语料的判断）

- **定位是「物理自由度普查」，不是算力竞争**：机械速度比电子慢 6–9 个数量级、生物基质可复现性天然受限 —— 这条路径的任何出路都始于为基质找到与物理特性匹配的任务生态位，而非对标 GPU。
- **机械计算的出路在场景而非速度**：Mei2023 证明学习不必依赖电学、Alu2025 把计算具身进材料本构与结构几何 —— 被动、零功耗、结构即传感-计算-执行合一的场景（软体机器人、自适应结构）是合理落点。
- **生物基质的近期定位是原理演示平台**：存活期、批次差异与响应漂移使它短期内无法成为可部署的计算产品；且它带有其他路径不存在的伦理维度（Cai2023 条目已注明），引用者不可回避。
- **「比较的地基」尚未打下**：机械域缺乏统一的能耗度量惯例（Mei2023 明言），Tanaka2019 的四条共识（依赖固有动力学 / 记忆深度受限 / 停留器件级 / 缺统一基准）全部适用于本路径。
- **储备池范式是新基质的最小可行闭环**：Tanaka2019 框架使任何新基质都能用「只训练读出」的最小闭环先证明有用，再谈规模化 —— 对这条路径的每个新支线都是现成的入场协议。

08 对照轴 · 量子机器学习与 AI-for-Physics（不属于主体，用于划界）

本节**不是** physics-for-AI 的组成部分 —— 收录这 11 篇的目的是**划界**。轴内分两簇： **量子侧**（量子机器学习与 NISQ 算法）与 physics-for-AI 分享「用物理系统做计算」的口号，但它的物理自由度（量子叠加/纠缠）与经典物理计算（热涨落、光干涉、电导）有本质区别，其成熟度结论正好构成主体的对照组； **AI-for-physics 侧**（神经网络势、材料发现）方向相反 —— 是用 AI 解物理问题。把这两簇放在同一份报告里，读者可以一眼区分三种容易混淆的「AI × 物理」组合。

8.1 量子侧：NISQ、变分算法、贫瘠高原与「去量子化」教训

Preskill2018 —— NISQ 时代及其之后（对照轴的总纲）

Quantum **2**, 79 (2018) `10.22331/q-2018-08-06-79` NISQ

核心工作

定义了「含噪中等规模量子（NISQ）」时代的概念框架：50–100 量子比特的设备可能在特定任务上超越经典计算机，但门噪声限制可可靠执行的电路深度；100 比特量子计算机「不会立刻改变世界」。文中的核心判断 —— **噪声是资源还是障碍、量子优势需要多深的电路、容错还有多远** —— 至今仍是对照轴的坐标系。

领域级共识

NISQ 设备是有用工具（多体物理探索），但「实用量子优势」至今未实现；容错量子计算仍需多年甚至数十年 —— 这与路径 ①–⑤ 的「工程距离」形成了量级上的对照：**经典物理计算的瓶颈是工程与口径问题，量子计算的瓶颈是物理资源问题。**

Cerezo2021 + McClean2018 + Larocca2025 —— 变分量子算法与贫瘠高原三部曲

Nat. Rev. Phys. **3**, 625 (2021) · Nat. Commun. **9** (2018) · Nat. Rev. Phys. **7**, 174 (2025)

`10.1038/s42254-021-00348-9` · `10.1038/s41467-018-07090-4` · `10.1038/s42254-025-00813-9` VQA 贫瘠高原

核心工作

三篇连读构成变分量子算法（VQA）的完整叙事弧：**Cerezo2021** 建立 VQA 的系统分类学（ansatz、代价函数、可训练性）；**McClean2018** 发现 **贫瘠高原** —— 随机参数化量子电路的梯度方差随问题规模指数衰减至零，训练地形指数级平坦；**Larocca2025** 对 BP 现象做全面综述：ansatz、初态、可观测量、损失函数、硬件噪声的任何不当选择都可触发 BP，并总结缓解策略及其代价。

领域级共识

VQA 曾是 NISQ 时代的头号应用候选，而 BP 问题被证明是其**结构性障碍**而非工程瑕疵：它是参数化量子电路的表达能力与可训练性的固有张力。对 physics-for-AI 的对照价值在于： **「物理自由度做计算」必须同时回答「可训练性」问题** —— 这正是 Momeni2025 把「物理神经网络的训练」列为头号开放问题的原因（经典物理计算的梯度可以反传，量子系统的梯度会被噪声淹没）。

两条对照短条目

Biamonte2017（Nature **549**, 195–202 (2017)，DOI `10.1038/nature23474`，"Quantum machine learning"）： 量子机器学习领域的奠基性综述，划分了 QML 的四象限（量子数据 × 经典/量子处理器），并明确指出多数「指数加速」声明依赖**输入/输出假设**（态制备与读出）—— 这条警告在两年后被 Tang 的经典算法部分兑现。

Tang2021（"A quantum-inspired classical algorithm for recommendation systems"；盘内为 arXiv:1807.04271v3 排版，发表于 PRX **11**, 021019 (2021)）： 给 Kerenidis–Prakash 量子推荐系统（曾被认为是最强的指数加速候选）构造了**只慢多项式的经典算法** —— 证明其「指数优势」其实来自态制备假设。 对 physics-for-AI 的教训：**当有人声称某条物理路线有数量级优势时，第一个该问的问题是「优势来自物理，还是来自输入/输出口径」** —— 本报告 §3 的「峰值 vs 持续」、§5 的「光学很省 ≠ 系统很省」，都是同一认识论问题的不同化身。

8.2 AI-for-physics 侧：神经网络势与材料发现（方向相反的对照簇）

> 以下 5 篇（覆盖盘内 6 个文件，GNoME 有两份排版）是**用 AI 解物理问题** —— 方向与报告主体相反。收录原因：它们与主体的「物理器件做 AI」构成方法论镜像 —— 主体的核心难题是把 AI 负载映射到物理系统，这一簇的核心难题是把物理问题映射进 AI 的归纳偏置。三篇早期/方法类文献做精简条目。

Behler2007 → Rupp2012 → Carleo2017 —— 三个奠基节点（精简条目）

PRL **98**, 146401 (2007) · PRL **108**, 058301 (2012) · Science **355**, 602 (2017)

10.1103/PhysRevLett.98.146401 · 10.1103/PhysRevLett.108.058301 · 10.1126/science.aag2302 精简条目 ×3

核心工作

Behler2007：高维神经网络势（HDNNP）—— 用对称化原子环境描述符（Behler–Parrinello 对称函数）把 DFT 级精度的势能面表示为神经网络，解决了「神经网络如何保持平移/旋转/置换不变性」的第一性问题。 **Rupp2012**：用 Coulomb 矩阵描述分子 + 回归模型预测原子化能 —— 「分子指纹 → 性质」范式的第一个标准化基准（G2-137 数据集），机器学习进化学/材料的方法论起点。 **Carleo2017**：神经量子态（NQS）—— 用受限玻尔兹曼机表示多体量子波函数，变分蒙特卡洛优化，在自旋模型上达到并超越当时最先进张量网络方法的精度，开启「神经网络表示量子态」的研究方向。

共同教训（对主体的镜像价值）

这三篇成功的共同点是**把物理对称性写进网络结构**（不变性/等变性），而不是让网络从数据里学对称性 —— 这个设计原则在 15 年后的 NequIP 里仍然是胜负手。镜像到主体：物理计算硬件也要回答「物理自由度的对称性与约束如何映射进计算抽象」—— 只是方向相反。

Batzner2022 —— NequIP：E(3) 等变图神经网络原子间势（数据效率里程碑）

Nature Communications **13** (2022) 10.1038/s41467-022-29939-5 等变网络 分子动力学

核心工作

NequIP：把 E(3) 等变性（旋转/平移/镜像/置换）直接构造进消息传递图神经网络，学习原子间势。关键结果：**数据效率提升最多 3 个数量级** —— 用比既有方法少几个数量级的 DFT 训练数据达到同等或更高精度（如水体系上以 ~1k 结构达到此前需要 ~10^6 结构的精度水平），同时保持高推理速度。

创新点

证明了「对称性先验的正确编码」比「数据规模」更值钱 —— 与 GNoME 的「规模化」叙事形成同一簇内的两条路线张力（先验 vs 数据），是理解 AI-for-physics 方法论谱系的关键一对。

局限

等变算子计算开销大；外推到训练分布之外的化学空间仍是根本困难；力/能量的误差指标依赖具体基准集，跨基准比较需谨慎。

Merchant2023 —— GNoME：规模化深度学习做材料发现

Nature **624**, 80 (2023) 10.1038/s41586-023-06735-9 图网络 主动学习

核心工作

DeepMind 的 GNoME：图网络 + 主动学习闭环，把稳定无机晶体的已知数量**扩大一个数量级** —— 在既有 48,000 个稳定晶体基础上，发现 **220 万个**凸包以下的新结构（其中 38 万个位于最终凸包上），736 个已被独立实验合成。模型对「凸包距离」的预测误差降至约 0.02 eV/atom 级（此前方法约 0.1 eV/atom 级）。

创新点

① 「规模化 + 自训练闭环」在材料空间的胜利：发现的 220 万结构全部公开，直接催生 A-Lab 等自动化合成验证；② 把「发现」形式化为**过滤问题**（凸包稳定性判据），使 ML 产出可被物理判据硬性检验 —— 这一点对主体是重要提醒：物理计算的产出同样需要物理判据闭环。

局限

「稳定」≠「有用」：220 万结构绝大多数缺乏已知合成路径与目标应用；训练数据来自既有计算数据库（Materials Project 系），继承其偏差；凸包判据依赖势能面精度（DFT 级别）。

量化指标（分层标注）

数据规模：220 万新结构（220 万这个数字是**训练/筛选产出量**，与路径 ②③④ 的「物理自由度规模」完全不同维度 —— 本报告 §2.2 的「三种规模」即由此例立标）。**精度**：凸包距离误差 ~0.02 eV/atom 级。**验证**：736 个结构被独立实验合成。

8.3 对照轴小结：两簇路线的现状与展望

簇	路线脉络（按时间）	现状判断（本语料口径）
量子侧 量子机器学习 / NISQ	Preskill2018（NISQ 框架）→ Cerezo2021（VQA 分类学）→ McClean2018（发现贫瘠高原）→ Larocca2025（BP 全面化）→ Tang2021（去量子化教训）+ Biamonte2017（四象限分类）	「实用量子优势」至今未实现；BP 是参数化电路的结构性障碍而非工程瑕疵；「指数加速」声明多数依赖态制备 / 读出假设，Tang2021 已部分兑现这一警告
AI-for-physics 侧 方向与主体相反	Behler2007 / Rupp2012 / Carleo2017（三个奠基节点）→ Batzner2022（对称性先验线：数据效率提升最多 3 个数量级）→ Merchant2023（规模化线：220 万新结构）	「先验 vs 数据」两条路线的张力是本簇方法论主轴；「稳定 ≠ 有用」；物理判据闭环（736 个结构被独立实验合成）是产出可信度的关键

对照轴对主体的三重镜像价值（展望性质的收束）

- **瓶颈性质对照**：经典物理计算（路径 ①–⑤）的瓶颈是**工程与口径**问题（外围电路、基准缺失、一致性）；量子侧的瓶颈是**物理资源**问题（噪声、电路深度、纠错）—— 两者的「距离实用」不在同一个数量级上（Preskill2018）。
- **可训练性对照**：量子系统的梯度会被噪声淹没（BP），经典物理系统原则上可以反传（Pai2023 已在光域实验）—— 但「梯度如何穿过不可微分的器件」仍是共同未解题（Momeni2025）。「物理自由度做计算」必须同时回答「可训练性」。
- **口径审查对照**：Tang2021 证明优势可以来自输入/输出假设而非物理本身 —— 这是给路径 ①–⑤ 的通用警报：本报告各条目的「峰值 vs 持续」「实测 vs 外推」「口径提示」都是这一教训在工程层的化身。量子侧用二十年学到的怀疑纪律，经典物理计算现在就该用。

09 横贯性发现：六条跨路径的规律

以下六条规律不是任何单篇论文的结论，而是把 55 篇语料并排放在一起后才显形的模式 —— 这也是本报告用「技术路径」而非「论文列表」组织的原因。

发现 1 · 「器件级 → 系统级」的能效落差是本领域最稳定的规律，落差常达 2–30×

路径 ① 给出了最干净的量化样板：Ambrogio2023 的 tile 峰值 20.0 TOPS/W → 全芯片持续 6.94 TOPS/W（2.9×）。但同一模式在光子路径同样成立 —— McMahon2023 引用的原型（单次通过 >5×10^5 次标量乘）整机性能比电子差几个数量级；Wetzstein2020 点名批评的「不计光电转换」的能耗估计是同一枚硬币的反面。**读这个领域任何能效数字，第一个问题永远是：这一层算到哪一级？**

发现 2 · 外围电路（ADC/DAC/TDC/接口）是落差的主要来源，且已被显式量化

这不是定性的抱怨，语料里有硬数字：Jung2022 用 TDC 替代 ADC 换来的 262→405 TOPS/W 依赖供电从 1.0 V 降到 0.8 V、精度让出 0.83-bit —— 周边电路与核心阵列的权衡被写成了显式曲线；Shen2017 的热调相移维持功耗 10 mW/MZI（静态！）与其「fJ/FLOP」外推口径之间的矛盾；Tait2017 的 3.0 W 静态热调功耗；Melanson2025 的 SPU 功耗由 ADC 主导（0.005 mW/单元）。**模拟计算复活的原因是 AI 不需要高精度，而模拟计算的死因是转换精度需求 —— 这两句话同时成立。**

发现 3 · 「规模」至少有三种互不可比的含义（§2.2 的展开）

物理自旋数（Litvinenko2025 的 50）、器件电导级数（Rao2023 的 2,048）、训练数据量（Merchant2023 的 220 万）在各自的论文里都是 headline 数字，但互相之间不存在换算关系。额外的第四种：FPGA p-bit 数（Niazi2024 的 4,264 / Nikhar2024 的 1,008 并行）—— 它衡量的是「可编程随机性资源」，与 s-MTJ 投影的 10^6 又隔着一个未实现的器件工程。**跨论文比较规模数字前，先问它数的是什么。**

发现 4 · 多数路径缺「系统级任务评测」，能效的账不闭合

语料覆盖度上：路径 ① 的 7 篇器件论文有 5 篇给出芯片级实测指标（最好）；路径 ③ 的 7 篇研究论文只有 4 篇给出系统级口径数字（且多为外推/预测 —— 294×、50 zJ/MAC、fJ/FLOP 全部是预测口径）；路径 ② 是 0%（全部停在器件现象与综述）；路径 ④ 报 TTS 与采样率但**无一篇报 TOPS/W 类能效**；路径 ⑤ 无能效度量惯例。后果：**任何「哪条路线最省能」的跨路径排名在当前语料下都无法诚实地做出** —— 这就是本报告拒绝给出排名的技术原因。

发现 5 · 「利用物理涨落」与「抑制物理涨落」是两条相反但都成立的技术路线

同一种物理现象在不同路径里扮演相反角色：热/量子涨落在路径 ④ 是**计算资源**（p-bit、热力学采样器 —— Melanson2025 甚至刻意把噪声加大到超过本征水平），在路径 ①③ 是**必须抑制的误差源**（Jung2022 的供电-精度权衡、Hamerly2019 的散粒噪声极限、Shen2017 的噪声-精度外推）。散粒噪声尤其典型：在 Hamerly2019 里它是能效的**下限设定者**（50 zJ/MAC），在 Wetzstein2020 里它是模拟光学的**根本障碍。读论文先分清它站在哪一边。**

发现 6 · 物理基质决定「耦合/互连」瓶颈的形状，进而决定可扩展性的天花板

每条路径的「卡点」都不相同，且都指向同一个抽象位置 —— 耦合与互连：电子 crossbar 的卡点是 ADC 与 sneak path（发现 2）；光子 MZI 网格的卡点是 N^2 相移器与级联损耗（Shen2017 → Hamerly2019 专门为绕开它而生）；CIM 的卡点是耦合注入的可编程性（Marandi2014 固定延迟线 → McMahon2016 测量-反馈，用电子反馈换可编程性）；Ising 机的卡点是 all-to-all 的 $O(n^2)$ 权重依赖（Nikhar2024 的稀疏主图 + 复用）；p-bit 机的可扩展性上限则干脆押在尚未实现的 s-MTJ 阵列上。**评估一条新路线时，先找它的「耦合瓶颈」长什么形状。**

10 语料库方法论：55 篇全文是怎么被验证的

本报告的每一条目内容都直接取自出版社官网下载的 PDF 全文（见第 1 节口径）。这一节记录语料库本身的构建过程、错误率与修正 —— 因为本轮构建中实测的**参考文献错误率高达 28%**，任何不做核验的「AI 综述」都不可信，读者应当知道本报告为对抗这一点做了什么。

10.1 最终语料构成

路径	盘内全文	构成说明
① 存内计算	11	7 篇器件/芯片研究 + Sebastian2020 / Ielmini2018 两篇综述 + Momeni2025（训练方法论）+ Kudithipudi2025（规模化综述）
② 自旋磁子	9	4 篇综述（Baltz/Grollier/Dieny/Everschor-Sitte）+ 5 篇研究（Camsari2017 / Kumar2025 / Litvinenko×2 / Prychynenko）
③ 光子计算	11	7 篇研究工作（Pai2023 正文+补充材料各 1）+ McMahon2016 补充材料 + 3 篇综述
④ 概率 Ising	9	7 篇研究（Borders/Sutton/Chowdhury/Niazi/Nikhar/Melanson/Aifer）+ Mohseni2022、Albash2018 两篇综述
⑤ 新兴基质	4	Mei2023 / Cai2023 / Alu2025 / Tanaka2019
⑥ 对照轴	11	量子侧 6（Preskill/Biamonte/Cerezo/McClean/Larocca/Tang）+ AI-for-physics 侧 5（Behler/Rupp/Carleo/Batzner/GNoME）
合计	**55**	全部为出版社/期刊官方 PDF；唯一例外见 10.3 第 4 条

10.2 逐层验证管线（每篇 PDF 必过四关）

1. **魔数头**：`%PDF` 字节头校验 —— 拦截把 HTML 拦截页/Cloudflare 页存成 .pdf 的情况；
2. **首页关键词**：用 `norm()`（去空白、去软连字符、还原 fi/fl 连字）后做标题/摘要关键词组匹配 —— 拦截「下载到了别的论文」；
3. **垃圾词黑名单**：12 个跨域词（melanoma、SARS-CoV-2、ebselen、sortase 等，均来自实际踩坑）→ 命中即拒 —— 拦截「同名关键词、完全无关论文」（例：Honjo2021 实为 SARS-CoV-2 论文、Aadit2023 实为 1T-TaS_2 相变论文，均被此关拦截）；
4. **轴归属审计**：六轴关键词打分复核每篇论文的路径归属（本轮 0 例可疑）。

全量复核结果：**TOTAL 55（去重后）| OK 55 | BAD 0 | ERR 0。**

10.3 本轮实测的坑（对后来者最有价值的一节）

1. **入口 DOI 错误是错误率的根因**：28% 的初始参考文献错误中，绝大多数不是「下载通道坏了」，而是**给下载器的 DOI 本身指错了论文**（例：把 Mn_3Ge 掺杂论文当作某篇自旋电子学综述来下）。对策已固化为本流程第 0 步：**任何条目写入报告前，先经 Crossref/OpenAlex 核验 title / container-title / 卷页。**本轮 §5 写作中该纪律当场又抓出 3 处错误（Feldmann2019 的 DOI 与卷页、Marandi2014 的卷页、Borders2019 的卷页 —— 均为「记忆正确率 < 100%」的直证）。
2. **APS 的 Cloudflare 按出口 IP 信誉分级放行**：同一 URL 在两个并行工作环境中一个得 200、一个得 403 —— 双方测量都真实。定稿策略：**先 requests 直连，403 再转浏览器同源分片；`link.aps.org` 跳转域名禁用**（跨源 302 重定向被 CORS 拒绝）。
3. **关键词核验的假阴性**：Science 排版把 "artificial" 拆成 ligature（`Arti⨀ial`）、RMP/Nature Photonics 的标题在第二页之后 —— 修复 = 去空白归一化 + 扫描前 4 页。只修一半就会漏报。
4. **Science 的 `citation_pdf_url` 元数据指向补充材料而非正文**（Pai2023 实测）：需手工构造 `/doi/pdf/<DOI>` 且带 Referer。本报告对此的处理是**正文与补充材料两份都保留**（03 轴的 06/09 两个文件）；同理，McMahon2016 盘内仅持有补充材料 PDF（含 Materials and Methods，正文未单独下载）—— 条目中已如实标注。
5. **语料中唯一非出版社排版文件**：`Tang2021` 为 arXiv:1807.04271v3 排版（内容经核验确为该论文本身，对应发表版 PRX 11, 021019 (2021)）。按「只从出版社下载」的口径它是唯一残留，特此明示；如需纯出版社版可从 APS 补下。
6. **Nature 直连 `/articles/<suffix>.pdf` 会返回 HTML 落地页**（本轮实测）：解决 = 带 cookie jar + Referer 的完整浏览器式头（本轮 2/2 成功）。无头直连版本已不可靠。
7. **并发写文件的中文文件名截断**：多进程同时改同一批文件名曾把文件名截断 —— 对策 = 每个文件名用 UTF-8 字节数校验后落盘，且**各工作环境只动自己路径轴的文件。**

10.4 本轮隔离与更正台账（全部为移入隔离区，未硬删除）

处置	文件	原因
隔离	`05/Zolfagharinejad2025_物理计算语音识别.pdf`	与 01 轴文件 sha256 逐字节相同（跨轴重复）

处置	文件	原因
隔离	`06/Zhang2023GNoME_材料发现规模化深度学习.pdf`	与同目录另一 GNoME 文件逐字节相同
隔离	`06/Preskill2018_含噪量子计算.pdf`	与「NISQ时代」文件为**同一论文的两种排版**（首页文本逐字相同）
改名	`Kumar2022_NatCommun_随机纳米磁体Ising.pdf` → `Sutton2017_SciRep_随机纳米磁体内在优化.pdf`	原文件名作者/年份/期刊全误；经 Crossref 核验实为 Sutton, Camsari, Behin-Aein & Datta, Sci. Rep. 7:44370 (2017)
改名（更早轮次）	`Hamerly2019`、`Mei2023`、`Feldmann2019`（文件名中「全光卷积」与实际论文「全光脉冲神经突触网络」不符，正文条目已按核验后引文书写）	文件名与内容对齐
隔离（更早轮次）	Mikolajick2023（1 页 Editorial）、Aadit2023（1T-TaS_2 论文）、Honjo2021（SARS-CoV-2 论文）、Tang2021 竞争传播论文、wrongaxis_Albash2018	跨域内容 / 轴归属错误

> 与报告本体的分工：本节只记录「语料可信度」；论文内容层面的所有数字层级标注规范见第 1 节与各条目的「口径提示」。

11 缺口与未解决问题

本报告明确不回答「该选哪条路」（见第 1 节）。但语料本身暴露的**技术缺口**值得列出 —— 它们是这个领域未来 3–5 年真正的看点：

1. **系统级评测基准的缺失是全局性瓶颈。**路径 ④ 的作者（Nikhar2024）与路径 ③⑤ 的综述（Shastri2021、Tanaka2019）用几乎相同的措辞抱怨「没有统一基准」。在基准出现之前，跨路线的能效/性能比较都应视为营销口径。
2. **训练问题在物理计算里普遍未解。**Momeni2025 把「物理神经网络的训练」定义为领域级方法论问题；Pai2023 给出光域原位反向传播的第一个实验；FPGA p-bit 用对比散度训练玻尔兹曼网络（Niazi2024）—— 三条线索指向同一问题：**梯度如何穿过一个不可微分的物理系统。**
3. **可级联性是非线性光学器件的死结**（Shastri2021：全光神经元的输出常弱于输入、甚至无法驱动下一级）。在它被解决前，「全光」路线的实际形态大概率是光电混合的。
4. **量子机器学习对「物理计算」的教训尚未被充分吸收**：Tang 的去量子化结果与 BP 理论（McClean2018 → Larocca2025）合起来说明，「来自物理的优势声明」必须经受「口径假设审查」与「可训练性审查」双重检验 —— 而路径 ①–⑤ 的大量论文尚未通过同等强度的检验（发现 4）。
5. **物理器件的可靠性工程数据不足**：PCM 耐久性、RRAM 漂移、s-MTJ 翻转率分布、类器官存活期 —— 语料中几乎没有跨工艺批次的统计可靠性报告，而这是所有模拟路线走向产品的必经之路。
6. **语料自身的缺口**：本语料以 Nature/Science/APS/RMP 高影响力论文为主，天然偏向「成功演示」—— 负结果与失败试错几乎不存在于顶刊语料中；掺杂网络、 Electrochemical RAM 等子方向覆盖较浅；路径 ② 的高规模声表面波/磁子系统（>50 自旋）在公开文献中仍是空白，Litvinenko2025 的 50 自旋已接近当前公开水平的天花板。

免责声明与使用说明

本报告是**技术领域报告**：理解「物理用于 AI 计算」这一研究领域的技术现状。 它**不包含**：PI 排名、课题组招生信号、博士申请建议、选组策略 —— 任何此类延伸都超出了报告的编写口径。 所有论文条目基于出版社官方 PDF 全文书写；数字严格按原文层级标注（器件级 / 单片级 / 系统级 / 仿真级 / 外推 / 模型预测）， 原文未提供者写「未提供」，不推算、不补全。引用请回溯原始文献（各条目 DOI 已核验）。 语料 55 篇全文 PDF 存于 `papers/01–06` 六个路径目录，验证管线与台账见第 10 节。 报告生成于 2026-09-23；2026-09-24 修订：Tanaka2019 条目按原文目录校正，并新增各路径的「路线梳理与未来展望」小节（3.3 / 4.3 / 5.4 / 6.3 / 7.1 / 8.3）。